

Modelos estacionarios y no estacionarios

Series de tiempo con Python

Econ. Morales Alberto Alexis Adonai

2026



Procesos estocásticos y estacionarios

Un **proceso estocástico** es una familia de variables aleatorias que, en general, están relacionadas entre sí y siguen una ley de distribución conjunta. Se denota por:

$$Y_t(\omega), t = \dots, t-2, t-1, t, t+1, t+2, \dots, \\ \text{ó } \dots, Y_{t-2}, Y_{t-1}, Y_t, Y_{t+1}, Y_{t+2}, \dots, \\ [Y_t]_{-\infty}^{+\infty}$$

Dicho de otra manera, se le denomina un **proceso estocástico** a un conjunto de variables u observaciones aleatorias que están sujetas en el tiempo t . Es decir, cada variable X_t es una observación que está definida sobre el mismo espacio de probabilidad Ω . El conjunto de índices $\mathbf{T}$ se denomina **espacio de tiempo**, donde dichos espacios son en tiempo discreto o continuo.

Características de un proceso estacionario

Un proceso estocástico se puede caracterizar bien por su función de distribución o por sus momentos, los cuales se explican a continuación:

❶ Función de distribución:

Para conocer la función de distribución de un proceso estocástico es necesario conocer las funciones de distribución univariantes de cada una de las variables aleatorias del proceso, $F[Y_t]$, $\forall t$, y las funciones bivariantes correspondientes a todo par de variables aleatorias del proceso, $F[Y_{t_i}, Y_{t_j}]$, $\forall(t_i, t_j)$, y todas las funciones trivariantes, etc.

Características de un proceso estacionario

En resumen, la función de distribución de un proceso estocástico incluye todas las funciones de distribución para cualquier subconjunto finito de variables aleatorias del proceso:

$$F[Y_{t_1}, Y_{t_2}, \dots, Y_{t_n}] \quad \forall (t_1, t_2, \dots, t_n)$$

Características de un proceso estacionario

2 Momentos del proceso estocástico:

Como suele ser muy complejo determinar las características de un proceso estocástico a través de su función de distribución se suele recurrir a caracterizarlo a través de los dos primeros momentos.

- a) El primer momento de un proceso estocástico viene dando por el conjunto de **medias** de todas las variables aleatorias del proceso:

$$E(Y_t) = \mu_t < \infty, \quad t = 0, \pm 1, \pm 2, \dots,$$

Características de un proceso estacionario

- b) El segundo momento de un **proceso estocástico** esta centrado en lo que viene dando por el conjunto de las **varianzas** de todas las variables aleatorias del proceso y por las **covarianzas** entre todo par de variables aleatorias:

$$V(Y_t) = E[Y_t - \mu_t]^2 = \sigma_t^2, < \infty \quad t = 0, \pm 1, \pm 2, \dots,$$
$$\text{cov}(Y_t, Y_s) = E[Y_t - \mu_t][Y_s - \mu_s] = \gamma_{t,s}, \quad \forall t, s \quad (t \neq s)$$

Proceso estocásticos estacionarios

Dentro de la teoría de series de tiempo, el objetivo de utilizar los **proceso estocásticos** es determinar qué clase de **proceso estocástico** es capaz de generar la serie temporal (a estudiar) con el fin de caracterizar el comportamiento de la serie y predecir en el futuro (con base al planteamiento de una estructura autorregresiva, de medias móviles, etc).

El concepto de **estacionariedad** se puede caracterizar bien, en términos de la función de distribución o de los momentos del proceso. En el primer caso, se hablará de *estacionariedad en el sentido estricto* y, en el segundo, de *estacionariedad de segundo orden o en covarianza*.

❶ Estacionariedad estricta:

Un proceso estocástico, Y_t , es estacionario en el sentido estricto si y solo si:

$$F[Y_{t_1}, Y_{t_2}, \dots, Y_{t_n}] = F[Y_{t_1+k}, Y_{t_2+k}, \dots, Y_{t_n+k}] \\ \forall (t_1, t_2, \dots, t_n)$$

Es decir, si la función de distribución de cualquier conjunto finito de n variables aleatorias del proceso no se altera si se desplaza k periodos en el tiempo.

Proceso estocásticos estacionarios

2 Estacionariedad en covarianza:

Un **proceso estocástico**, Y_t , es estacionario en covarianza si y solo si:

- a) Es estacionario en media, es decir, todas las variables aleatorias del proceso tienen la misma media y es finita:

$$E(Y_t) = \mu < \infty \quad \forall t$$

- b) Todas las variables aleatorias tienen la misma varianza y es finita, es decir, la dispersión en torno a la media constante a lo largo del tiempo, es la misma para todas las varianzas del proceso:

$$V(Y_t) = E[Y_t - \mu]^2 = \sigma_Y^2 < \infty, \quad \forall t$$

- e) Las autocovarianzas solo dependen del número de periodos de separación entre las variables y no del tiempo, es decir, la covarianza lineal entre dos variables aleatorias del proceso que disten k periodos de tiempo es la misma que existe entre cualesquiera otras dos variables que estén separadas también en k periodos, independientemente del momento concreto de tiempo al que estén referidas.

$$\text{cov}(Y_t, Y_s) = E[Y_t - \mu][Y_s - \mu] = \gamma_{|t-s|} = \gamma_k < \infty, \forall k$$

Proceso estocásticos estacionarios

Por lo tanto, un proceso estocástico es estacionario en covarianza si solo si:

$$E(Y_t) = \mu < \infty \quad (A)$$

$$\text{cov}(Y_t, Y_s) = \begin{cases} V(Y_t) = \sigma_Y^2 < \infty & t = s \\ \gamma_{|t-s|} = \gamma_k < \infty & t \neq s \end{cases} \quad (B)$$

Proceso estocásticos estacionarios

Un proceso estocástico estacionario en covarianza está caracterizado si se conoce:

$$\mu, V(Y_t), \gamma_k, k = \pm 1, \pm 2, \dots$$

Si un proceso estocástico es estacionario en covarianza y su distribución es **normal**, es estacionario en sentido estricto.

Proceso estocásticos estacionarios

En resumen, los procesos **estocásticos estacionarios** son aquellos donde **la media y la varianza** de un conjunto de observaciones Y_t , son constantes en el tiempo **T** y además que existe la **covarianza** entre dos periodos de tiempo. Donde el valor de está depende sólo de la distancia o rezago entre estos dos periodos, y no del tiempo en el cual se calculó la covarianza.

$$E(Y_t) = \mu \quad (1)$$

$$Var(Y_t) = E(Y_t - \mu)^2 = \sigma^2$$

$$Cov(Y_t, Y_{t-k}) = \gamma_k = E[(Y_t - \mu) - (Y_{t-k} - \mu)]$$

Ruido blanco

El proceso estocástico más sencillo, y que por lo general, es en el que más se basa para afirmar la estacionariedad, es denominado **ruido blanco** y consiste en una secuencia de variables aleatorias de media cero, varianza constante y covarianzas nulas. Se denotará habitualmente por a_t , $t = 0, \pm 1, \pm 2, \dots$,:

$$E(a_t) = 0, \forall t$$

$$V(a_t) = \sigma^2, \forall t$$

$$\text{cov}(a_t, a_s) = 0, \forall t \neq s$$

Ruido blanco

Así, un proceso de **ruido blanco**, $a_t \sim RB(0, \sigma^2)$, es estacionario si la varianza σ^2 es finita con una función de autocovarianzas (FACV):

$$\gamma_k = \sigma^2, k = 0 \text{ y } \gamma_k = 0, k > 0$$

Y la función de autocorrelación (FAC):

$$\gamma_k = 1, k = 0 \text{ y } \gamma_k = 0, k > 0$$

Modelo lineal estacionario

Dentro de los procesos estocásticos estacionarios se considerará únicamente la clase de procesos lineales que se caracterizan porque se pueden representar como una combinación lineal de variables aleatorias. En el caso de procesos estacionarios con distribución normal y media cero, la teoría de procesos estocásticos señala que, bajo condiciones muy generales, Y_t se puede expresar como combinación lineal de los valores pasados infinitos de Y_t más una innovación de ruido blanco:

$$Y_t = \pi_1 Y_{t-1} + \pi_2 Y_{t-2} + \pi_3 Y_{t-3} + \cdots + a_t \quad \forall t \quad t = 1, 2, \dots \quad (2)$$

Modelo lineal estacionario

Las condiciones generales que ha de cumplir el proceso son:

- a) Que el proceso sea **no anticipante**, es decir, que el presente no venga determinado por el futuro, luego el valor de Y_t en el momento t no puede depender de valores futuros de Y_t o de las innovaciones a .
- b) Que el proceso sea **invertible**, es decir, que el presente dependa de forma convergente de su propio pasado, lo que implica que la influencia de Y_{t-k} en Y_t ha de ir disminuyendo conforme se aleje del pasado. Esta condición se cumple si los parámetros del modelo general (2) cumplen con la siguiente restricción:

$$\sum_{i=1}^{\infty} \pi_i^2 < \infty$$

Modelo lineal estacionario

El modelo (2), se puede escribir de forma más compacta en términos del operador de retardos:

$$\begin{aligned} Y_t &= \left(\pi_1 L + \pi_2 L^2 + \cdots \right) Y_t + a_t \\ \left(1 - \pi_1 L - \pi_2 L^2 - \cdots \right) Y_t &= a_t \\ \Pi_\infty(L) Y_t &= a_t \end{aligned}$$

Otra forma de escribir el modelo (2) es:

$$\begin{aligned} Y_t &= \frac{1}{\Pi_\infty(L)} a_t = \Psi_\infty(L) a_t \\ Y_t &= \left(1 - \psi_1 L + \psi_2 L^2 + \cdots \right) a_t \\ Y_t &= a_t + \psi_1 a_{t-1} + \psi_2 a_{t-2} + \psi_3 a_{t-3} + \cdots \quad t = 1, 2, \dots \end{aligned} \tag{2.1}$$

Modelo lineal estacionario

Es decir, el valor de Y_t se puede representar como la combinación lineal del ruido blanco a_t y su pasado infinito. El modelo (2.1) cumple la condición de estacionariedad si los parámetros del modelo satisfacen la siguiente restricción:

$$\sum_{i=1}^{\infty} \psi_i^2 < \infty$$

Esta restricción implica que el valor presente depende de forma convergente de las innovaciones pasadas, es decir, la influencia de la innovación a_{t-k} va desapareciendo conforme se aleja en el pasado.

Conceptos fundamentales de procesos no estacionarios

Dentro de los procesos no estacionarios, se deben identificar esta clase de modelos que se le denominan **deterministas** y esto se debe a que son estructuras que no se pueden estimar, ya que generarían procesos de regresión espuria al no cumplir con las condiciones de un **proceso estocástico estacionario**.

Caminata aleatoria.- Modelo que describe que el comportamiento de Y_t esta dado por el valor anterior Y_{t-1} más un choque aleatorio μ_t matemáticamente:


$$Y_t = Y_{t-1} + \mu_t \quad (2)$$

Conceptos fundamentales de procesos no estacionarios

Caminata aleatoria con deriva.- En esta función determinista, solo se visualiza la deriva de Y_t y si su movimiento es hacia arriba o hacia abajo, algo parecido a AR(1):

$$Y_t = \delta + Y_{t-1} + \mu_t \quad (3)$$

Ejemplo de caminata aleatoria



Proceso estocástico de raíces unitarias

Las condiciones de un proceso estocástico, es que los datos no presenten correlación en el tiempo T , dado a n periodos. Por lo tanto, los términos de no estacionariedad, caminata aleatoria, raíz unitaria y tendencia estocástica, se consideran sinónimos.

Como una condición particular para el modelaje ARIMA/ARMA, establece que las series deben ser estocásticamente estacionarias, es por ello que la correlación no debe presentarse en la serie.

$$Y_t = \rho Y_{t-1} + \mu_t \quad (4)$$
$$-1 \leq \rho \leq 1$$

¿Cómo se puede identificar un proceso estacionario?

Existen pruebas estadísticas y gráficas que permiten evaluar la existencia de ρ dentro de una serie de tiempo, estas son las siguientes:

- Pruebas estadísticas:

- ▶ Dickey-Fuller.
- ▶ Dickey-Fuller Aumentada.
- ▶ Phillips-Perron
- ▶ KPSS
- ▶ Zivot Andrews

- Pruebas gráficas:


- ▶ ACF (Función de autocorrelación simple)
- ▶ PACF (Función de autocorrelación parcial)

1 ACF

Función de autocorrelación simple (ACF).- Para entender el concepto se considera una serie de tiempo débilmente estacionaria. Por lo tanto, la función de autocorrelación simple es una colección de autocorrelaciones en diferentes rezagos. El coeficiente de correlación entre X_t y X_{t-k} es llamada o denominada ***autocorrelación de retardo-k*** de X_t y comúnmente se denota por ρ_k :

$$\rho_k = \frac{\text{Cov}(x_t, x_{t-k})}{\sqrt{\text{Var}(x_t) \text{Var}(x_{t-k})}} = \frac{\text{Cov}(x_t, x_{t-k})}{\text{var}(x_t)} = \frac{\gamma_k}{\gamma_0}$$

Ejemplo ACF




2 PACF

Función de autocorrelación parcial (PACF).- Es una prueba asociada a la de función de autocorrelación simple, que busca medir la correlación entre valores de una secuencia temporal, es por ello que se denomina la función de autocorrelación parcial. Es el conjunto de coeficientes de autocorrelación parcial desde el retardo $K = 1$, hasta un máximo posible de retardos igual a la mitad de la cantidad de valores contenidos en la secuencia., se realiza mediante el estadístico insesgado para ρ_{kk} :

$$\rho_{kk} = \frac{\rho_k - \sum_{j=1}^{k-1} \rho_{k-j} (\rho_{k-1j} - \rho_k * \rho_{k-1k-j})}{1 - \sum_{j=1}^{k-1} \rho_j (\rho_{k-1j} - \rho_k * \rho_{k-1k-j})}$$

Ejemplo PACF




¿Cómo se visualizan los correlogramas cuando una serie no es estacionaria?

Cuando iniciamos el análisis básico de una serie de tiempo, comenzamos con su gráfico inicial, es decir, con el comportamiento de la misma serie. Se podrá observar elementos tales como:

- Una constante de origen.
- Tendencia.

Posterior a ello, se utiliza como primer herramienta de análisis de estacionaridad, la función de autocorrelación simple. Ahora, si esta última no presenta una caída exponencial, entonces se puede intuir que la serie tiene un proceso no estacionario.

Ejemplo: Serie no estacionaria



❶ Dickey-Fuller

Dickey-Fuller es una prueba que consiste en regresionar un proceso $AR(1)$ con la serie diferenciada como variable dependiente y la serie sin transformación y en un primer rezago como variable independiente.

La desventaja de dicha prueba es que no hay un rezago óptimo, por lo tanto el sustento de validación se basa solo en encontrar la significancia de los parámetros usados en la regresión auxiliar.

Hay tres tipos de prueba:

- Sin constante.
- Con constante pero sin tendencia
- Con constante y tendencia

Prueba Dickey-Fuller

a) Dickey-Fuller sin tendencia

$$\Delta Y_t = \delta Y_{t-1} + \varepsilon_t$$

b) Dickey-Fuller con constante

$$\Delta Y_t = \beta_0 + \delta Y_{t-1} + \varepsilon_t$$

c) Dickey-Fuller con tendencia y constante

$$\Delta Y_t = \beta_1 + \beta_2 t + \delta Y_{t-1} + \varepsilon_t$$

• Nota

Donde $\delta : (\rho - 1)$

Prueba Dickey-Fuller: Demostración

Para poder identificar la estimación de los modelos de Dickey-Fuller, se debe considerar o partir del siguiente modelo:

$$Y_t = \rho Y_{t-1} + u_t$$

Sin embargo, el modelo anterior no se puede estimar, es por ello que (Gujarati, 2010) menciona que el proceso de transformación del anterior modelo, solo consiste en restar la ecuación con Y_{t-1} en ambos lados, tal y como se muestra a continuación:

$$Y_t - Y_{t-1} = \rho Y_{t-1} - Y_{t-1} + u_t$$

$$\Delta Y_t = (\rho - 1) Y_{t-1} + u_t$$

$$\Delta Y_t = \delta Y_{t-1} + u_t$$

Prueba Dickey-Fuller Aumentada ADF

Una forma de comprobar las raíces unitarias en una serie de tiempo, es a través de la prueba de Dickey-Fuller Aumentada, que consiste en estimar la siguiente regresión:

$$\Delta Y_t = \beta_1 + \beta_2 t + \delta Y_{t-1} + \sum_{i=1}^m \alpha_i + \Delta Y_{t-i} + \varepsilon_t$$

La finalidad de dicha regresión es ver si los coeficientes se correlacionan entre sí cada i rezagos, obteniendo **tau** como un valor crítico a niveles de confianza del 99, 95 y 90 %.

La hipótesis de la prueba es:

$H_0 : \delta = 0$ Tendencia estocástica $\rightarrow$ No estacionariedad

$H_a : \delta < 0$ No tendencia estocástica $\rightarrow$ Estacionariedad

Phillips-Perron

Es una prueba similar a ADF solo que esta no es paramétrica, en ella se mejoran las matrices de varianzas para que los regresores no se correlacione. La regresión propuesta por Phillips-Perron es la siguiente:

$$Y_t = \mu + \alpha Y_{t-1} + u_t$$

$$Y_t = \mu + \beta \left(t - \frac{1}{2} T \right) + \alpha Y_{t-1} + u_t$$

- Hipotesis nula (H_0): Hay al menos una raíz unitaria (serie no estacionaria en media).

Se corrige la inconsistencia de la matriz de varianzas y covarianzas calculada mediante un procedimiento alternativo al ADF (fundado en Newey-West).

Prueba KPSS

Es una prueba formulada por Denis Kwiatkowski, Peter Phillips, Peter Schmidt y Yongcheol Shin. Su objetivo es innovar las pruebas anteriores (ADF y PP) mediante la creación de un multiplicador lagrangeano que busque medir la consistencia de la varianza de una serie de tiempo, bajo este supuesto, entonces la prueba KPSS nos dirá si la serie es estacionaria solo si su varianza es constante.

$$Y_t = \xi t + r_t + \varepsilon_t$$

- Donde:

$$r_t = r_{t-1} + u_t$$

Mediante las regresiones auxiliares que se presentaron anteriormente, se formula un estadístico con la varianza de la estimación y la varianza de los residuales:

$$LM = \sum_{i=1}^T \left(\frac{S_t^2}{\sigma_\varepsilon^2} \right)$$

● Donde:

- ▶ S_t^2 : Varianza de la estimación MCO
- ▶ σ_ε^2 : Varianza de los errores.

- Hipótesis

$$H_0 : \sigma_{\varepsilon}^2 = 0 \text{ Estacionariedad}$$

$$H_a : \sigma_{\varepsilon}^2 > 0 \text{ No estacionariedad}$$

¿Qué se debe hacer en caso de no presentar un proceso estacionario?

Cuando se estudia una serie de tiempo y esta resulta no ser estacionaria, la teoría matemática y estadística, hace mención de aplicar **primeras diferencias**, lo cual es una transformación que elimina la tendencia y la constante de origen y provoca que la serie se parezca a un ruido blanco.



¿Qué son las primeras diferencias?

Consiste en una transformación matemática, basada en un procedimiento de resta entre la serie original menos un rezago de la misma. Es definido como:

$$\begin{aligned}\Delta Y_t &= (Y_t - Y_{t-1}) \\ \Delta \Delta Y_t &= \Delta(Y_t - Y_{t-1}) = Y_t - 2Y_{t-1} + Y_{t-2}\end{aligned}$$

Ejemplo de una primera diferencia

Se dice que la serie es estacionaria, ya que se comporta como un ruido blanco $wn \sim (0, \sigma^2)$:



¿Qué es el orden de integración?

En términos más básicos, el orden de integración es aquel número de diferenciaciones que requiere una serie para ser estacionaria, que comúnmente se identifica con la definición $I(d)$.

Para conocer el orden de integración, es necesario hacer las pruebas anteriores en $I(0)$, es decir, la serie sin diferenciación. Si esta resulta estacionaria, se le conoce a la serie integrada de orden 0.

Sin embargo, la mayoría de las series requieren un proceso de diferenciación y algunas requieren hasta dos diferenciaciones, por lo que $I(1)$ e $I(2)$ son utilizados para definir integración de orden 1 o 2.

Modelos estacionarios

Se dice que son modelos en donde la serie de tiempo Y_t no requiere de un proceso de integración para ser estacionaria. Estos modelos son:

- Modelo AR.
- Modelo MA.
- Modelo ARMA.

Modelo autorregresivo de orden p : AR(p)

Se trata de un modelo en el que una determinada observación es predecible a partir de la observación inmediatamente anterior o a partir de las dos observaciones que le preceden. La observación actual, se define como la suma ponderada de una cantidad finita p de observaciones procedentes más un impulso aleatorio independiente:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \phi_3 Y_{t-3} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

Proceso autorregresivo de orden 1: AR(1)

Un proceso autorregresivo de primer orden, consiste en que el análisis de la variable endógena (dependiente), se explica por si misma a través de un *shock* pasado, más un término de residual, tal como se muestra a continuación:

$$Y_t = c + \phi_1 Y_{t-1} + \varepsilon_t \quad t = 1, 2, \dots$$

Proceso autorregresivo de orden 1: AR(1)

Para demostrar si el modelo AR(1) es estacionario para cualquier valor del parámetro ϕ es preciso comprobar las condiciones de estacionariedad. En esta demostración se ocupará el procedimiento de medias.

1 Estacionariedad en media:

$$E(Y_t) = E(\phi_1 Y_{t-1} + \varepsilon_t) = \phi_1 E(Y_{t-1})$$

Para que el proceso sea estacionario, la media ha de ser constante y finita, lo que implica:

$$\begin{aligned} E(Y_t) &= \phi E(Y_t) \rightarrow (1 - \phi) E(Y_t) = 0 \\ E(Y_t) &= \frac{0}{1 - \phi} = 0 \end{aligned}$$

Proceso autorregresivo de orden 1: AR(1)

Por lo tanto, para que el proceso sea estacionario es necesario que el parámetro $\phi < 1$.

2 Estacionario en covarianza:

Para que el proceso sea estacionario, la varianza ha de ser constante y finita:

$$\gamma_0 = E(Y_t - E(Y_t))^2 = E(\phi Y_{t-1} + \varepsilon_t - 0)^2$$

$$\gamma_0 = \phi^2 E(Y_{t-1})^2 + E(\varepsilon_t)^2 + 2\phi E(Y_{t-1}\varepsilon_t)$$

$$\gamma_0 = \phi^2 V(Y_{t-1}) + \sigma^2 + 0$$

Proceso autorregresivo de orden 1: AR(1)

Dada la estructura de autocorrelación del proceso:

$$E(Y_{t-1}\varepsilon_t) = E[(Y_{t-1} - 0)(\varepsilon_t - 0)] = \text{cov}(Y_{t-1}\varepsilon_t) = 0$$

Bajo el supuesto de que el proceso es estacionario:

$$E(Y_{t-1})^2 = V(Y_{t-1}) = V(Y_t) = \gamma_0$$

Por lo tanto:

$$\gamma_0 = \phi\gamma_0 + \sigma^2 \rightarrow (1 - \phi^2)\gamma_0 = \sigma^2 \rightarrow \gamma_0 = \frac{\sigma^2}{1 - \phi^2}$$

Para que el proceso sea estacionario y la varianza es constante y finita, es necesario que el término ϕ en valores absolutos sea menor que 1 $|\phi| < 1$.

Proceso autorregresivo de orden 1: AR(1)

En lo que se refiere a la función de autocovarianzas, el proceso de AR(1), presenta una estructura como la siguiente:

$$\gamma_k = \begin{cases} \frac{\sigma^2}{1-\phi^2} & k = 0 \\ \phi\gamma_{k-1} & k > 0 \end{cases}$$

Los coeficientes de autocorrelación de un proceso estacionario AR(1) son:

$$\rho_k = \frac{\gamma_k}{\gamma_0} = \frac{\phi\gamma_{k-1}}{\gamma_0} = \phi\rho_{k-1}$$

Proceso autorregresivo de orden 1: AR(1)

La función de autocorrelación de un proceso AR(1) estacionario es:

$$\rho_k = \begin{cases} 1 & k = 0 \\ \phi \rho_{k-1} & k > 0 \end{cases}$$

Se puede demostrar que la función de autocorrelación simple es una función exponencial:

$$\rho_1 = \phi \rho_0 = \phi$$

$$\rho_2 = \phi \rho_1 = \phi^2$$

$$\rho_3 = \phi \rho_2 = \phi^3$$

$$\vdots$$


$$\rho_k = \phi \rho_{k-1} = \phi^k$$

Proceso autorregresivo de orden 1: AR(1)


Dado que para procesos estacionarios el parámetro en valor absoluto es menor que la unidad, la función de autocorrelación decrece exponencialmente con k , es decir, se va aproximando a cero conforme $k \rightarrow \infty$ pero no llega nunca a tomar el valor de 0.

Proceso autorregresivo de orden 1: AR(1)

AR(1) $\phi=0.5$




AR(1) $\phi=0.5$




Proceso autorregresivo de orden 1: AR(1)

AR(1) $\phi=0.5$



AR(1) $\phi=-0.5$



Proceso autorregresivo de orden 2: AR(2)

Un proceso autorregresivo de primer orden, consiste en que el análisis de la variable endógena (dependiente), se explica por si misma a través de dos *shock's* pasados, más un término de residual, tal como se muestra a continuación:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t \quad t = 1, 2, \dots$$

Proceso autorregresivo de orden 2: AR(2)

Para demostrar si el modelo AR(2) es estacionario para cualquier valor del parámetro ϕ es preciso comprobar las condiciones de estacionariedad.

1 Estacionariedad en media:

Se aplica el valor esperado a la regresión AR(2)

$$\begin{aligned}E[Y_t] &= E(c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t) \\E[Y_t] &= c + \phi_1 E[Y_{t-1}] + \phi_2 E[Y_{t-2}] + E[\varepsilon_t]\end{aligned}$$

Proceso autorregresivo de orden 2: AR(2)

Recordando que $E[Y_t] = \mu$

$$\mu = c + \phi_1\mu + \phi_2\mu + 0$$

$$\mu - \phi_1\mu - \phi_2\mu = c$$

$$\mu(1 - \phi_1 - \phi_2) = c$$

$$\mu = \frac{c}{(1 - \phi_1 - \phi_2)}$$

La condición de estacionariedad para AR(2), consiste en que $|\phi| < 1$ y que $\phi_1 + \phi_2 < 1$.

Proceso autorregresivo de orden 2: AR(2)

② Modelo de medias:

Recordando que $E[Y_t] = \mu = \frac{c}{(1-\phi_1-\phi_2)}$, se puede utilizar la condición para realizar o construir el modelo AR(2) en medias, por lo que primero se debe encontrar el valor de c

$$c = \mu (1 - \phi_1 - \phi_2) \quad (\text{C.1})$$

Proceso autorregresivo de orden 2: AR(2)

Al sustituir C.1 en AR(2):

$$Y_t = \mu(1 - \phi_1 - \phi_2) + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t$$

$$Y_t = \mu - \mu\phi_1 - \mu\phi_2 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t$$

$$Y_t - \mu = -\mu\phi_1 - \mu\phi_2 + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t$$

$$Y_t - \mu = \phi_1 (Y_{t-1} - \mu) + \phi_2 (Y_{t-2} - \mu) + \varepsilon_t$$

Se sabe que: $Y_t - \mu = \tilde{Y}_t$

$$\tilde{Y}_t = \phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \varepsilon_t$$

Proceso autorregresivo de orden 2: AR(2)

③ Estacionariedad en covarianza:

Planteando lo siguiente $\gamma_0 = \text{Var}(Y_t) = E \left[\tilde{Y}_t^2 \right]$, se obtiene lo siguiente:

$$\gamma_0 = E \left[\left(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \varepsilon_t \right)^2 \right]$$

$$\gamma_0 = E \left[\phi_1^2 \tilde{Y}_{t-1}^2 + \phi_2^2 \tilde{Y}_{t-2}^2 + \varepsilon_t^2 + 2\phi_1\phi_2 \tilde{Y}_{t-1} \tilde{Y}_{t-2} + 2\phi_1 \tilde{Y}_{t-1} \varepsilon_t + 2\phi_2 \tilde{Y}_{t-2} \varepsilon_t \right]$$

Proceso autorregresivo de orden 2: AR(2)

Dado los siguientes valores esperados $E[\varepsilon_t^2] = \sigma^2$, $E[Y_{t-1}, \varepsilon_t] = 0$ y $E[\tilde{Y}_t^2] = \gamma_0$ la ecuación anterior de γ_0 queda de la siguiente manera:

$$\begin{aligned}\gamma_0 &= \phi_1^2 \gamma_0 + \phi_2^2 \gamma_0 + \sigma^2 + 2\phi_1 \phi_2 \gamma_1 + 0 + 0 \\ (1 - \phi_1^2 - \phi_2^2) \gamma_0 &= \sigma^2 + 2\phi_1 \phi_2 \gamma_1 \\ \gamma_0 &= \frac{\sigma^2 + 2\phi_1 \phi_2 \gamma_1}{1 - \phi_1^2 - \phi_2^2}\end{aligned}$$

Para que el proceso sea estacionario, se debe conocer el valor de γ_1 y mantener la idea de que $|\phi| < 1$ y $\phi_1 + \phi_2 < 1$

Proceso autorregresivo de orden 2: AR(2)

Para completar la función de autocovarianza de AR(2), se procede a calcular γ_1 :

$$\gamma_1 = E[(Y_t - \mu)(Y_{t-1} - \mu)] = E[\tilde{Y}_t \tilde{Y}_{t-1}]$$

$$\gamma_1 = E\left[\left(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \varepsilon_t\right) \tilde{Y}_{t-1}\right]$$

$$\gamma_1 = E\left[\phi_1 \tilde{Y}_{t-1}^2 + \phi_2 \tilde{Y}_{t-1} \tilde{Y}_{t-2} + \varepsilon_t \tilde{Y}_{t-1}\right]$$

Proceso autorregresivo de orden 2: AR(2)

Recordando los valores esperados: $E[\tilde{Y}_t^2] = \gamma_0$, $E[\tilde{Y}_t, \tilde{Y}_{t-1}] = \gamma_1$ y $E[\tilde{Y}_{t-1}\varepsilon_t] = 0$ la ecuación anterior tiene el siguiente resultado:

$$\gamma_1 = \phi_1\gamma_0 + \phi_2\gamma_1$$

$$\gamma_1 - \phi_2\gamma_1 = \phi_1\gamma_0$$

$$\gamma_1(1 - \phi_2) = \phi_1\gamma_0$$

$$\gamma_1 = \frac{\phi_1\gamma_0}{1 - \phi_2}$$

$$\gamma_1 = \frac{\phi_1}{1 - \phi_2}\gamma_0$$

Proceso autorregresivo de orden 2: AR(2)

Reemplazando γ_1 en γ_0 del proceso AR(2) en covarianzas, se tiene lo siguiente:

$$\gamma_0 = \phi_1^2 \gamma_0 + \phi_2 \gamma_0 + \sigma^2 + 2\phi_1 \phi_2 \left(\frac{\phi_1}{1 - \phi_2} \right) \gamma_0$$

$$\gamma_0 - \phi_1^2 \gamma_0 - \phi_2 \gamma_0 - 2\phi_1 \phi_2 \left(\frac{\phi_1}{1 - \phi_2} \right) \gamma_0 = \sigma^2$$

$$\gamma_0 \left(1 - \phi_1^2 - \phi_2 - 2\phi_1 \phi_2 \left(\frac{\phi_1}{1 - \phi_2} \right) \right) = \sigma^2$$

$$\gamma_0 = \frac{\sigma^2}{\left(1 - \phi_1^2 - \phi_2 - 2\phi_1 \phi_2 \left(\frac{\phi_1}{1 - \phi_2} \right) \right)}$$

$$\gamma_0 = \frac{(1 - \phi_2) \sigma^2}{(1 + \phi_2) \left[(1 - \phi_2)^2 - \phi_1^2 \right]}$$

Proceso autorregresivo de orden 2: AR(2)

Con lo anterior se afirma que para que el proceso AR(2) sea estacionario, los valores de las pendientes deben ser: $\phi < 1$ y $\phi_1 + \phi_2 < 1$.

4 Autocovarianzas

Las autocovarianzas γ_k , cuando $k > 1$ son:

$$\begin{aligned}\gamma_k &= E \left[\tilde{Y}_t \tilde{Y}_{t-k} \right] \\ \gamma_k &= E \left[\left(\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \varepsilon_t \right) \tilde{Y}_{t-k} \right] \\ \gamma_k &= E \left[\phi_1 \tilde{Y}_{t-1} \tilde{Y}_{t-k} + \phi_2 \tilde{Y}_{t-2} \tilde{Y}_{t-k} + \varepsilon_t \tilde{Y}_{t-k} \right] \\ \gamma_k &= \phi_1 E \left(\tilde{Y}_{t-1} \tilde{Y}_{t-k} \right) + \phi_2 E \left(\tilde{Y}_{t-2} \tilde{Y}_{t-k} \right) + E \left(\varepsilon_t \tilde{Y}_{t-k} \right)\end{aligned}$$

Proceso autorregresivo de orden 2: AR(2)

Recordando los valores esperados $E[\tilde{Y}_t \tilde{Y}_{t-1}] = \gamma_1$ y $E[\tilde{Y}_{t-1} \varepsilon_t] = 0$. La ecuación anterior queda de la siguiente forma:

$$\gamma_k = \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}$$

Por lo tanto la función de autocovarianzas de un modelo AR(2) es la siguiente:

$$\gamma_k = \begin{cases} \gamma_0 & k = 0 \\ \gamma_1 & k = 1 \\ \phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2} & k > 1 \end{cases}$$

Proceso autorregresivo de orden 2: AR(2)

5 Coeficientes de autocorrelación

Con base en las autocovarianzas, la función de autocorrelación es:


$$\begin{aligned}\rho_k &= \frac{\gamma_k}{\gamma_0} \\ \rho_k &= \frac{\phi_1 \gamma_{k-1} + \phi_2 \gamma_{k-2}}{\gamma_0} \\ \rho_k &= \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2}\end{aligned}$$

La función de autocorrelación de un modelo AR(2) es:


$$\rho_k = \begin{cases} 1 & k = 0 \\ \phi_1 \rho_{k-1} + \phi_2 \rho_{k-2} & k > 0 \end{cases}$$

Proceso autorregresivo de orden 2: AR(2)

AR(2) $\phi_1=0.5$ $\phi_2=0.2$




AR(2) $\phi_1=0.5$ $\phi_2=0.2$




Proceso autorregresivo de orden 2: AR(2)

AR(2) $\phi_1=-0.5\phi_2=-0.2$



AR(2) $\phi_1=-0.5\phi_2=-0.2$



Proceso autorregresivo de orden p: AR(p)

Una vez conociendo AR(1) y AR(2) se pueden generalizar los casos para AR(p):

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t \quad (\text{AR}(p))$$

Proceso autorregresivo de orden p: AR(p)

1 Estacionariedad en media:

$$E[Y_t] = c + \phi_1 E[Y_{t-1}] + \phi_2 E[Y_{t-2}] + \cdots + \phi_p E[Y_{t-p}] + E[\varepsilon_t]$$

$$\mu = c + \phi_1 \mu + \phi_2 \mu + \cdots + \phi_p \mu + 0$$

$$\mu - \phi_1 \mu - \phi_2 \mu - \cdots - \phi_p \mu = c$$

$$\mu(1 - \phi_1 - \phi_2 - \cdots - \phi_p) = c$$

$$\mu = \frac{c}{1 - \phi_1 - \phi_2 - \cdots - \phi_p}$$

Las condiciones para que el proceso de AR(p) sea estacionario son: $\phi < 1$ y $\phi_1 + \phi_2 + \cdots + \phi_p < 1$ ó $\sum \phi < 1$

Proceso autorregresivo de orden p: AR(p)

2 Modelo en medias:

Primero, se debe encontrar el valor de c:

$$\begin{aligned}\mu &= \frac{c}{1 - \phi_1 - \phi_2 - \cdots - \phi_p} \\ \mu(1 - \phi_1 - \phi_2 - \cdots - \phi_p) &= c \\ c &= \mu(1 - \phi_1 - \phi_2 - \cdots - \phi_p)\end{aligned}$$

Proceso autorregresivo de orden p: AR(p)

Se sustituye el valor de c en AR(p):

$$Y_t = \mu(1 - \phi_1 - \phi_2 - \cdots - \phi_p) + \phi_1 Y_{t-1} + \phi_2 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

$$Y_t = \mu - \mu\phi_1 - \mu\phi_2 - \cdots - \mu\phi_p + \phi_1 Y_{t-1} + \phi_2 Y_{t-1} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

$$Y_t - \mu = \phi_1 (Y_{t-1} - \mu) + \phi_2 (Y_{t-2} - \mu) + \cdots + \phi_p (Y_{t-p} - \mu) + \varepsilon_t$$

$$\tilde{Y}_t = \phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \cdots + \phi_p \tilde{Y}_{t-p} + \varepsilon_t$$

Proceso autorregresivo de orden p: AR(p)

3 Estacionariedad en varianza:

Se toma multiplica $\tilde{Y}_t$ por el modelo AR(p) en medias:

$$\tilde{Y}_t \tilde{Y}_t = (\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \cdots + \tilde{Y}_{t-p} + \varepsilon_t) * \tilde{Y}_t$$

$$\tilde{Y}_t \tilde{Y}_t = \phi_1 \tilde{Y}_{t-1} \tilde{Y}_t + \phi_2 \tilde{Y}_{t-2} \tilde{Y}_t + \cdots + \tilde{Y}_{t-p} \tilde{Y}_t + \varepsilon_t \tilde{Y}_t$$

$$E[\tilde{Y}_t^2] = \phi_1 E[\tilde{Y}_{t-1} \tilde{Y}_t] + \phi_2 E[\tilde{Y}_{t-2} \tilde{Y}_t] + \cdots + \phi_p E[\tilde{Y}_{t-p} \tilde{Y}_t] + E[\varepsilon_t \tilde{Y}_t]$$

Proceso autorregresivo de orden p: AR(p)

Hay que recordar: $E[\tilde{Y}_t \tilde{Y}_t] = \gamma_0$, $E[\tilde{Y}_t \tilde{Y}_{t-1}] = \gamma_1$, $E[\tilde{Y}_t \tilde{Y}_{t-2}] = \gamma_2$,
 $E[\tilde{Y}_t \tilde{Y}_{t-p}] = \gamma_p$ y $E[\varepsilon_t \tilde{Y}_t] = \sigma^2$ por lo tanto la ecuación anterior queda:

$$\gamma_0 = \phi_1 \gamma_1 + \phi_2 \gamma_2 + \cdots + \phi_p \gamma_k + \sigma^2$$

Proceso autorregresivo de orden p: AR(p)

4 Autocovarianzas

Se multiplica el modelo AR(p) por $\tilde{Y}_{t-p}$ y se aplica el valor esperado:

$$\tilde{Y}_t \tilde{Y}_{t-p} = (\phi_1 \tilde{Y}_{t-1} + \phi_2 \tilde{Y}_{t-2} + \cdots + \tilde{Y}_{t-p} + \varepsilon_t) * \tilde{Y}_{t-p}$$

$$\tilde{Y}_t \tilde{Y}_{t-p} = \phi_1 \tilde{Y}_{t-1} \tilde{Y}_{t-p} + \phi_2 \tilde{Y}_{t-2} \tilde{Y}_{t-p} + \cdots + \tilde{Y}_{t-p} \tilde{Y}_{t-p} + \varepsilon_t \tilde{Y}_{t-p}$$

$$E[\tilde{Y}_t \tilde{Y}_{t-p}] = \phi_1 E[\tilde{Y}_{t-1} \tilde{Y}_{t-p}] + \phi_2 E[\tilde{Y}_{t-2} \tilde{Y}_{t-p}] + \cdots + \phi_p E[\tilde{Y}_{t-p} \tilde{Y}_{t-p}] \\ + E[\varepsilon_t \tilde{Y}_{t-p}]$$

Proceso autorregresivo de orden p: AR(p)

Hay que recordar: $E[\tilde{Y}_t \tilde{Y}_t] = \gamma_0$, $E[\tilde{Y}_{t-1} \tilde{Y}_{t-p}] = \gamma_{p-1}$, $E[\tilde{Y}_t \tilde{Y}_{t-p}] = \gamma_p$ y $E[\varepsilon_t \tilde{Y}_{t-1}] = 0$ por lo tanto la ecuación anterior queda:

$$\gamma_p = \phi_1 \gamma_{p-1} + \phi_2 \gamma_{p-2} + \cdots + \phi_p \gamma_0$$

Proceso autorregresivo de orden p: AR(p)

5 Autocorrelación

Hay que recordar que $\rho_k = \frac{\gamma_k}{\gamma_0}$, por lo tanto la realización la operación para γ_p , el resultado es el siguiente:

$$\rho_p = \phi_1 \rho_{p-1} + \phi_2 \rho_{p-2} + \cdots + \phi_p$$

Estacionariedad del proceso AR

- Relacionado con la estabilidad de las ecuaciones en diferencias.
- Para estudiar la estacionariedad del proceso AR se utilizarán los operadores de rezagos “L”.

Operador de rezagos.

Es aquel operador matemático que indica el grado de rezagos que se aplicarán a una variable sujeta en el tiempo. Por lo regular se utiliza el operador L , ejemplo:

$$Lc = c$$

$$LY_t = Y_{t-1}$$

$$L^2 Y_t = L(LY_t) = LY_{t-1} = Y_{t-2}$$

$$L^j Y_t = Y_{t-j}$$

Estacionariedad del proceso AR

El proceso AR(p) utilizando operador de rezagos es:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} + \varepsilon_t$$

$$Y_t = c + \phi_1 L Y_t + \phi_2 L^2 Y_t + \cdots + \phi_p L^p Y_t + \varepsilon_t$$

$$Y_t - \phi_1 L Y_t - \phi_2 L^2 Y_t - \cdots - \phi_p L^p Y_t = c + \varepsilon_t$$


$$\left(1 - \phi_1 L - \phi_2 L^2 - \cdots - \phi_p L^p\right) Y_t = c + \varepsilon_t$$

$$\Phi(L) Y_t = c + \varepsilon_t$$

- $\Phi(L)$ expresión polinómica de grado p .
- El grado del polinomio indica cuantos rezagos serán incluidos.

Estacionariedad del proceso AR

- $\Phi(L)$ es un polinomio de grado p . Para que el $AR(p)$ sea estacionario. Las raíces del polinomio (solución igual a 0: $\Phi(L) = 0$) deben caer por fuera del círculo unitario (valor absoluto > 1).
- Las raíces de un polinomio pueden ser reales o complejas, en caso de raíces complejas, éstas deben ser conjugadas de la forma: $a \pm i$.



Ejemplo de estacionariedad AR(1)

$$Y_t = c + \phi Y_{t-1} + \varepsilon_t$$

$$Y_t = c + \phi L Y_t + \varepsilon_t$$

$$Y_t - \phi L Y_t = c + \varepsilon_t$$

$$(1 - \phi L) Y_t = c + \varepsilon_t$$

$$\Phi(L) = 1 - \phi L$$

La solución de $\Phi(L) = 1 - \phi L$ es $L = \frac{1}{\phi}$. Si $|\phi| < 1$ entonces $|L| > 1$. Equivalente a decir que existe estabilidad en la ecuación en diferencias y se habla de un proceso estacionario.

Ejemplo de estacionariedad AR(2)

En el caso de AR(2), se plantea un polinomio de la siguiente manera:

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \varepsilon_t$$

$$Y_t = c + \phi_1 L Y_t + \phi_2 L^2 Y_t + \varepsilon_t$$

$$Y_t - \phi_1 L Y_t - \phi_2 L^2 Y_t = c + \varepsilon_t$$

$$(1 - \phi_1 L Y_t - \phi_2 L^2) Y_t = c + \varepsilon_t$$

$$\Phi(L) = (1 - \phi_1 L Y_t - \phi_2 L^2)$$

Ejemplo de estacionariedad AR(2)

La solución de $\Phi(L) = (1 - \phi_1 L - \phi_2 L^2)$ se plantea mediante una ecuación general de segundo grado:

$$L_{1,2} = \frac{-\phi_1 \pm \sqrt{\phi_1^2 + 4\phi_2}}{2\phi_2}$$

Si $\phi_1 + \phi_2 = 1$, una de las raíces es igual a 1 y por lo tanto $|L| > 1$ y caerán dentro del círculo unitario provocando la no estacionariedad, entonces se busca por lo general que $\phi_1 + \phi_2 < 1$.

Modelo de medias móviles de orden q MA(q)

En este modelo, una determinada observación está condicionada por los impulsos aleatorios de las observaciones anteriores. De esta forma la observación actual se define como la suma del impulso actual y de los impulsos aleatorios anteriores con un determinado peso:

$$Y_t = c + e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2} + \cdots + \theta_q e_{t-q}$$

- Cada shock e_t es independiente entre sí y siguen un proceso de ruido blanco $idd \sim (0, \sigma^2)$.
- La cantidad de rezagos de los shocks determinan el orden q del proceso.
- Se comprobará que Y_t fluctúa al rededor de su media μ .
- La conexión con el pasado depende del orden q .

Modelo de medias móviles de orden 1: MA(1)

Es un modelo en el que se indica que la variable presente dependiente, se explica a través de un primer shock de los movimientos aleatorios de la serie, dando como resultado el siguiente modelo:

$$Y_t = \mu + e_t + \theta_1 e_{t-1}$$

- Donde: $e_t \sim w.n(0, \sigma^2)$

Modelo de medias móviles de orden 1: MA(1)

1 Estacionariedad en media:

$$Y_t = \mu + e_t + \theta_1 e_{t-1}$$
$$E[Y_t] = \mu + E[e_t] + \theta_1 E[e_{t-1}]$$

Considerando que: $E[e_t] = 0$ y $E[e_{t-1}] = 0$

$$Y_t = \mu \quad \forall t$$

Modelo de medias móviles de orden 1: MA(1)

2 **Varianza:** $\gamma_0 = \text{Var}(Y_t) = E[(Y_t - \mu)^2]$

$$\begin{aligned}\gamma_0 &= E[(e_t + \theta_1 e_{t-1})^2] \\ \gamma_0 &= E[e_t^2 + \theta_1^2 e_{t-1}^2 + 2\theta_1 e_t e_{t-1}]\end{aligned}$$

• Donde: $E[e_t^2] = \sigma^2$, $E[e_{t-1}^2] = \sigma^2$ y $E[e_t e_{t-1}] = 0$

$$\begin{aligned}\gamma_0 &= \sigma^2 + \theta_1^2 \sigma^2 + 2\theta_1 [0] \\ \gamma_0 &= \sigma^2 + \theta_1^2 \sigma^2 \\ \gamma_0 &= \sigma^2 (1 + \theta_1^2)\end{aligned}$$

Modelo de medias móviles de orden 1: MA(1)

③ **Autocovarianzas:** $\gamma_1 = \text{Cov}(Y_t Y_{t-1}) = E[(Y_t - \mu)(Y_{t-1} - \mu)]$

$$\begin{aligned}\gamma_1 &= E[(e_t + \theta_1 e_{t-1})(e_{t-1} + \theta_1 e_{t-2})] \\ \gamma_1 &= E[e_t e_{t-1} + \theta_1 e_{t-1}^2 + \theta_1 e_t e_{t-2} + \theta_1^2 e_{t-1} e_{t-2}]\end{aligned}$$

• Donde: $E[e_t e_{t-1}] = 0$ y $E[e_t^2] = \sigma^2$

$$\begin{aligned}\gamma_1 &= E[e_t e_{t-1}] + \theta_1 E[e_{t-1}^2] + \theta_1 E[e_t e_{t-2}] + \theta_1^2 E[e_{t-1} e_{t-2}] \\ \gamma_1 &= \theta_1 \sigma^2\end{aligned}$$

Modelo de medias móviles de orden 1: MA(1)

③ Autocovarianzas: $\gamma_2 = \text{Cov}(Y_t Y_{t-2}) = E[(Y_t - \mu)(Y_{t-2} - \mu)]$

$$\begin{aligned}\gamma_2 &= E[(e_t + \theta_1 e_{t-1})(e_{t-2} + \theta_1 e_{t-3})] \\ \gamma_2 &= E[e_t e_{t-2} + \theta_1 e_{t-1} e_{t-2} + \theta_1 e_t e_{t-3} + \theta_1^2 e_{t-1} e_{t-3}]\end{aligned}$$

• Donde: $E[e_t e_{t-1}] = 0$.

$$\begin{aligned}\gamma_2 &= E[e_t e_{t-2}] + \theta_1 E[e_{t-1} e_{t-2}] + \theta_1 E[e_t e_{t-3}] + \theta_1^2 E[e_{t-1} e_{t-3}] \\ \gamma_2 &= 0\end{aligned}$$

Modelo de medias móviles de orden 1: MA(1)

Se puede generalizar que la autocovarianza de orden 2 o superior para el proceso de MA(1) de la siguiente manera:

$$\begin{aligned}\gamma_j &= \text{Cov}(Y_t, Y_{t-j}) \\ \gamma_j &= E[(Y_t - \mu)(Y_{t-j} - \mu)] = 0 \quad \forall j \geq 2\end{aligned}$$


4 Autocorrelación

- A partir de las funciones de autocovarianzas calculadas anteriormente se puede obtener las autocorrelaciones para MA(1). Considerando lo siguiente: $\rho_k = \frac{\gamma_k}{\gamma_0}$:


$$\begin{aligned}\rho_0 &= \frac{\gamma_0}{\gamma_0} = 1 \\ \rho_1 &= \frac{\gamma_1}{\gamma_0} = \frac{\theta_1 \sigma^2}{(1 + \theta_1^2) \sigma^2} = \frac{\theta_1}{(1 + \theta_1^2)} \\ \rho_2 &= \frac{\gamma_2}{\gamma_0} = \frac{0}{(1 + \theta_1^2) \sigma^2} = 0 \\ \rho_k &= 0 \quad \forall_j \geq 2\end{aligned}$$

Modelo de medias móviles de orden 1: MA(1)

MA(1) $\theta_1=0.5$




MA(1) $\theta_1=0.5$




Modelo de medias móviles de orden 1: MA(1)

MA(1) $\theta_1=-0.5$



MA(1) $\theta_1=-0.5$



Modelo de medias móviles de orden 2: MA(2)

Es un modelo en el que se indica que la variable presente dependiente, se explica a través de dos shock's de los movimientos aleatorios de la serie, dando como resultado el siguiente modelo:

$$Y_t = \mu + e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2}$$

- Donde: $e_t \sim w.n(0, \sigma^2)$

Modelo de medias móviles de orden 2: MA(2)

❶ Estacionariedad en media:

$$Y_t = \mu + e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2}$$
$$E[Y_t] = \mu + E[e_t] + \theta_1 E[e_{t-1}] + \theta_2 E[e_{t-2}]$$

- Considerando que: $E[e_t] = 0$

$$E[Y_t] = 0$$

Modelo de medias móviles de orden 2: MA(2)

2 **Varianza:** $\gamma_0 = \text{Var}(Y_t) = E[(Y_t - \mu)^2]$

$$\gamma_0 = E[(e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2})^2]$$

$$\gamma_0 = E[e_t^2 + \theta_1^2 e_{t-1}^2 + \theta_2^2 e_{t-2}^2 + 2\theta_1 e_t e_{t-1} + 2\theta_2 e_t e_{t-2} + 2\theta_1 \theta_2 e_{t-1} e_{t-2}]$$

• Hay que recordar que $E[e_t^2] = \sigma^2$ y $E[e_t e_{t-1}] = 0$

$$\gamma_0 = E[e_t^2] + \theta_1^2 E[e_{t-1}^2] + \theta_2^2 E[e_{t-2}^2] + 2\theta_1 E[e_t e_{t-1}]$$

$$+ 2\theta_2 E[e_t e_{t-2}] + 2\theta_1 \theta_2 E[e_{t-1} e_{t-2}]$$

$$\gamma_0 = \sigma^2 + \theta_1^2 \sigma^2 + \theta_2^2 \sigma^2 + 0 + 0 + 0$$

$$\gamma_0 = \sigma^2 + \theta_1^2 \sigma^2 + \theta_2^2 \sigma^2$$

$$\gamma_0 = \sigma^2 (1 + \theta_1^2 + \theta_2^2)$$

3 Autocovarianzas:

Para el caso de γ_1 se plantea: $\text{Cov}(Y_t, Y_{t-1}) = E[(Y_t - \mu)(Y_{t-1} - \mu)]$:

$$\begin{aligned}\gamma_1 &= E[(e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2})(e_{t-1} + \theta_1 e_{t-2} + \theta_2 e_{t-3})] \\ \gamma_1 &= E[\theta_1 e_{t-1}^2 + \theta_1 \theta_2 e_{t-2}^2 + e_t e_{t-1} + \theta_1 e_t e_{t-2} + \theta_2 e_t e_{t-3} \\ &\quad + \theta_1^2 e_{t-1} e_{t-2} + \theta_1 \theta_2 e_{t-1} e_{t-3} + \theta_2 e_{t-1} e_{t-2} + \theta_2^2 e_{t-2} e_{t-3}]\end{aligned}$$

Modelo de medias móviles de orden 2: MA(2)

- Recordando que $E[e_t^2] = \sigma^2$ y $E[e_t e_{t-1}] = 0$, γ_1 toma los siguientes valores:

$$\gamma_1 = \theta_1 \sigma^2 + \theta_1 \theta_2 \sigma^2$$

$$\gamma_1 = \sigma^2 (\theta_1 + \theta_1 \theta_2)$$

Modelo de medias móviles de orden 2: MA(2)

3 Autocovarianzas

Para el caso de γ_2 se plantea: $Cov(Y_t, Y_{t-2}) = E[(Y_t - \mu)(Y_{t-2} - \mu)]$:

$$\gamma_2 = E[(e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2})(e_{t-2} + \theta_1 e_{t-3} + \theta_2 e_{t-4})]$$

$$\begin{aligned}\gamma_2 = E[& e_t e_{t-2} + \theta_1 e_t e_{t-3} + \theta_2 e_t e_{t-4} + \theta_1 e_{t-1} e_{t-2} + \theta_1^2 e_{t-1} e_{t-2} \\ & + \theta_1 \theta_2 e_{t-1} e_{t-4} + \theta_2 e_{t-2}^2 + \theta_1 \theta_2 e_{t-2} e_{t-3} + \theta_2^2 e_{t-2} e_{t-4}]\end{aligned}$$

- Solo hay un término cuadrático e_{t-2}^2 , por lo tanto: $E[e_t^2] = \sigma^2$.

$$\gamma_2 = \theta_2 \sigma^2$$

Modelo de medias móviles de orden 2: MA(2)

- **3 Autocovarianzas:** Para el caso de γ_3 se plantea $Cov(Y_t, Y_{t-3})$.

$$\gamma_3 = E[(e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2})(e_{t-3} + \theta_1 e_{t-4} + \theta_2 e_{t-5})]$$

Se aprecia que en la expresión anterior, habrá puros productos cruzados, por lo tanto al aplicar el valor esperado tendremos combinaciones del tipo $E[e_t e_{t-1}] = 0$. Entonces la ecuación anterior tiene el siguiente resultado:

$$\gamma_3 = 0$$

En general, para cualquier rezago mayor o igual que 3, se tiene:

$$\gamma_j = Cov(Y_t, Y_{t-j}) = E[(Y_t - \mu)(Y_{t-j} - \mu)] = 0$$
$$\forall j \geq 3$$

4 Autorrelaciones:

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1$$


$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{\sigma^2 (\theta_1 + \theta_1 \theta_2)}{\sigma^2 (1 + \theta_1^2 + \theta_2^2)} = \frac{\theta_1 + \theta_1 \theta_2}{1 + \theta_1^2 + \theta_2^2}$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \frac{\sigma^2 \theta_2^2}{\sigma^2 (1 + \theta_1^2 + \theta_2^2)} = \frac{\theta_2^2}{1 + \theta_1^2 + \theta_2^2}$$


$$\rho_3 = \frac{\gamma_3}{\gamma_0} = 0 \quad \forall_j \geq 3$$

Modelo de medias móviles de orden 2: MA(2)

MA(2) $\theta_1=0.5\theta_2=0.2$




MA(2) $\theta_1=0.5\theta_2=0.2$




Modelo de medias móviles de orden 2: MA(2)

$$\text{MA}(2)\theta_1=-0.5\theta_2=-0.2$$



$$\text{MA}(2)\theta_1=-0.5\theta_2=-0.2$$



Modelo de medias móviles de orden q: MA(q)

- Podemos continuar realizando demostraciones de MA(3), MA(4), etc. Pero nos daremos cuenta que dentro de las covarianzas y autocorrelaciones, simplemente van a ir aumentando la memoria en un rezago, es decir, si se analiza MA(3), la función de autocovarianza será cero cuando $k > 3$ y así sucesivamente para cada orden.
- Es por ello que se puede generalizar el caso de MA(q):

$$Y_t = \mu + e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2} + \cdots + \theta_q e_{t-q}$$

Modelo de medias móviles de orden q: MA(q)

1 Condición de media

$$E(Y_t) = \mu$$

2 Condición de varianza

$$\text{Var}(Y_t) = (1 + \theta_1^2 + \theta_2^2 + \dots + \theta_q^2) \sigma^2$$

$$\text{Var}(Y_t) = \left(1 + \sum_{i=1}^q \theta_i^2\right) \sigma^2$$

3 Autocovarianzas

$$\gamma_1 = (\theta_1 + \theta_1\theta_2 + \theta_2\theta_3 + \cdots + \theta_{q-1}\theta_q) \sigma^2$$

$$\gamma_2 = (\theta_2 + \theta_1\theta_3 + \theta_2\theta_4 + \cdots + \theta_{q-2}\theta_q) \sigma^2$$

$$\gamma_s = (\theta_s + \theta_1\theta_{1+s} + \theta_2\theta_{2+s} + \cdots + \theta_{q-s}\theta_q) \sigma^2 \quad \text{si } s < q$$

$$\gamma_s = \theta_s \sigma^2 \quad \text{si } s = q$$

$$\gamma_s = 0 \quad \text{si } s > q$$

Modelo de medias móviles de orden q : $MA(q)$

4 Funciones de autocorrelación

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1$$

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \frac{(\theta_1 + \theta_1\theta_2 + \theta_2\theta_3 + \cdots + \theta_{q-1}\theta_q)}{(1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2)}$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \frac{(\theta_2 + \theta_1\theta_3 + \theta_2\theta_4 + \cdots + \theta_{q-2}\theta_q)}{(1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2)}$$

$$\rho_s = \frac{\gamma_s}{\gamma_0} = \frac{(\theta_s + \theta_1\theta_{1+s} + \theta_2\theta_{2+s} + \cdots + \theta_{q-s}\theta_q)}{(1 + \theta_1^2 + \theta_2^2 + \cdots + \theta_q^2)} \text{ si } s < q$$

$$\rho_s = 0 \text{ si } s = q$$

$$\rho_s = 0 \text{ si } s \geq q$$

Estacionariedad de MA(q)

- La propiedad de estacionariedad se cumple dependiendo de los valores de los parámetros.
- En este caso, los parámetros de MA(q), se requieren que la suma del valor absoluto de los θ sea menor que infinito (∞):

$$\sum_{j=0}^{\infty} |\theta_j| < \infty$$

- Es lo mismo que:

$$\sum_{j=0}^q |\theta_j| < \infty \rightarrow \text{Estacionario}$$

Invertibilidad de los proceso AR y MA

- Aunque los proceso AR y MA tienen propiedades distintas, pueden ser considerados (hasta cierto punto) como modelos *equivalentes* ó *similares*.
- Por ejemplo, cuando se reviso la función de autocorrelación del un proceso MA(q), esta se extendía hasta el rezago q , cayendo exponencialmente hacía cero para valores mayores que q .
- Pero si $q \rightarrow \infty$, el correlograma del MA(∞) se extiende infinitamente y puede ser considerado como equivalente al proceso AR(p).

Invertibilidad de los proceso AR y MA

Teorema de Wold: Cualquier proceso débilmente estacionario puede ser expresado como un proceso MA.

- Un proceso $AR(p)$ es invertible si puede ser expresado como un proceso $MA(\infty)$ estacionario.
- Ejemplo: El proceso $AR(1)$ puede ser representado como un $MA(\infty)$ mediante reemplazos sucesivos:

$$Y_t = c + \phi_1 Y_{t-1} + e_t \quad (1)$$

Rezagando:

$$Y_{t-1} = c + \phi_1 Y_{t-2} + e_{t-1} \quad (1.a)$$

Invertibilidad de los proceso AR y MA

Reemplazando (1.a) es (1):

$$\begin{aligned} Y_t &= c + \phi_1 (c + \phi_1 Y_{t-2} + e_{t-1}) \\ Y_t &= c + \phi_1 c + \phi_1^2 Y_{t-2} + \phi_1 e_{t-1} + e_t \end{aligned} \tag{2}$$

Rezagando nuevamente y reemplazando:

$$Y_t = c + \phi_1 c + \phi_1^2 c + \phi_1^3 Y_{t-3} + e_t + \phi_1 e_{t-1} + \phi_1^2 e_{t-2}$$

Invertibilidad de los proceso AR y MA

Repitiendo esto al infinito:

$$Y_t = c \left(1 + \phi_1 + \phi_1^2 + \cdots \right) + \phi_1^\infty Y_{t-\infty} + e_t + \phi_1 e_{t-1} + \phi_1^2 e_{t-2}$$

$$Y_t = \frac{c}{1 - \phi_1} + e_t + \phi_1 e_{t-1} + \phi_1^2 e_{t-2} + \cdots$$

$$Y_t = \frac{c}{1 - \phi} + \sum_{j=0}^{\infty} |\phi^j| e_{t-j}$$

Esto es un $MA(\infty)$ estacionario donde $\mu = \frac{c}{1-\phi}$ y se cumple que $\sum_{j=0}^{\infty} |\phi^j| < \infty$.

Invertibilidad de los proceso AR y MA

-Hay que notar que el proceso $MA(\infty)$ es estacionario ya que la suma de los ϕ es menor que infinito.

- Otros procesos como $AR(2)$ también pueden invertirse siempre y cuando sean estacionarios.
- En general, un proceso AR es invertible si y solo si es estacionario.

Invertibilidad de los proceso AR y MA

- En el caso de los proceso MA, también pueden ser invertidos en procesos AR(∞) estacionarios.

$$Y_t = \mu + e_t + \theta_1 e_{t-1} + \cdots + \theta_q e_{t-q}$$

Aplicando el operador de rezagos:

$$Y_t = \mu + (1 + \theta_1 L + \cdots + \theta_q L^q) e_t$$
$$Y_t = \mu + \Theta(L) e_t$$

- Si las raíces de $\Theta(L) = 0$ caen fuera del círculo unitario, entonces se puede invertir el proceso MA(q).

Invertibilidad de los proceso AR y MA

$$\left(\frac{1}{\Theta(L)}\right) Y_t = \left(\frac{1}{\Theta(L)}\right) \mu + e_t$$

Por ejemplo, en un MA(1): $Y_t = \mu + e_t + \theta_1 e_{t-1}$:

$$\begin{aligned}\left(\frac{1}{1 + \theta L}\right) Y_t &= \left(\frac{1}{1 + \theta L}\right) \mu + e_t \\ \left(1 - \theta_1 L + \theta_1^2 L^2 - \theta_1^3 L^3 + \dots\right) Y_t &= \frac{\mu}{1 + \theta_1} + e_t \\ Y_t - \theta_1 Y_{t-1} + \theta_1^2 Y_{t-2} - \theta_1^3 Y_{t-3} + \dots &= \frac{\mu}{1 + \theta_1} + e_t\end{aligned}$$

Lo anterior es un AR(∞).

Invertibilidad de los proceso AR y MA

- La raíz de $1 + \phi_1 L = 0$ es $L = \frac{-1}{\theta}$. Para que sea invertible en algo estacionario, se necesita que $|\theta| < 1$.
- Si el MA es invertible, el MA es estacionario, pero si el MA es estacionario no necesariamente es invertible.

Modelo autorregresivo de medias móviles de orden p, q : ARMA(p, q)

Este modelo es la combinación de las estructuras anteriores: Modelos Autorregresivo y modelo de medias móviles. Así, una observación está determinada tanto por observaciones anteriores así como por impulsos aleatorios o también llamados shocks pasados.

$$Y_t = c + \phi_1 Y_{t-1} + \phi_2 Y_{t-2} + \cdots + \phi_p Y_{t-p} \\ + e_t + \theta_1 e_{t-1} + \theta_2 e_{t-2} + \cdots + \theta_q e_{t-q}$$

$$\Phi(L) Y_t = c + \Theta(L) e_t$$

Existirá estacionariedad si: $\sum_{j=0}^{\infty} |\theta_j| < \infty$ y si la parte de AR es estacionaria $\Phi(L) \neq 0$.

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

Partiendo de:

$$Y_t = c + \phi_1 Y_{t-1} + e_t + \theta_1 e_{t-1}$$

❶ Condición de media

Se aplica el operador E al modelo ARMA(1,1)

$$E[Y_t] = c + \phi_1 E[Y_{t-1}] + E[e_t] + \theta_1 E[e_{t-1}]$$

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

Recordando que: $E[Y_t] = \mu$ y $E[e_t] = 0$

$$\mu = c + \phi_1 \mu$$

$$\mu - \phi_1 \mu = c$$

$$\mu(1 - \phi_1) = c$$

$$\mu = \frac{c}{(1 - \phi_1)}$$

μ es igual que en el proceso AR(1).

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

2 Modelo en desviaciones

$$Y_t - \mu = \phi_1 (Y_{t-1} - \mu) + e_t + \theta_1 e_{t-1}$$

$$\tilde{Y}_t = \phi_1 \tilde{Y}_{t-1} + e_t + \theta_1 e_{t-1}$$

Con el modelo en medias, se realizarán las comprobaciones para la varianza, autocovarianza y las correlaciones el proceso ARMA(1,1)

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

③ **Varianza.**- La varianza se plantea de la siguiente manera: $\gamma_0 = E[(Y_t - \mu)^2]$ ó $\gamma_0 = E[\tilde{Y}_t^2]$.

$$\begin{aligned}\gamma_0 &= E\left[\left(\phi_1 \tilde{Y}_{t-1} + e_t + \theta_1 e_{t-1}\right)^2\right] \\ \gamma_0 &= E[\phi_1^2 \tilde{Y}_{t-1}^2 + e_t^2 + \theta_1^2 e_{t-1}^2 + 2\phi_1 \theta_1 \tilde{Y}_{t-1} e_{t-1} \\ &\quad + 2\phi_1 \tilde{Y}_{t-1} e_t + 2\theta_1 e_t e_{t-1}]\end{aligned}$$

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

Recordando que: $E[\tilde{Y}_t^2] = \sigma_2$, $E[e_t^2] = \sigma^2$, $E[\tilde{Y}_t e_t] = \sigma^2$ y $E[Y_{t-1} e_t] = 0$.

$$\gamma_0 = \phi_1^2 \gamma_0 + \sigma^2 + \theta_1^2 \sigma^2 + 2\phi_1 \theta_1 \sigma^2$$

$$\gamma_0 - \phi_1^2 \gamma_0 = \sigma^2 (1 + \theta_1^2 + 2\phi_1 \theta_1)$$

$$\gamma_0 (1 - \phi_1^2) = \sigma^2 (1 + \theta_1^2 + 2\phi_1 \theta_1)$$

$$\gamma_0 = \frac{\sigma^2 (1 + \theta_1^2 + 2\phi_1 \theta_1)}{(1 - \phi_1^2)}$$

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

4 Autocovarianza

Para el caso de γ_1 se plantea: $\gamma_1 = E[\tilde{Y}_t \tilde{Y}_{t-1}]$

$$\begin{aligned}\gamma_1 &= E \left[\left(\phi_1 \tilde{Y}_{t-1} + e_t + \theta_1 e_{t-1} \right) \tilde{Y}_{t-1} \right] \\ \gamma_1 &= E \left[\phi_1 \tilde{Y}_{t-1}^2 + e_t \tilde{Y}_{t-1} + \theta_1 e_{t-1} \tilde{Y}_{t-1} \right]\end{aligned}$$

Recordando que: $E[Y_t^2] = \gamma_0$ y $E[e_{t-1} Y_{t-1}] = \sigma^2$

$$\gamma_1 = \phi_1 \gamma_0 + \theta_1 \sigma^2$$

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

4 Autocovarianzas

Para el caso de γ_2 se toma $E[\tilde{Y}_t \tilde{Y}_{t-2}]$:

$$\begin{aligned}\gamma_2 &= E \left[\left(\phi_1 \tilde{Y}_{t-1} + e_t + \theta_1 e_{t-1} \right) \tilde{Y}_{t-2} \right] \\ \gamma_2 &= E \left[\phi_1 \tilde{Y}_{t-1} \tilde{Y}_{t-2} + e_t \tilde{Y}_{t-2} + \theta_1 e_{t-1} \tilde{Y}_{t-2} \right] \\ \gamma_2 &= \phi_1 \gamma_1 + 0 + 0 \\ \gamma_2 &= \phi_1 \left(\phi_1 \gamma_0 + \theta_1 \sigma^2 \right) \\ \gamma_2 &= \phi_1^2 \gamma_0 + \phi_1 \theta_1 \sigma^2\end{aligned}$$

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

Generalizando:

$$\gamma_j = \phi_1 \gamma_{j-1} \quad \forall j \geq 2$$
$$\gamma_j = \phi_1^j \gamma_0 + \phi_1^{j-1} \theta_1 \sigma^2$$

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

5 Autocorrelación

Partiendo de los valores de γ_0 , γ_1 , γ_2 y γ_j , se tiene:

$$\rho_0 = \frac{\gamma_0}{\gamma_0} = 1$$

$$\rho_1 = \frac{\gamma_1}{\gamma_0} = \phi_1 + \frac{\theta_1 (1 - \phi_1^2)}{1 + \theta_1^2 + 2\phi_1\theta_1}$$

$$\rho_2 = \frac{\gamma_2}{\gamma_0} = \phi_1^2 + \phi_1 \frac{\theta_1 (1 - \phi_1^2)}{1 + \theta_1^2 + 2\phi_1\theta_1}$$


$$\vdots$$

$$\rho_j = \phi_1 \rho_{j-1} \quad \forall j \geq 2$$


- La función de autocorrelación es similar a la de la parte AR pero con una **deformación** en el rezago 1.

Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

ARMA(1,1) $\phi_1=0.5\theta_1=0.2$




ARMA(1,1) $\phi_1=0.5\theta_1=0.2$




Modelo autorregresivo de medias móviles de orden 1,1: ARMA(1,1)

ARMA(1,1) $\phi_1=-0.5\theta_1=0.2$



ARMA(1,1) $\phi_1=-0.5\theta_1=0.2$



Modelos no estacionarios

Para el caso de estos modelos, se les denominan así, ya que la serie a niveles (integración 0 ó $I(0)$), no es estacionaria, por ello se aplica un proceso de diferenciación dando como resultado un modelo integrado, de los cuales son:

- ARI (Autorregresivo integrado)
- IMA (Medias móviles integradas)
- ARIMA

Solo se ejemplificará el caso ARIMA, ya que el proceso autorregresivo integrado y el modelo de medias móviles integrado cuentan con la misma estructura, solo que la serie esta diferenciada.

Modelo autorregresivo integrado de medias móviles de orden p, l, q : ARIMA (p, l, d).

En este modelo se sigue una estructura similar al ARMA, puesto a que el modelo es una combinación de procesos autorregresivos y de medias móviles (shocks de larga y corta memoria), pero dentro de estos procesos la serie no es estacionaria, por ello se le conoce como: Modelo no estacionario.

Es decir, el modelo utilizará primeras diferencias para poder ser estimado de forma estacionaria, por ello lleva el nombre de integrado.

$$\Delta^d Y_t = \phi_1 \Delta^d Y_{t-1} + \phi_2 \Delta^d Y_{t-2} + \cdots + \phi_p \Delta^d Y_{t-p} \\ - a_t - \theta_1 a_{t-1} - \theta_2 a_{t-2} - \cdots - \theta_q a_{t-q}$$

Modelos estacionarios en polinomios

Trabajar los modelos en polinomios, ayuda a obtener las raíces unitarias para formar el círculo unitario y verificar que la ecuación estimada sea un proceso estacionario.

a) AR(q)

$$\Phi_p(L) Y_t = c + \varepsilon_t$$

b) MA(q)

$$Y_t = c + \Theta(L) \varepsilon_t$$

c) ARMA(p,q)

$$\Phi_p(L) Y_t = c + \Theta(L) \varepsilon_t$$

$$Y_t = c + \Psi(L) \varepsilon_t$$

Modelo no estacionario en polinomios

A pesar de ser un modelo no estacionario, también se puede trabajar en polinomios para obtener las raíces y detectar si dichos cálculos validan a la ecuación como un proceso estacionario en el círculo unitario.

a) Modelo ARIMA(p,l,q)

$$\Phi_p(L) \Delta^d Y_t = c + \Theta_q(L) \varepsilon_t$$



¿Qué es el círculo unitario?

Para que un proceso $AR(p)$ sea estacionario, se deben validar algunos supuestos matemáticos tales como $\Phi_p(L) \neq 0$ donde el polinomio característico es: $\Phi_p(L)$.

Sin embargo, para el resto de los modelos: MA, ARMA y ARIMA. Se debe sustentar que estos cumplen con la invertibilidad (Puede ver la demostración en el libro de Hamilton) y se obtiene un polinomio característico similar al del proceso $AR(p)$.

Al solucionar las raíces, se obtendrán dos componentes: El real $\mathbb{R}$ y el imaginario i , donde las magnitudes tienen que ser mayores a 1, para indicar que el proceso es estacionario.

Circulo unitario: Ejemplo



Metodología Box-Jenkis para la estimación de un modelo AR, MA, o ARMA/ARIMA

- Los profesores G.E.P. Box y G. M. Jenkis, en la década de los años 1970, proponen una serie de pasos para lograr identificar, ajustar y verificar los modelos ARIMA adecuados.
- Dicha metodología es más orientada a los procesos no estacionales, es decir, que los datos no presenten fluctuaciones periódicas a lo largo del tiempo.
- Solo se puede aplicar a datos equidistantes en el tiempo y discretos.
- Se requiere un mínimo de datos para poder realizar dicho procedimiento, con un parámetro de 50 datos en adelante.
- Se asume que los errores no están correlacionados.

Metodología Box-Jenkis para la estimación de un modelo AR, MA, o ARMA/ARIMA



Pasos de la estimación

- 1 Estacionariedad.- Identificar el orden de estacionariedad, ya sea $I(0)$, $I(1)$ o $I(2)$.
- 2 Identificación. – Con el uso de los correlogramas de la serie estacionaria, se puede identificar el orden p y q .
- 3 Estimación .- Se realiza la estimación con ayuda de un software especializado y se elige el mejor modelo a través de AIC (Akaike Information Criterion) o RMSE (Root Mean Square Error).
- 4 Evaluación. – Se analizan los residuos, si estos no presentan correlación; visualización de ACF y una prueba de Ljung-Box o Pierce-Box de no correlación.
- 5 Pronóstico. – Al encontrar el mejor modelo, se recomienda pronosticar periodos cortos, 5 observaciones a futuro como máximo. (Algunos proponen 10).



1 Estacionariedad

Se realiza la prueba ADF y los correlogramas para ver si la serie es estacionaria en orden $I(0)$, sino es así y hay presencia de raíces unitarias, se debe diferenciar una vez. Se vuelve a repetir el proceso y si en orden $I(1)$ es estacionario, entonces tendremos un orden $d=1$. No obstante, si la serie es estacionaria en $I(0)$, hablaremos de un modelo ARMA, por que $d=0$.



Identificación $AR(p)$

MODELO	Función de autocorrelación simple (FAS)	Función de autocorrelación parcial (FAP)
Autorregresivo (AR)		



Identificación MA(q)

MODELO	Función de autocorrelación simple (FAS)	Función de autocorrelación parcial (FAP)
De media móvil (MA)		

Identificación ARMA(p,q)

MODELO	Función de autocorrelación simple (FAS)	Función de autocorrelación parcial (FAP)
ARMA		

Identificación ARIMA (p,d,q)

MODELO	Función de autocorrelación simple (FAS)	Función de autocorrelación parcial (FAP)
ARIMA		

② Estimación

Una vez, elegido los modelos más representativos (ya sea $AR(p)$, $MA(p)$, $ARMA(p,q)$ o $ARIMA(p,d,q)$), se elegirá uno mediante los criterios de Akaike o el que presente menor termino de error cuadrático medio, lo cual se le conoce como **bodad de ajuste**.

Bondad de ajuste: Akaike Information Criterion (AIC)

Es una medida de calidad relativa de un modelo estadístico para un conjunto de datos dado, este estadístico proporciona un parámetro para la selección de un modelo teniendo en cuenta a otros modelos del mismo tipo o corte.

Se basa en la teoría de la información, por lo tanto este estadístico hace mención de la posible pérdida de información, entonces, entre menor sea mejor será.

$$AIC = 2K - 2\ln(L)$$
$$AIC_c = \frac{2kn}{n - k - 1} - 2\ln(L)$$

Root Mean Square Error

El error cuadrático medio, mide la cantidad de error que hay entre dos conjuntos de datos. En otras palabras, compara el valor estimado con el valor real u observado. Dentro de los modelos, se busca que el RMSE sea lo menor posible y que tienda a 0.

$$RMSE = \sqrt{\sum_{i=1}^n \frac{(\hat{y}_i - y_i)^2}{n}}$$

3 Evaluación

En esta parte, cuando ya se eligió la mejor estimación, se presenta el estudio de los residuos. Como parte fundamental de dicho modelo, es buscar que el comportamiento de una caminata aleatoria no se haga presente, por lo que no debe existir correlación alguna, es por ello que para identificar dicha cuestión, se hace uso de los siguientes estadísticos:

- Box-Ljung Statistic.
- Box-Pierce Statistic.


Estadístico Box-Pierce-Ljung

Es un estadístico asociado a la hipótesis nula de autocorrelación de la variable en una serie temporal discreta. Permite valorar en cuanto la variable en una serie temporal es aleatoria o en cuanto manifiesta autocorrelación de tipo simple para el conjunto de retardos en que se especifica la prueba.

- H_0 : No correlación serial
- H_a : Correlación serial

$$Q = n \sum_{j=1}^P \hat{\rho}_j^2$$
$$\hat{\rho}_j = \frac{\sum_{t=j+1}^n e_t e_{t-j}}{\sum_{t=1}^n e_t^2}$$

4 Análisis de ACF para los residuales



5 Pronostico

- La fase final de la metodología Box-Jenkins es pronosticar valores futuros de la serie de tiempo. Para esta ultima parte, es necesario tener presentes el concepto *intervalo de confianza y suficiencia de los pronósticos*.
- Los dos conceptos anteriores, se refiere a que el modelo ARIMA, nos otorga valores a futuro en diversos intervalos: 85%, 90% y 95% a una estimación creciente y decreciente, con ello realiza una estimación puntual que se situé en el comportamiento más probabilístico posible.

Conclusión

Los modelos AR, MA, ARMA y ARIMA son modelos de predicción paramétrica, es decir, se basan en el comportamiento de la misma serie (por ello son denominados univariantes) y la desventaja es el poco plazo de valores futuros que llegan a pronosticar, además de que se debe ser muy preciso a la hora de tratar las metodologías para conseguir una estimación eficiente

- AGUIRRE, J. A. (1994). *Introducción al tratamiento de series temporales: Aplicación a las ciencias de la salud*. Ediciones Diaz de Santos, S.A. Madrid.
- CAO, A. R. (2002). *Introducción a la simulación y a la teoría de colas*. Netbiblo, España.
- CHAN, H. N. (2010). *Time series: applications to Financer with R and S-Plus*. Wiley, USA.
- GUJARATI, N. D. (2010). *Econometría* (5ta. ED.). MC Graw Hill, México.
- SHUMWAY, H. R. & STOFFER, S. D. (2017). *Time series analysis and its applications*. Springer, USA.

TSAY, S. R. (2012). *An introduction to analysis of financial data with R*. Wiley, USA.

WOODWARD, A. W, et al. (2016). *Applied time series analysis with R*. CRC Press, USA.