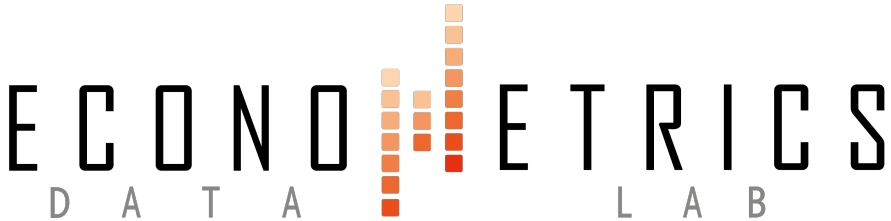
Filtros de series de tiempo

Series de tiempo con Python

Econ. Morales Alberto Alexis Adonai

2024



Introducción

- Existen métodos de suavización que pueden ser aplicados en las series temporales. La finalidad de éstos es minimizar la varianza para poder trabajar con una serie más estable. O bien, también ayudan a mitigar el componente ciclico que genera altas varianzas o media no constante en una serie temporal.
- Dichas innovaciones en series de tiempo pueden ayudar a que las series transformadas, sean más manipulables, es decir, que se ajusten mejor a los modelos estacionarios o cualquier otro modelo dinámico.
- Además estas metodologías pueden servir para poder predecir el comportamiento futuro de la serie de tiempo mediante la tendencia de la misma o mediante innovaciones dinámicas que permiten una estimación más ***óptima***.

Introducción

- Los modelos estacionarios, no estacionarios y estacionales, son modelos paramétricos en los que se obtiene la representación de la variable en términos de su interralación temporal (MATILLA, et al, 2017).
- Los modelos de componentes inobservables se basan en la idea de que una serie temporal se puede considerar como la superposición de componentes no observables (como ciclo, varianza, étc.).

Ciclos

Para comenzar e introducirse al filtro de Hodirck y Prescott, se debe entender un poco sobre el ciclo (ques es un concepto relacionado con la estacionalidad pero que no es lo mismo), el cual influye dentro de los fenómenos económicos o en series que se presentan factores repetitivos.

- Un ciclo consiste en expansiones, recesiones, contracciones y recuperaciones. Por lo tanto, se puede definir como una serie de repeticiones de la tendencia en ciertos periodos y que se muestran en lapsos de tiempo dentro de un intervalo de la muestra.
- El ciclo se puede expresar como una diferencia entre serie y tendencia.

Filtro de Hodrick y Prescott

- Surge de un estudio en los años 80's como consecuencia de analizar ciclos reales de la economía.
- Este filtro permite estimar la tendencia y el ciclo de una serie de tiempo, por lo que se puede deducir que dicha serie esta consistituida (formada) por estos dos elementos:

$$Y_t = C_t + T_t \quad t = 1, \cdots, T.$$

- Para cálcula dichas estimaciones, se debe de encontrar una constante definida como λ que se refiere a un parámetro de suavidad de la tendencia y que comúnmente se expresa como un valor estándar.

Filtro de Hodrick y Prescott

- La constante del filtro Hodrick y Prescott (HP) se propone que sea elegida de acuerdo con el método de Guerrero (2008), para que la tendencia tenga un porcentaje de suavidad elegido de antemano y que se pueda comparar con los resultados en diversas aplicaciones.
- El método para series trimestrales se puede extemnder a series con otras frecuencias de observaciones (mensuales, anuales, etc.) equivalentes, que producen los mismos porcentajes de suavidad.
- El objetivo principal es ilustrar las implicaciones que conlleva el uso de distintos porcentajes de suavidad para la tendencia, en las conclusiones sobre los ciclos.

Filtro de Hodrick y Prescott

- Se define la serie de tiempo como la suma de un componente de crecimiento (que es equivalente a la tendencia) y un ciclo.

$$Y_t = g_t + c_t \ \ \forall t = 1, 2, 3, \cdots, T.$$

- Existe un proceso de optimización particular: Minimizar la varianza del componente cícliclo y la varianza de la segunda diferencia del componente de tendencia.

$$min_{\{gt\}_{t=-1}^{T}} \left\{ \sum_{t=1}^{T} c_t^2 + \lambda \sum_{t=1}^{T} \left[(g_t - g_{t-1}) - (g_{t-1} - g_{t-2}) \right]^2 \right\} \qquad (1)$$

Filtro de Hodrick y Prescott

- El factor de suavizado λ es:

$$\lambda = \frac{\sigma_1^2}{\sigma_2^2}$$

- La evidencia y pertinencia de los factores de suavizado λ que suguieren los autores (Hodrick y Prescott, 1997) para datos anuales es de 100 y 1600 para datos trimestrales, aunque también se sabe que para series mensuales el factor es de 14400.
- Sin embargo, la crítica proviene de que el parámetro λ presenta una serie de inconsistencias.

Filtro de Hodrick Prescott

1. Los componentes ciclo y tendencia presentan desviaciones prominentes cuando el estimador λ no es consistente.
2. Los ciclos reales son espurios ya que se derivan de la sobreidentificación del orden de las series de tiempo.
3. Las varianzas del ciclo y la tendencia corresponden a series particulares, es decir, asumir fenómenos *a priori* en los factores de suavizado pueden perturbar inferencias.

Filtro de Hodrick Prescott

La propuesta de HP para una correcta estimación es la siguiente:

- Identificar puntualmente el orden de integración de la tendencia y proceder a utilizar la varianza correspondiente.
- Considerar y ponderar el factor λ por un coeficiente inverso de *frecuencia angular* :

$$\lambda = fa\frac{\sigma_1^2}{\sigma_2^2}$$

- Donde:

$$fa = \left[\frac{\tau}{T}\right]^{-1}$$

Filtro de Hodrick Prescott

- En términos de Hodrick y Prescott (1997):

$$y_t = (y_1, y_2, \cdots, y_t) \quad y_t \in R^T$$
$$g_t \in R^T$$
$$c_t \in R^T$$
$$y_t = g_t + c_t$$

- Si el factor suavizado no es negativo $\lambda > 0$, la descomposición de la serie y_t, se obtiene minimizando la suma ponderada de cuadrados con respecto a g_t:

$$||y - g||^2 + \lambda||\Delta^2 - g||^2 \quad \lambda \in R^T$$

Filtro de Hodrick Prescott

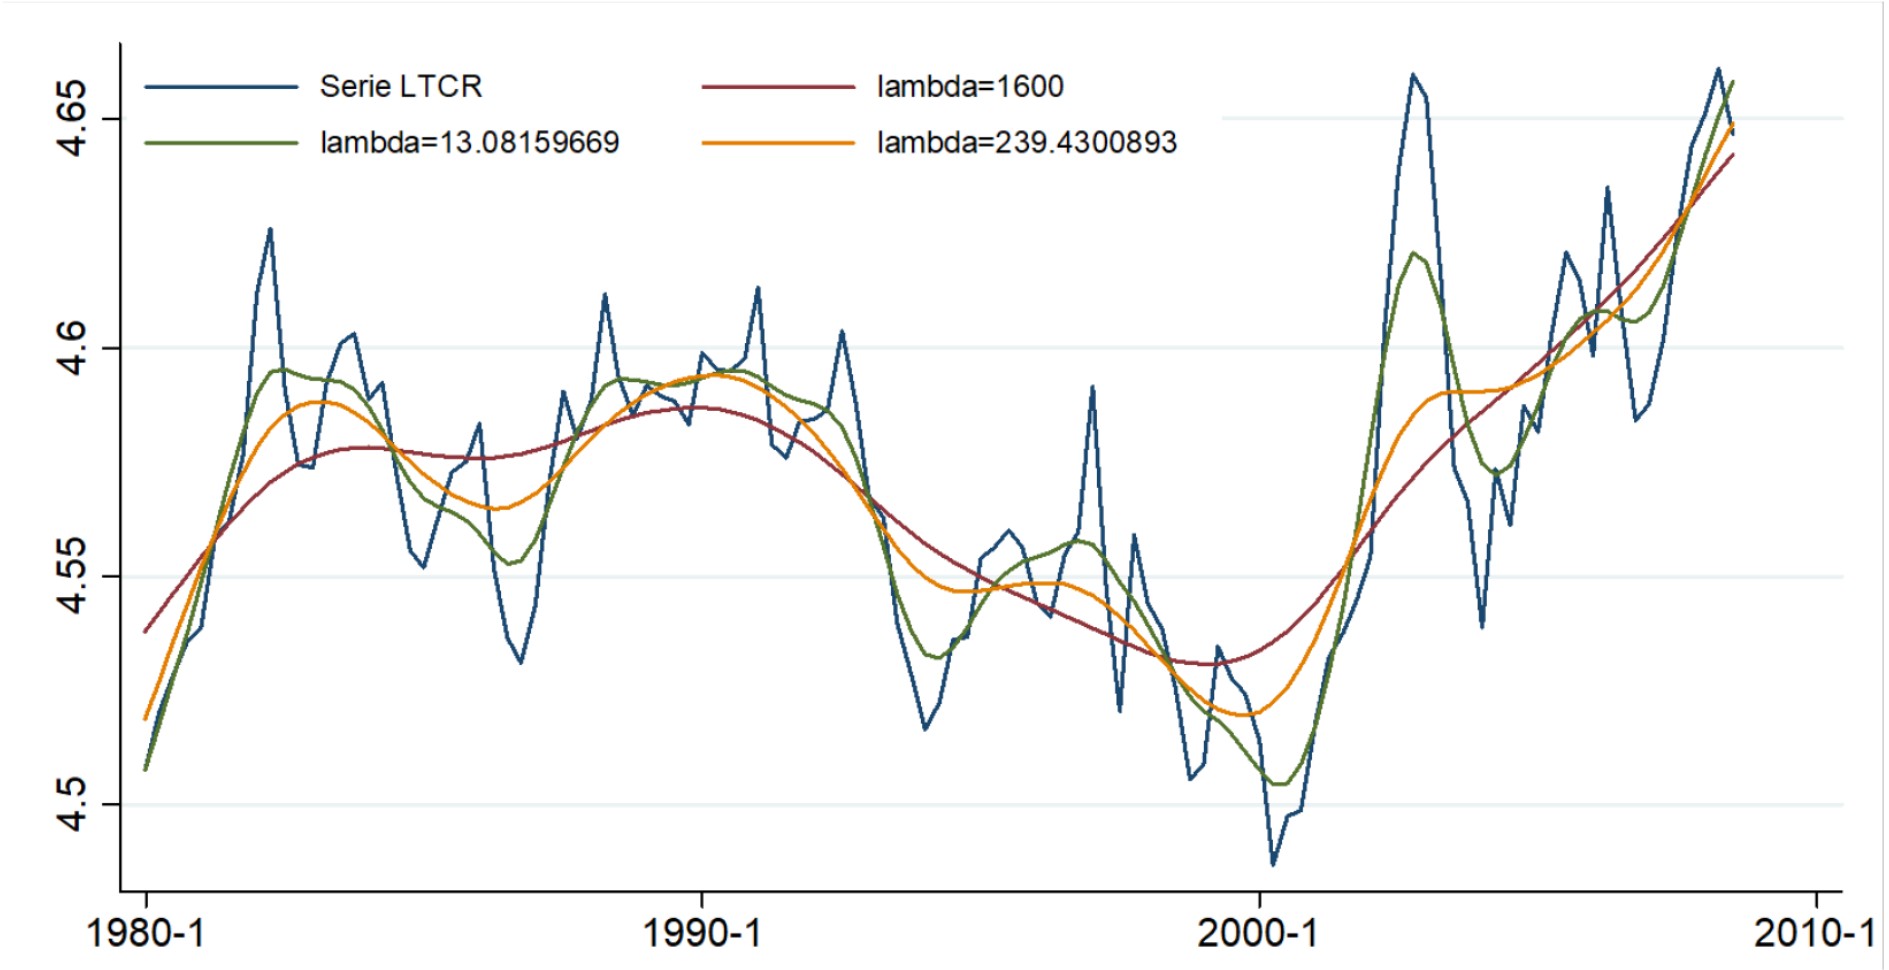
- La solución única de la minimización se define como:

$$g\left(\lambda, y\right)\right)\left[I+\lambda Z^{'} Z\right]^{-1} y$$

- Donde Z denota una matriz particular de dimensión $\left(T-2 \times T\right)$, e I indica una matriz de identidad:

$$Z_{T-2 \times T}=\begin{bmatrix} 1 & -2 & 1 & \cdots & \cdots & 0 \\ 0 & 1 & -2 & 1 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots & \cdots & \cdots \\ 0 & \cdots & \cdots & 1 & -2 & 1 \end{bmatrix}$$

Filtro de Hodrick Prescott



Promedios móviles

- Dentro de los métodos de alisado o *suavizamiento*, se encuentran las medias móviles (no hay que confundirlo con el modelo de medias móviles).
- Este método tiene diversas aplicaciones, por lo cual puede ser útil si se desea obtener la tendencia de una serie temporal, sin tener que ajustarse a una función previa.
- Al realizar lo anterior, se obtiene una serie suavizasa o alisada ya que al promediar varios valores, se elimina la parte ciclica o los móvimientos irregulares.

Promedios móviles

- Existen dos tipo de medias móviles: La centrada y la no centrada (asimétrica). La primera se utiliza para la representación de la tendencia, mientras que la segunda solo se aplicará para poder predecir la serie mediante la tendencia.
- Hay que recordar, que estos métodos estan sustentados mediante **el modelo clásico de descomposición** y que por consiguiente, la comprensión del método clásico permite entender mejor los métodos actuales.

Promedios móviles: Centrada

- Se caracterizan porque el número de observaciones que entran en su cálculo es impar, asignándose cada media móvil a la observación central. Así, una media móvil centrada en t de longitud $2n + 1$:

$$\hat{T}_t = \frac{1}{m} \sum_{i=-k}^{k} Y_{t+i} \text{ donde } m = 2k + 1$$

Promedios móviles: Centrada

- La estimación de la tendencia en el momento t se obtiene promediando los valores de la serie de tiempo, utilizando k desfases hacia atrás y k valores hacia adelante de su periodo central t.
- Este promedio elimina en gran parte la aleatoriedad de la serie, dejando un componente más suavizado.
- Se denominará al promedio móvil centrado de orden m como $m - MA$.

Ejemplo

Table 1: Producción de cemento.

Años	Cemento	3-MA	9-MA
1980	19724.00		
1981	18487.00	18914.00	
1982	18531.00	18314.66	
1983	17926.00	17565.00	
1984	16238.00	16902.66	18732.74
1985	16544.00	17006.46	19432.91
1986	18237.40	18339.46	20553.42
1987	20237.00	20381.56	21694.11
1988	22670.30	22977.62	22596.89
1989	26025.56	25755.80	23319.45
1990	28571.56	27798.11	24152.09
1991	28797.23	27806.60	24954.42
1992	26051.01	25863.09	25453.30

Ejemplo

Table 2: Producción de cemento.

Años	Cemento	3-MA	9-MA
1993	22741.03	24276.61	25911.56
1994	24307.79	24079.05	26463.17
1995	25458.33	24741.02	27136.00
1996	24726.96	25659.96	28207.27
1997	26794.60	27503.88	29996.11
1998	30990.09	30803.89	32371.53
1999	34626.98	34685.23	34836.58
2000	38438.64	38405.40	37341.55
2001	42150.58	41569.68	40317.41
2002	44119.82	44164.54	
2003	46223.24	46115.39	
2004	48003.11	48578.66	
2005	51509.64		

Ejemplo

El primer valor de la columna denominada **3-MA** de las tablas anteriores, se calcula de la siguiente forma: $18914 = (19724 + 18478 + 18531)/3$, y el primero de la columna **9-MA**, $18732.74 = (19724 + 18487 + 18531 + 17926 + 16238 + 16544 + 18237.4 + 20237 + 22670.3)/9$.

Promedios móviles: Centrada

- El orden de la media móvil m, determina la suavidad de la estimación. En general, un orden mayor implica una curva más suave.
- Los promedios simples son de orden impar. De esta forma se consigue que sean símetricos en su punto medio t: En un promedio móvil de orden impar $m = 2k+1$, hay k observaciones anteriores, y k posteriores a la observación que se promedia t. Pero si m fuera par, la media ya no sería simétrica.

Promedios móviles: No centrada

- Por su parte, en el caso de las medias móviles asimétricas (no centradas) se asigna cada media móvil al periodo correspondiente de la observación más adelantada, de todas las que intervinen en su cálculo. Así, la media móvil asimétrica de n puntos esta asociada a la observación t.

$$MMA(n) = \frac{y_{t-n} + y_{t-n+1} + \cdots + y_t}{n}$$

Ejemplo

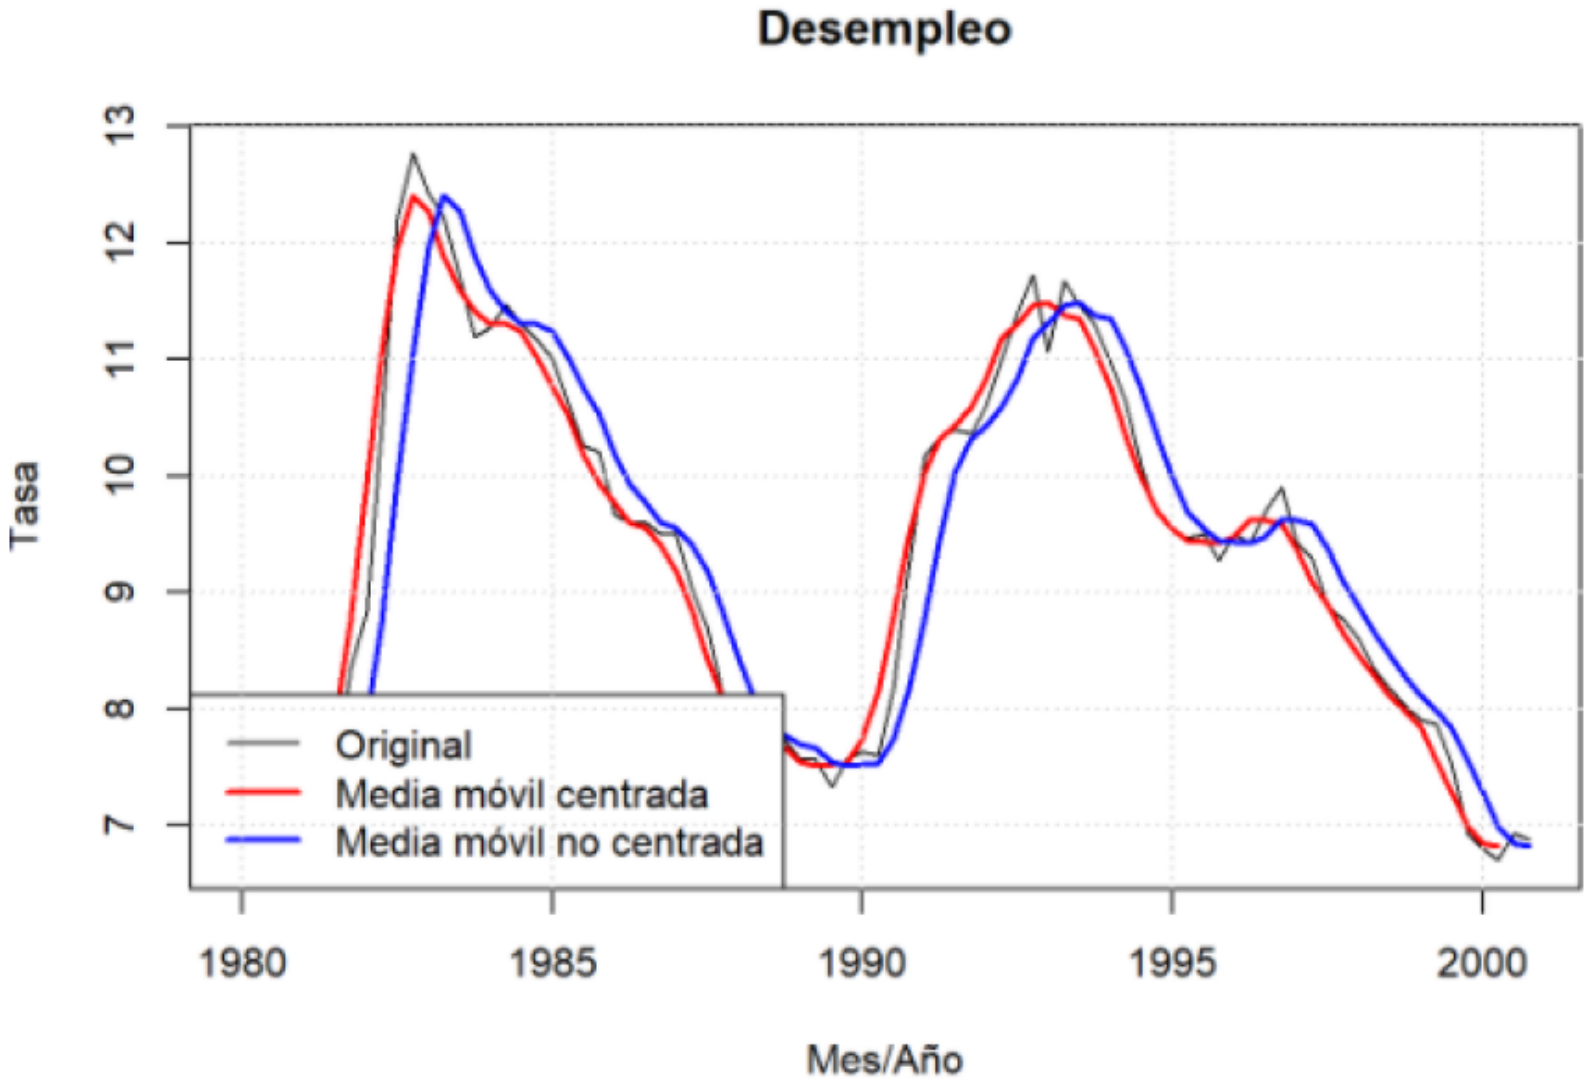
Table 3: Refrescos vendidos por día

Día	Venta	MMA(3)
1	20	
2	23	
3	24	22.33
4	25	24
5	30	26.33
6	35	30
7	40	35
8	50	41.66

Ejemplo

- El cálculo de la primera media es: $(20+23+24)/3$, pero si el lector es observador, los promedios se irán recorriendo de un dato en un dato, con la finalidad de que se pueda obtener una media en el día 8 de la venta.
- A diferencia de la media móvil centrada, se toman valores pasados y futuros para calcular el promedio móvil y no solo pasados tal y como lo hace la media móvil asimétrica.

¿Cómo se visualizan ambos tipos de media móvil?



Alisado exponencial de Holt

- Antes de retomar el filtro de **Holt-Winters**, vale la pena repasar en qué consiste el alisado de **Holt**.
- El alisado exponencial con tendencia lo planteó Holt (1957), partiendo del AES (Alisado Exponencial Simple) y añadiendo una tendencia lineal, por lo tanto, la ecuación se plantea de la siguiente manera:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = n_t + h * b_t$$

$$\text{Nivel } n_t = \alpha Y_t + (1-\alpha)(n_{t-1} + b_{t-1})$$

$$\text{Tendencia } b_t = \beta^* (n_t - n_{t-1}) + (1-\beta^*) b_{t-1}$$

Alisado exponencial de Holt

- Donde n_t es la ecuación de nivel de la serie; b_t la pendiente estimada de la tendencia; α el parámetro de suavizado del nivel, $0 \leq \alpha \leq 1$; y β^* el parámetro de suavizado de la tendencia $0 \leq \beta^* \leq 1$.
- Al igual que el AES, la ecuación de nivel muestra que n_t es un promedio ponderado de la observación Y_t y la estimación del valor anterior, en este caso $Y_{t|t-1} = n_{t-1} + b_{t-1}$.
- La ecuación de tendencia indica que b_t es un promedio ponderado de la tendencia en el momento t, $n_t - n_{t-1}$ y b_{t-1}, la estimación de tendencia de la observación anterior.

Alisado exponencial de Holt

- La previsión ya no es constante, sino una tendencia lineal con b_t como pendiente de la recta de previsión y el nivel, n_t, como ordenada en el origen.
- La ecuación de corrección de errores es:

$$n_t = n_{t-1} + b_{t-1} + \alpha e_t b_t$$

$$n_t = b_{t-1} + \alpha\beta^* e_t;$$

$$\text{Donde } e_t = Y_t - (n_{t-1} + b_{t-1}) = Y_t - \hat{Y}_{t|t-1}$$

Alisado con tendencia exponencial de Holt

- Una variante del método de Holt consiste en introducir los componentes, tendencia y nivel, de una forma multiplicativa (en vez de aditiva), la ecuación por componentes es:

$$\text{Prónostico } \hat{Y}_{t+h|T} = n_t * b_t^h$$

$$\text{Nivel } n_t = \alpha Y_t + (1-\alpha)(n_{t-1} * n_{t-1})$$

$$\text{Tendencia } b_t = \beta^* \frac{n_t}{n_{t-1}} + (1-\beta^*) b_{t-1}$$

- Donde b_t es la tasa de crecimiento constante de predicción (es decir, se considera el crecimiento en términos relativos en vez de términos absolutos).

Alisado con tendencia exponencial de Holt

- La tendencia ahora es exponencial en vez de lineal.
- La ecuación de corrección de error es:

$$n_t = n_{t-1} * b_{t-1} + \alpha e_t$$

$$b_t = b_{t-1} + \alpha\beta^* \frac{e_t}{n_{t-1}}$$

Donde: $e_t = Y_t - (n_{t-1} * b_{t-1}) = Y_t - \hat{Y}_{t|t-1}$

Alisado con tendencia lineal amortiguada

- En muchas ocasiones los métodos de alisado exponencial con tendencia, lineal o exponencial, tienen a sobreestimar las previsiones, especialmente a largo plazo, por ello Ladiray y Quenneville (2001) introdujeron un parámetro que amortiguara la tendencia.
- El métdo consiste en intriducir un término de ϕ que este entre 0 y 1 $0 \leq \phi \leq 1$, que amortigua la tendencia hasta convertirla en una constante. Es decir, al incluir el término de ϕ se amortiguara la tendencia y la previsión convergerá a $n_t + \frac{\phi b_t}{1-\phi}$ cuando $h \to \infty$.

Alisado con tendencia lineal amortiguada

- La ecuación por componentes adivitos es:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = n_t + \left(\phi + \phi^2 + \cdots + \phi^h\right) b_t$$

$$\text{Nivel } n_t = \alpha Y_t + (1-\alpha)\left(n_{t-1} + \phi b_{t-1}\right)$$

$$\text{Tendencia } b_t = \beta^*\left(n_t - n_{t-1}\right) + \left(1-\beta^*\right)\phi b_{t-1}$$

- Si $\phi = 1$ el método es idéntico al lineal de Holt. Para valores entre 0 y 1, ϕ amortigua la tendencia hasta convertirse en una constante en el futuro lejano.

Alisado con tendencia lineal amortiguada

- Por consiguiente las previsiones a corto plazo presentan una tendencia amortiguada mientras que las previsiones a largo o muy largo plazo son constantes. La ecuación de corrección de errores es:

$$n_t = n_{t-1} + \phi b_{t-1} + \alpha e_t$$
$$b_t = \phi b_{t-1} + \alpha\beta^* e_t$$

Alisado con tendencia exponencial amortiguada

- Cuando se condiera la intriducción de los componentes de forma multiplicativa, la forma por componentes es:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = n_t * b_t^{\left(\phi+\phi^2+\cdots+\phi^h\right)}$$

$$\text{Nivel } n_t = \alpha Y_t + (1-\alpha)\, n_{t-1} * b_{t-1}^{\phi}$$

$$\text{Tendencia } b_t = \beta^* \frac{n_t}{n_{t-1}} + (1-\beta^*)\, b_{t-1}^{\phi}$$

- La ecuacón de corrección de errores es:

$$n_t = n_{t-1} * b_{t-1}^{\phi} + \alpha e_t$$

$$b_t = b_{t-1}^{\phi} + \alpha\beta^* \frac{e_t}{n_{t-1}}$$

Alisado estacional de Holt-Winters

- Holt (1957); Winters (1960) extendieron el método de Holt para capturar el componente estacional. El método estacional de Holt-Winters comprende la ecuación de pronóstico y tres ecuaciones de componentes.
  1. Nivel: n_t.
  2. Tendencia: b_t.
  3. Estacional: s_t.
- Con parámetros de suavizado α, β^* y γ. Se utiliza m para denominar el núemero de periodos estacionales del año, por ejemplo. Para datos trimestrales $m = 4$, para datos mensuales $m = 12$ y así sucesivamente.

Alisado estacional de Holt-Winters

- Hay dos variaciones del método que difieren en la naturaleza del componente estacional. La referencia es al método aditivo, ya que cuando las variaciones estacionales son más o menos constantes en toda la serie, mientras.
- La segunda variación es referente al método multiplicativo, ya que cuando las variaciones estacionales cambian proporcionalmente con el nivel de la serie.
- Con el método aditivo, el componente estacional se expresa en términos absolutos en la escala de la serie observada y en la ecuación de nivel de la serie se ajusta estacionalmente restando el componente estacional.

Alisado estacional de Holt-Winters

- Dentro de cada año, la suma de los m valores del componente estacional es aproximadamente cero.
- Con el método multiplicatuvo, el componente estacional se expresa en términos relativos (porcentakes) y la serie se ajusta estacionalmente dividiendo por el componente estacional.
- Dentro de cada año, la suma de los índices estacionales multiplicativos es aproximadamente igual a m.

Holt-Winters aditivo

- La ecuación por componentes del método aditivo es:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = n_t + h * b_t + s_{t-m+h_m^+}$$
$$\text{Nivel } n_t = \alpha\left(Y_t - s_{t-m}\right) + (1-\alpha)\left(n_{t-1} + b_{t-1}\right)$$
$$\text{Tendencia } b_t = \beta^*\left(n_t - n_{t-1}\right) + \left(1-\beta^*\right) b_{t-1}$$
$$\text{Estacionalidad } s_t = \gamma\left(Y_t - n_{t-1} - b_{t-1}\right) + (1-\gamma)\, s_{t-m}$$

- Donde $h_m^+ = [(h-1)\, mod\, m] + 1$, garantiza que las estimaciones de los índices estacionales utilizados para pronosticar provengan del último año muestral.

Holt-Winters aditivo

- La ecuación de nivel es una media ponderada entre la observación desestacionalizada $(Y_t - s_{t-m})$ y la previsión desestacionalizada $(n_{t-1} + b_{t-1})$ para el momento t.
- La ecuación de tendencia es la tendencia lineal de Holt. La ecuación de estacionalidad es una media ponderada entre el actual índice de estacionalidad, $(Y_t - n_{t-1} - b_{t-1})$, y el índice de estacionalidad anterior.

Holt-Winters aditivo

- La ecuación del componente estacional suele expresarse como:

$$s_t = \gamma(Y_t - n_{t-1}) + (1 - \gamma)\, s_{t-m}$$

- Si se sustituye n_t de la ecuación de suavizado para el nivel de la fórmula, por componentes anterior, se obtiene:

$$s_t = \gamma * (1 - \alpha)\,(Y_t - n_{t-1} - b_{t-1}) + [1 - \gamma * (1 - \alpha)]\, s_{t-m}$$

Holt-Winters aditivo

- La ecuación anterior, es identica a la ecuación de suavizado para el componente estacional que se especifico con $\gamma = \gamma^*(1-\alpha)$. La restricción de parámetro usual es que $0 \leq \gamma \leq 1$, lo que se traduce en que $0 \leq \gamma \leq 1-\alpha$.
- La forma de corrección es:

$$n_t = n_{t-1} + b_{t-1} + \alpha e_t$$
$$b_t = b_{t-1} + \alpha\beta^* e_t$$
$$s_t = s_{t-m} + \gamma e_t$$
$$\text{Donde: } e_t = Y_t - (n_{t-1} + b_{t-1} + s_{t-m}) = Y_t - \hat{Y}_{t|t-1}$$

Holt-Winters multiplicado

- La forma de componente para el método multiplicativo es:

$$\text{Pronóstico } \hat{Y}_{t+h|T} = (n_t + h * b_t) * s_{t-m+h_m^+}$$

$$\text{Nivel } n_t = \alpha \left(\frac{Y_t}{s_{t-m}} \right) + (1-\alpha)(n_{t-1} + b_{t-1})$$

$$\text{Tendencia } b_t = \beta^* (n_t - n_{t-1}) + (1-\beta^*) b_{t-1}$$

$$\text{Estacionalidad } s_t = \gamma \left(\frac{Y_t}{n_{t-1} + b_{t-1}} \right) + (1-\gamma) s_{t-m}$$

Holt-Winters multiplicado

- La represntación de correción de errores:

$$n_t = n_{t-1} + b_{t-1} + \alpha \frac{e_t}{s_{t-m}}$$

$$b_t = b_{t-1} + \alpha\beta^* \frac{e_t}{s_{t-m}}$$

$$s_t = s_{t-m} + \gamma \frac{e_t}{n_{t-1} + b_{t-1}}$$

Donde: $e_t = Y_t - (n_{t-1} + b_{t-1})\, s_{t-m} = Y_t - \hat{Y}_{t|t-1}$

Holt-Winters amortiguado

- En ocasiones el método de pronóstico más preciso para las series de tiempo estacionales es el método de Holt-Winters con una tendencia amortiguada y estacionalidad multiplicativa, su expresión por componente es:

$$\text{Prónostico } \hat{Y}_{t+h|T} = \left(n_t + \phi + \phi^2 + \cdots + \phi^h\right) * s_{t-m+h_m^+}$$

$$\text{Nivel } n_t = \alpha\left(\frac{Y_t}{s_{t-m}}\right) + (1-\alpha)\left(n_{t-1} + \phi b_{t-1}\right)$$

$$\text{Tendencia } b_t = \beta^*\left(n_t - n_{t-1}\right) + \left(1-\beta^*\right)\phi b_{t-1}$$

$$\text{Estacionalidad } s_t = \gamma\left(\frac{Y_t}{n_{t-1} + \phi b_{t-1}}\right) + (1+\gamma)\, s_{t-m}$$

Filtro de Kalman

- El filtro de Kalman es un procedimiento recursivo cuyo objetivo es calcular estimadores óptimo del vector estado en un momento de tiempo t, utilizando toda la información disponible hasta el momento t.
- Es decir, conocidas las observaciones de la serie Y_t hasta el momento t; los valores de z, C, R, Q, σ^2 y los valores iniciales (a_0, P_0). El método o algoritmo recursivo se puede dividir en dos grupos de ecuaciones.

Filtro de Kalman

1. Ecuaciones de predicción, que obtienen un predictor óptimo del vector estado y de la próxima observación: Dados los valores a_t y P_t obtenemos $a_{t+1|t}$, $Y_{t+1|t}$, $P_{t+1|t}$.
2. Ecuaciones de actualización que incorporan la nueva observación Y_{t+1} en la estimación del vector de estado: Dada la nueva observación Y_{t+1} obtenemos a_{t+1}, P_{t+1}.

Filtro de Kalman

Las ventajas del filtro son:

- Permite actualiza la estimación del vector estado continuamente según se van obteniendo nuevas observaciones.
- Produce predictores óptimos, en el sentido de *ECM* mínimo.
- El filtro tiene algoritmos además que permite estimar los componentes, mediante la denominada *extracción de señales*, utilizando toda la información de la muestra.
- Cuando las perturbaciones se distribuyen normalmente, se puede construir la función de verosimilitud, estimar los parámetros desconocidos y realizar constrastes diagnóstico y especificación.

Filtro de Kalman

Forma general del filtro de Kalman:

- Considerando el modelo invariable en el tiempo, se tiene:

$$Y_t = z\alpha_t + d + e_t$$
$$\alpha_t = C\alpha_{t-1} + g + R_t\eta_t$$

- Donde:

$$\begin{bmatrix} e_t \\ \eta_t \end{bmatrix} \sim NID\left[0, \begin{bmatrix} \sigma^2 & 0 \\ 0 & Q \end{bmatrix}\right]$$
$$cov\left(e_t, a_{t-k}\right) = 0 \ \forall k \geq 0 \quad a_0 \sim N\left(a_0, P_0\right)$$
$$E\left(e_t\eta_t\right) = 0 \ E\left(e_t a_t\right) = 0 \ E\left(\eta_t a_t\right) = 0 \ \forall t, s$$

Filtro de Kalman

- El conjunto de ecuaciones que forman el filtro se dividen en ecuaciones de predicción que proporcionan el predictor óptimo para el vector de estado a_{t+1} con toda la información hasta t, y las ecuaciones de actualización permiten incorporar la nueva información disponible dentro del estimador del vector estado.
- Sea a_{t-1} el estimador óptimo de a_{t-1}, basado en todas las observaciones disponibles hasta Y_{t-1}. Denotemos P_{t-1} a la matriz de covarianzas del error de estimación del vector de estado:

$$P_{t-1} = E\left[\left(\alpha_{t-1} - a_{t-1}\right)\left(\alpha_{t-1} - a_{t-1}\right)'\right]$$

Filtro de Kalman

- Dados a_{t-1} y P_{t-1}, el estimador óptimo de α_t junto con su *ECM* viene dado por las ecuaciones de predicción:

$$a_{t|t-1} = Ca_{t-1} + e$$
$$P_{t|t-1} = CP_tC^{'} + RQR^{'}$$

- Dada esta estimación del vector estado en el momento t con información hasta el momento $t-1$, se puede obtener la predicción del valor futuro Y_t:

$$Y_{t|t-1} = za_{t|t-1} + d$$

Filtro de Kalman

- El error de predicción correspondiente es:

$$\xi_t = Y_t - Y_{t|t-1} = Y_t - za_{t|t-1} - d = z\left(\alpha_t - a_{t|t-1}\right) + e_t$$

- Estos errores de predicción se denominan *innovacione* ya que representan la nueva información contenida en la última observación.

Filtro de Kalman

- Cuando llega la nueva observación Y_t, el estimador de α_t, $a_{t|t-1}$, junto con su matriz de **ECM**, se puede actualizar, mediante las ecuaciones de actualización:

$$a_t = a_{t|t-1} + P_{t|t-1} z f_t^{-1} \left(Y_t - z a_{t|t-1} - d \right)$$
$$P_{t|t-1} = P_{t|t-1} - P_{t|t-1} z f_t^{-1} P_{t|t-1}$$

- Donde:

$$f_t = z P_{t|t-1} z^{'} + \sigma^2$$

- Se puede observar que las innovaciones tienen un papel fundamental en la actualización del vecto estado. Cuanto más alejado esté el error ξ_t del vector nulo, mayor será la corrección en el vector estado. Además se observa que f_t no es más que la varianza del error de pedicción.

Filtro de Kalman

- Las ecuaciones de predicción junto con las actualización conforman el filtro. Este se puede especificar también como un solo conjunto de recursiones:

$$a_{t|t-1} = C\left[a_{t|t-1} + P_{t|t-1} z f_t^{-1}\left(Y_t - z a_{t|t-1} - d\right)\right] + e$$
$$P_{t|t-1} = C\left[P_{t|t-1} - P_{t|t-1} z^{'} f_t^{-1} z P_{t|t-1}\right] C^{'} + RQR^{'}$$

- Operando se tiene:

$$a_{t|t-1} = C a_{t|t-1} + k_t\left(Y_t - z a_{t|t-1} - d\right) + e$$
$$P_{t|t-1} = C\left[P_{t|t-1} - P_{t|t-1} z^{'} f_t^{-1} z P_{t|t-1}\right] C^{'} + RQR^{'}$$

Filtro de Kalman

- Donde:

$$k_t = CP_{t|t-1}zf_t^{-1}$$

- Es conocida como la *ganancia de Kalman*. La ecuación de recursión para el vecto estado se puede escribir como una combinación lineal de la nueva observación y de la última estimación:

$$a_{t+1|t} = (C - kz)\, a_{t|t-1} + k_t Y_t$$

Filtro de Kalman

- La recursión para la matriz de covarianzas del error de estimación se conoce como *ecuación de Ricatti*.
- Los valores indiciales dek filtro se pueden especificar en términos de a_0 y P_0 y/o de $a_{1|0}$ y $P_{1|0}$. Dadas las condiciones inciales, el filtro proporciona el estimador óptimo del vector estado según va llegando cada nueva observación.
- Cuando se han procesado las T observaciones, el filtro nos proporciona el estimador óptimo del vector estado en el momento T, a_T, y en el $T+1$ basado en el conjunto de información completo, $a_{T+1|T}$.
- Este estimador contiene toda la información necesaria para llevar a cabo predicciones óptimas de los valores futuros tanto de Y_t como del vector estado.

Interpretación del filtro de Kalman

- Bajo los supuestos de normalidad siguiente:

$$a_0 \sim N(\alpha_0, P_0)$$

$$\begin{bmatrix} e_t \\ \eta_t \end{bmatrix} \sim NID \left[0, \begin{bmatrix} \sigma^2 & 0 \\ 0 & Q \end{bmatrix} \right]$$

- Se puede derivar el filtro e interpretarlo. Para $t = 1$, entonces:

$$\alpha_1 = C\alpha_0 + R\eta_1$$

Interpretación del filtro de Kalman

- Donde α_1 es normal multivariante porque es una combinación lineal de variables normales y condicionado a Y_0, se tiene que la media de α_1 es:

$$a_{1|0} = Ca_0$$

- Y la matriz de covarianzas:

$$P_{1|0} = CP_0C^{'} + RQR^{'}$$

Interpretación del filtro de Kalman

- Con lo que la distribución condicionada es:

$$\alpha_1 | Y_0 \sim N\left(a_{1|0}, P_{1|0}\right)$$

- Donde $a_{1|0}$ es la media de α_1 condicionada a la información disponible en el momento $t = 0$.

Interpretación del filtro de Kalman

- Si conociéramos la distribución de α_1 en $t = 0$, entonces los resultados anteriores son redundantes y las condiciones iniciales vendrán dadas en términos de $a_{1|0}$ y $P_{1|0}$. Para obtener la distribución de α_1 condicionada a Y_1, se hace lo siguiente:

$$\alpha_1 = a_{1|0} + \left(\alpha_1 - a_{1|0}\right)$$
$$Y_1 = z a_{1|0} + z\left(\alpha_1 - a_{1|0}\right) + e_1$$

Interpretación del filtro de Kalman

- El vector $(\alpha_1^{'}, Y_1)$ tiene una dsitribución normal con media $(a_{1|0}^{'} z a_{1|0})$ y una matriz de covarianzas:

$$\begin{bmatrix} P_{1|0} & P_{1|0} z \\ z^{'} P_{1|0} & z P_{1|0} z^{'} + \sigma^2 \end{bmatrix}$$

Interpretación del filtro de Kalman

- Aplicando el siguiente lema:

$$\begin{bmatrix} X \\ Y \end{bmatrix} \sim \left[\begin{bmatrix} \mu_X \\ \mu_Y \end{bmatrix}, \begin{bmatrix} \Sigma_{XX} & \Sigma_{XY} \\ \Sigma_{YX} & \Sigma_{YY} \end{bmatrix} \right]$$

$$X|Y \sim N\left(\mu_{X|Y}, \Sigma_{XX|Y}\right)$$

- Donde:

$$\mu_{X|Y} = \mu_X + \Sigma_{XX}\Sigma_{YY}^{-1}\left(Y - \mu_Y\right)$$

$$\Sigma_{XX|Y} = \Sigma_{XX} - \Sigma_{XY}\Sigma_{YY}^{-1}\Sigma_{YX}$$

Interpretación del filtro de Kalman

- Se ve que la distribución condicionaad de α_1 condicionada a Y_1 es:

$$\alpha_1 | Y_1 \sim N(a_1, P_1)$$

- Donde:

$$a_t = E\left(a_{t|Y_1, Y_2, \cdots, Y_t}\right) = E_t(\alpha_t)$$
$$P_t = \left\{[\alpha_t - E_{t-1}(\alpha_t)][\alpha_t - E_{t-1}(\alpha_t)]'\right\}$$

Interpretación del filtro de Kalman

- Hay que considerar la media de la distribución de α_t condicionada a la información disponible en el momento t, $E_t(\alpha_t)$. La media condicionada es una estimación de α_t de Error Cuadrático Medio Minimo, en el sentido de que cualquier otra estimación tiene una matriz de ECM que se puede escribir como:

$$V = P_t + A$$

Predicción: Filtro de Kalman

- Si se conocel los parámetris del modelo, la predicción de Y_{T+1} junto con su error cuadratico medio medio vienen datos directamente por las ecuaciones de predicción del filtro de Kalman.
- En el modelo Gaussiano, el filtro de Kalman proporciona a_T, el estimador de ECM mínimo de α_T basado en todas las observaciones. Además proporciona también la predicción hacia un periodod adelante y su ECMP:

$$a_{T+1|T} = Ca_T$$

$$Y_{T+1|T} = za_{T+1|T}$$

$$ECM\left(Y_{T+1|T}\right) = zP_{T+1|T}z^{'} + \sigma_e^2$$

Predicción: Filtro de Kalman

- Ahora, el problema general de obtener predicciones de valores futuros de Y_{T+h}, $h = 1, 2, \cdots$ basadas en la información de la muestra, es decir, conocidos a_T y P_T. En el modelo Gaussiano, la predicción óptima, en el sentido de minimizar el error cuadrático medio de predicción de Y_{T+h}, $Y_T(h)$, es la esperanza condicionada:

$$Y_T(h) = E\left(Y_{T+h|Y_T, Y_{T-1}, \cdots, Y_1}\right) = za_{T+h|T}$$

Predicción: Filtro de Kalman

- Donde:

$$a_{T+h|T} = E\left(a_{T+h|Y_T, Y_{T-1}, \cdots, Y_1}\right) = z a_{T+h|T}$$

- Y el error cuadrático medio de predicción viene dado por:

$$ECM\left(Y_{T+h|T}\right) = z^{'} P_{T+h|T} z + \sigma_e^2 \ \ (h = 1, 2, \cdots)$$

Predicción: Filtro de Kalman

- La mejor forma de obtener $a_{T+h|T}$ y $P_{T+h|T}$ es sustituir repetidamente las ecuaciones de predicción del filtro saltándose las de actualización (ya que no se tienen nuevas observaciones):

$$a_{T+h} = C^h \alpha_T + \sum i = 1^{h-1} C^{h-i} R \eta_{T+i} + R \eta_{T+h} \ (h = 2; 3, \cdots,)$$

$$E_t \left(\alpha_{T+h} \right) = a_{T+h|T} = C^h a_T$$

$$P_{T+h|T} = C^h P_t \left(C^{'} \right)^h + \sum_{i=1}^{h-1} C^i Q \left(C^{'} \right)^i$$

Referencias

ANEIROS, P. G. (2008). *Series de tiempo*. Universidad da Coruña, España.

GUERRERO. V. (2009). *Medición de la tendencia y el ciclo de una serie de tiempo económica desde una perspectiva estadística*. Instituto Tecnológico Autónomo de México, México.

HAMILTON, D. J. (1996). *Time Series Analysis*. Princenton University Press. USA.

MARILLA, C. M. et al. (2017). *Econometría y predicción*. Mc Grawll Hill, España.

Referencias

MINITAB. (2019). *Métodos y fórmulas para promedio móvil*. Soporte de Minitab 18. URL: https://support.minitab.com/esmx/minitab/18/help-and-how-to/modeling-statistics/time-series/howto/moving-average/methods-and-formulas/methods-and-formulas/. Consultado: 10/12/2021

PARRA, F. (2019). *Estadística y Machine Learning con R*. Libro electrónico. URL: https://bookdown.org/content/2274/portada.html. Consultado: 10/12/2021

VILLAREAL, F. (2016). *Introducción a los Modelos de Prónosticos*. Universidad Nacional del SUR, Argentina.