Modelos multivariantes: Vectores Autorregresivos (VAR)

Series de tiempo con Python

Econ. Morales Alberto Alexis Adonai

2026



Introducción

- Los modelos univariantes estudian la dinámica de una serie. Los multivariantes modelan conjuntamente varias series y sus relaciones temporales.
- En un VAR reducido, cada variable depende de sus rezagos y de los rezagos de las otras variables del sistema.
- La interdependencia predictiva motiva el análisis conjunto. Una interpretación causal estructural requiere restricciones de identificación adicionales.
- La cointegración permite representar combinaciones estacionarias de variables no estacionarias. Su existencia determina si un VEC de rango reducido es apropiado.

Introducción

- En el estudio de procesos multivariados, se necesita un marco para describir no solo las propiedades de la serie individual, sino también las posibles relaciones cruzadas entre los serie. Dos propósitos clave para analizar y modelar la serie de manera conjunta son (Box, et al. 1970):
  - Comprender las relaciones dinámicas a lo largo del tiempo entre las series.
  - Para mejorar la precisión de los pronósticos para series individuales mediante la utilización de la información disponible de la serie relacionada en los pronósticos de cada serie.

Cointegración

- En el marco I(1), las variables individuales son no estacionarias en niveles, pero sus primeras diferencias son I(0).
- Existe cointegración si una combinación lineal no trivial de los niveles es estacionaria:

$$X_t \sim I(1), \qquad \beta' X_t \sim I(0), \qquad \beta \neq 0.$$

- Los determinísticos de la combinación deben especificarse. Cointegración expresa una restricción de comovimiento de largo plazo y no demuestra causalidad estructural.

Cointegración

- Dos series no estacionarias pueden producir una regresión aparentemente significativa aunque no exista una relación estacionaria entre sus niveles.
- Una R cuadrada alta, un Durbin–Watson bajo y coeficientes aparentemente significativos pueden alertar sobre regresión espuria.
- Esos síntomas no constituyen una prueba de cointegración ni sus opuestos garantizan una regresión válida. Se requieren contrastes adecuados al orden de integración y a los determinísticos.

Cointegración

- Para variables I(1), la cointegración requiere que exista al menos una combinación de sus niveles que sea I(0).
- Que todas las series sean I(1) es una condición de partida del marco tratado, pero no garantiza cointegración.
- Un VAR estacionario de variables I(0) no necesita cointegración. Para variables I(1) sin cointegración puede utilizarse un VAR en diferencias.
- Cuando hay $0 < r < K$ relaciones cointegrantes, el VEC incorpora el ajuste de corto plazo compatible con ellas.

Cointegración

La estacionariedad débil requiere media constante, varianza finita y autocovarianzas que dependan del rezago, no de la fecha:

$$E(Y_t) = \mu, \qquad \text{Var}(Y_t) = \gamma(0) < \infty,$$
$$\text{Cov}(Y_t, Y_{t-h}) = \gamma(h).$$

La autocovarianza puede ser distinta de cero. Estacionariedad no equivale a ausencia de autocorrelación.

En el análisis I(1) se contrasta esta propiedad tanto en niveles como en primeras diferencias, con determinísticos apropiados.

Cointegración

Para pobrar las condiciones anteriores, se deben hacer uso de la siguientes pruebas:

1. Dickey-Fuller Aumentada (ADF).
2. Phillips-Perron.
3. KPSS.

Nota

Se recomienda consultar las notas de *Modelos estacionarios y no estacionarios* para entender los conceptos, estructura e interpretación de las pruebas.

Función de autocorrelación cruzada

- La correlación cruzada describe asociaciones a distintos rezagos. No es una prueba de cointegración.
- Para dos procesos conjuntamente estacionarios, una convención de covarianza cruzada es:

$$\gamma_{xy}(k) = E[(x_t - \mu_x)(y_{t+k} - \mu_y)].$$

- Con esta convención, $k > 0$ relaciona el valor actual de x con un valor posterior de y. El signo del rezago depende de la convención utilizada por el programa.

Función de autocorrelación cruzada

- Como función de k, $\gamma_{xy}(k)$ es llamda la función de covarianza cruzada entre x_t e y_t.
- La estandarización de $\gamma_{xy}(k)$ produce una función de correlación cruzada (FCC):

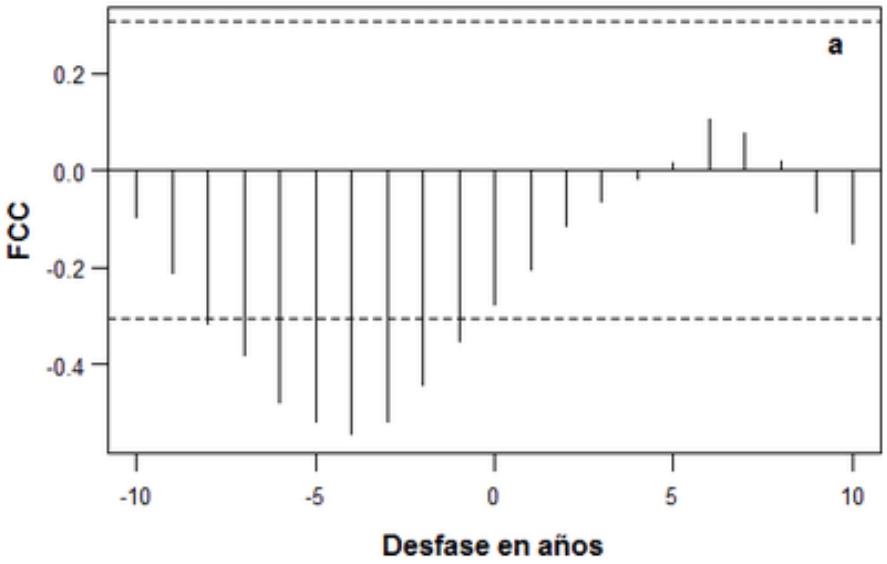
$$\rho_{xy}(k) = \gamma_{xy}(k)/\left(\sigma_x \sigma_y\right)$$

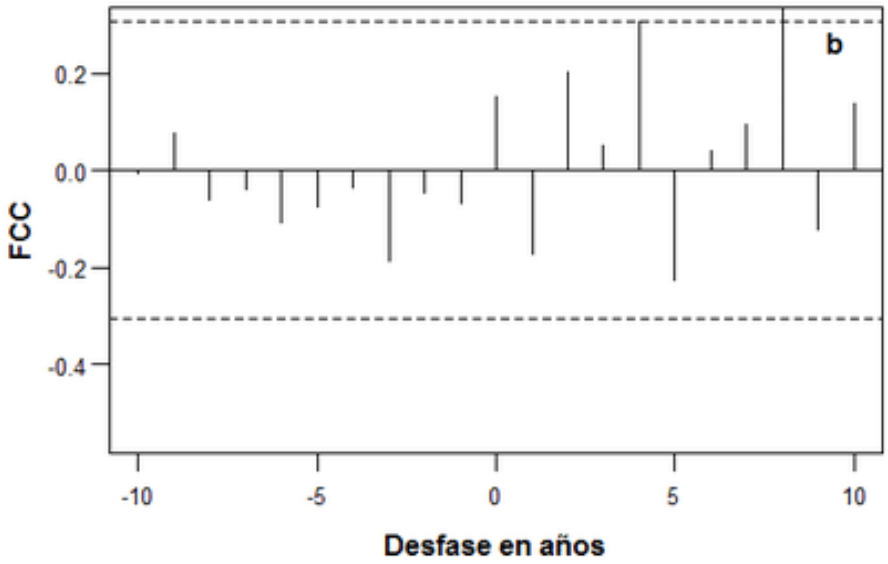
Para $k = 0, \pm 1, \pm 2, \cdots$, donde σ_x, σ_y son las desviaciones estándar de los procesos x_t e y_t.

Función de autocorrelación cruzada

- La FCC permite explorar asociación y adelantos o retrasos temporales bajo la convención elegida.
- Ni una caída exponencial ni una correlación cruzada pequeña demuestran cointegración.
- Las tendencias y la autocorrelación pueden distorsionar su lectura. Deben revisarse las transformaciones y el conjunto de información.
- La causalidad predictiva se contrasta mediante restricciones de un modelo dinámico. La causalidad estructural requiere identificación adicional.

Función de autocorrelación cruzada





Prueba de Engle y Granger

- Considere dos paseos aleatorios con innovaciones independientes, de varianzas positivas:

$$y_t = y_{t-1} + u_t, \qquad x_t = x_{t-1} + v_t,$$
$$E(u_t v_t) = 0.$$

- Para una constante b, la innovación de $y_t - bx_t$ es $u_t - bv_t$, con varianza $\sigma_u^2 + b^2\sigma_v^2 > 0$.
- Este ejemplo ilustra ausencia de cointegración. Para plantear cointegración se necesita una tendencia común que alguna combinación pueda cancelar.

Prueba de Engle y Granger

- Primero se examina si y_t y x_t son compatibles con I(1). Después se estima la relación en niveles:

$$y_t = b_0 + b_1 x_t + z_t.$$

- Se aplica una prueba de raíz unitaria a los residuos estimados $\widehat{z}_t$. La nula del contraste residual es ausencia de cointegración.
- Los valores críticos deben corresponder a Engle–Granger y a los determinísticos utilizados. No se usan sin ajuste los valores críticos ADF de una serie observada.

Prueba de Engle y Granger

- Si los niveles son I(1), se verifica que sus primeras diferencias sean compatibles con I(0).
- La regresión de cointegración se estima entre los niveles I(1), no entre sus diferencias estacionarias.
- Si el contraste residual no rechaza ausencia de cointegración, no se fuerza una relación de equilibrio. Puede estimarse un modelo en diferencias para la dinámica de corto plazo.
- Cointegración de orden I(1) significa que una combinación de los niveles tiene un orden de integración menor, aquí I(0).

Prueba de Engle y Granger

- La evidencia residual de cointegración exige rechazar la nula de raíz unitaria de $\widehat{z}_t$ con la distribución de referencia apropiada.
- Una R cuadrada alta o un Durbin–Watson cercano a dos no reemplazan ese contraste.
- La inferencia sobre la regresión de largo plazo y la corrección de error requiere considerar endogeneidad, dinámica y determinísticos.
- El procedimiento de una ecuación no identifica de forma general todas las relaciones de un sistema con varias tendencias comunes.

Prueba de Phillips-Ouliaris

- Phillips y Ouliaris (1990) desarrollan contrastes de ausencia de cointegración basados en residuos y correcciones de covarianza de largo plazo.
- En la implementación `urca::ca.po` se ofrecen los estadísticos P_u y P_z.
- P_z presenta invariancia respecto de la normalización de la relación. Los determinísticos y la estimación de largo plazo afectan la distribución de referencia.

Prueba de Phillips-Ouliaris

Para definir los objetos auxiliares, sea $z_t = (y_t, x_t')'$ de dimensión K, con x_t de dimensión $K-1$:

$$z_t = \widehat{\Pi} z_{t-1} + \widehat{\xi}_t. \tag{a.1}$$

La regresión incorpora o retira los determinísticos especificados. Esta matriz auxiliar $\widehat{\Pi}$ no debe confundirse automáticamente con la matriz de corrección de error del VEC que se desarrollará después.

Prueba de Phillips-Ouliaris

Prueba de la razón de varianza

El estadístico de la razón de la varianza es definido como:

$$\hat{P}_u = \frac{T\hat{\omega}_{11.2}}{T^{-1}\sum_{t=1}^{T}\hat{u}_t^2}$$

Donde $\hat{u}_t$ es el residual de la siguiente ecuación de regresión:

$$y_t = \hat{\beta}x_t + \hat{u}_t$$

Prueba de Phillips-Ouliaris

Prueba de la razón de varianza

Se particiona la matriz de covarianza de largo plazo de las innovaciones auxiliares:

$$\widehat{\Omega} = \begin{pmatrix} \widehat{\omega}_{11} & \widehat{\omega}_{12} \\ \widehat{\omega}_{21} & \widehat{\Omega}_{22} \end{pmatrix}.$$

La varianza de largo plazo residualizada es el complemento de Schur:

$$\widehat{\omega}_{11.2} = \widehat{\omega}_{11} - \widehat{\omega}_{12}\widehat{\Omega}_{22}^{-1}\widehat{\omega}_{21}.$$

Sus dimensiones deben ser compatibles y $\widehat{\Omega}_{22}$ invertible.

Prueba de Phillips-Ouliaris

Prueba de la razón de varianza

Una estimación HAC de covarianza de largo plazo toma la forma:

$$\widehat{\Omega} = \frac{1}{T}\sum_{t=1}^{T}\widehat{\xi}_t\widehat{\xi}_t' + \sum_{s=1}^{L} w_s\left(\widehat{C}_s + \widehat{C}_s'\right), \tag{a.2}$$

$$\widehat{C}_s = \frac{1}{T}\sum_{t=s+1}^{T}\widehat{\xi}_t\widehat{\xi}_{t-s}', \qquad w_s = 1 - \frac{s}{L+1}.$$

Los pesos anteriores corresponden al núcleo de Bartlett. El ancho de banda L debe documentarse.

Prueba de Phillips-Ouliaris

Prueba de la razón de varianza

El contraste de cointegración plantea:

$$H_0 : \text{ ausencia de cointegración,}$$
$$H_1 : \text{ existe al menos una relación cointegrante.}$$

Los valores grandes de P_u aportan evidencia contra H_0, comparados con sus valores críticos específicos. No se reemplaza esta hipótesis compuesta por una prueba ordinaria de una varianza igual a cero.

Prueba de Phillips-Ouliaris

Estadístico de traza multivariante

Se define:

$$\widehat{P}_z = T\,\mathrm{tr}(\widehat{\Omega} M_{zz}^{-1}), \qquad M_{zz} = \frac{1}{T}\sum_{t=1}^{T} \widetilde{z}_t \widetilde{z}_t'.$$

$\widetilde{z}_t$ representa el vector con el tratamiento determinístico del contraste. M_{zz} es una matriz de segundos momentos, no su inversa.
P_z no es el estadístico de traza de Johansen. Sus distribuciones y procedimientos son distintos.

Prueba de Phillips-Ouliaris

Los contrastes residuales anteriores permiten evaluar ausencia de cointegración, pero no sustituyen la estimación sistémica de su rango.

Para $K > 2$ pueden existir varias relaciones linealmente independientes. El procedimiento de Johansen estima su espacio y contrasta secuencialmente cuántas relaciones son compatibles con el sistema.

Prueba de Johansen

- Johansen utiliza autovalores asociados a un problema de correlación canónica entre niveles y diferencias residualizados.
- Ofrece contrastes de traza y máximo autovalor para el rango r de cointegración.
- r cuenta relaciones cointegrantes independientes. No cuenta diferencias ni órdenes de integración.
- Los valores críticos dependen del tratamiento de constantes y tendencias. La discrepancia entre ambos contrastes exige sensibilidad, no seleccionar el favorable.

Prueba de Johansen

Eigenvalor máximo

La nula de rango r se contrasta frente a rango $r+1$. Si ℓ_r es el máximo de log-verosimilitud bajo rango r:

$$LR_{\max}(r, r+1) = 2(\ell_{r+1} - \ell_r) = -n \log(1 - \widehat{\lambda}_{r+1}).$$

n es el tamaño efectivo de estimación. Se inicia en $r = 0$ y se avanza si se rechaza. $r+1$ significa una relación cointegrante adicional, no una diferencia adicional.

Prueba de Johansen

La prueba de la traza

Contrasta rango a lo sumo r frente a un rango mayor:

$$LR_{\text{traza}}(r) = -n \sum_{i=r+1}^{K} \log(1 - \widehat{\lambda}_i).$$

Se detiene el procedimiento secuencial en el primer no rechazo. Los valores críticos son no estándar y dependen de los determinísticos.
La expresión $-n \sum \log(1 - \widehat{\lambda}_i)/2$ es una diferencia de log-verosimilitudes, no el estadístico LR multiplicado por dos.

Cointegración

Conclusión

- Para variables I(0), un VAR estable en niveles no requiere cointegración.
- Para variables I(1) sin cointegración, un VAR en diferencias describe la dinámica sin imponer equilibrio de niveles.
- Para variables I(1) con $0 < r < K$, el VEC conserva las relaciones de niveles y el ajuste de corto plazo.
- Cointegración y causalidad predictiva son propiedades distintas. Ninguna de ellas identifica por sí sola causalidad estructural.

Modelo VAR(p)

Definición: un VAR reducido de orden p relaciona cada variable con p rezagos de todas las variables endógenas.

$$y_{1t} = c_1 + \sum_{j=1}^{p} a_{11,j} y_{1,t-j} + \sum_{j=1}^{p} a_{12,j} y_{2,t-j} + u_{1t},$$

$$y_{2t} = c_2 + \sum_{j=1}^{p} a_{21,j} y_{1,t-j} + \sum_{j=1}^{p} a_{22,j} y_{2,t-j} + u_{2t}.$$

Los errores reducidos pueden estar correlacionados contemporáneamente. La identificación de un VAR estructural añade restricciones.

Modelo VAR

- Para entender la estructura del modelo VAR, se pondrá un ejemplo con dos variables: Y_t y Z_t que están mutuamente relacionadas, por lo tanto el modelo se especifica de la siguiente manera.

$$Y_t = \gamma_{10} - b_{12} Z_t + \gamma_{11} Y_{t-1} + \gamma_{12} Z_{t-1} + W_{yt}$$
$$Z_t = \gamma_{20} - b_{21} Y_t + \gamma_{21} Y_{t-1} + \gamma_{22} Z_{t-1} + W_{zt}$$

Se asume que:

- Y_t y Z_t son estacionarias.
- Las innovaciones W_{yt} y W_{zt} tienen media cero y una matriz de covarianza especificada. Su interpretación como choques estructurales exige identificación.

Lo anterior constituye una forma estructural bivariada de orden 1. Su identificación requiere restricciones adicionales.

Modelo VAR

En un modelo estructural se especifican restricciones para interpretar las innovaciones como choques económicos.

1. Las innovaciones deben ser impredecibles a partir de la información pasada utilizada en el modelo.
2. Una identificación ortogonal impone covarianzas contemporáneas nulas entre choques estructurales, no necesariamente entre errores reducidos.
3. La exogeneidad e interpretación económica requieren argumentos adicionales. Un choque que mueve una variable endógena puede estar correlacionado con ella contemporáneamente.

Modelo VAR

Bajo las restricciones estructurales que identifican el sistema, los coeficientes tienen la siguiente lectura condicional:

- $-b_{12}$ es el **efecto contemporáneo** de Z_t en Y_t; $-b_{21}$ es el **efecto contemporáneo** de Y_t en Z_t.
- γ_{11} es el efecto de Y_{t-1} en Y_t; γ_{12} es el efecto de Z_{t-1} en Z_t y así sucesivamente.
- El modelo inicial, no se puede estimar po MCO, ya que causa sesgo de ecuaciones simultáneas.

Modelo VAR

El modelo estructural se puede escribir como:

$$\begin{bmatrix} 1 & b_{12} \\ b_{21} & 1 \end{bmatrix} \begin{bmatrix} Y_t \\ Z_t \end{bmatrix} = \begin{bmatrix} \gamma_{10} \\ \gamma_{20} \end{bmatrix} + \begin{bmatrix} \gamma_{11} & \gamma_{12} \\ \gamma_{21} & \gamma_{22} \end{bmatrix} \begin{bmatrix} Y_{t-1} \\ Z_{t-1} \end{bmatrix} + \begin{bmatrix} W_{yt} \\ W_{zt} \end{bmatrix}$$

$$B_0 X_t = \Gamma_0 + \Gamma_1 X_{t-1} + W_t \tag{1}$$

Modelo VAR

De la anterior ecuación (1), se definen los siguuientes vectores y matrices:

$$B_0 = \begin{bmatrix} 1 & b_{12} \\ b_{21} & 1 \end{bmatrix}, X_t = \begin{bmatrix} Y_t \\ Z_t \end{bmatrix}, \Gamma_0 = \begin{bmatrix} \gamma_{10} \\ \gamma_{20} \end{bmatrix},$$
$$\Gamma_1 = \begin{bmatrix} \gamma_{11} & \gamma_{12} \\ \gamma_{21} & \gamma_{22} \end{bmatrix}, W_t = \begin{bmatrix} W_{yt} \\ W_{zt} \end{bmatrix}$$

Y la varianza del proceso es la siguiente:

$$Var\left(W_t\right) = \Sigma_w = \begin{bmatrix} \sigma_Y^2 & 0 \\ 0 & \sigma_Z^2 \end{bmatrix}$$

Modelo VAR

De la ecuación (1), se debe *eliminar* B_0, para ello se aplica una propiedad neutra de división. Sin embargo, en matrices no hay la división, por lo que se invierte el proceso de B_0 dando:

$$B_0^{-1} = \frac{1}{1 - b_{12}b_{21}} \begin{bmatrix} 1 & -b_{12} \\ -b_{21} & 1 \end{bmatrix}$$

Ahora, B_0^{-1} multiplicado en (1) se obtiene:

$$X_t = A_0 + A_1 X_{t-1} + u_t \tag{2}$$

Modelo VAR

Al premultiplicar por B_0^{-1}:

$$A_0 = B_0^{-1}\Gamma_0 = (a_{10}, a_{20})',$$
$$A_1 = B_0^{-1}\Gamma_1 = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix},$$
$$u_t = B_0^{-1} W_t = (u_{1t}, u_{2t})'.$$

Por ejemplo:

$$a_{10} = \frac{\gamma_{10} - b_{12}\gamma_{20}}{1 - b_{12}b_{21}}, \qquad a_{11} = \frac{\gamma_{11} - b_{12}\gamma_{21}}{1 - b_{12}b_{21}}.$$

Los parámetros reducidos pueden estimarse por MCO bajo los supuestos del modelo dinámico. Identificar B_0 requiere restricciones adicionales.

Modelo VAR

El modelo VAR en forma reducida se puede escribir también de la siguiente manera:

$$Y_t = a_{10} + a_{11} Y_{t-1} + a_{12} Z_{t-1} + u_{1t}$$
$$Z_t = a_{20} + a_{21} Y_{t-1} + a_{22} Z_{t-1} + u_{2t}$$

Donde:

$$u_{1t} = (W_{yt} - b_{12} W_{zt}) / (1 - b_{12} b_{21})$$
$$u_{2t} = (W_{zt} - b_{21} W_{yt}) / (1 - b_{12} b_{21})$$

Modelo VAR

Bajo innovaciones estructurales de media cero, covarianza constante y ortogonalidad contemporánea, los errores reducidos tienen:

$$\sigma_1^2 = Var\left(u_{1t}\right) = \left(\sigma_{yt}^2 + b_{12}^2\sigma_{zt}^2\right) / \left(1 - b_{12}b_{21}\right)^2$$
$$\sigma_2^2 = Var\left(u_{2t}\right) = \left(\sigma_{zt}^2 + b_{21}^2\sigma_{yt}^2\right) / \left(1 - b_{12}b_{21}\right)^2$$

Además:

$$\Sigma_u = \begin{bmatrix} Var(u_{1t}) & Cov(u_{1t}, u_{2t}) \\ Cov(u_{1t}, u_{2t}) & Var(u_{2t}) \end{bmatrix} = \begin{bmatrix} \sigma_1^2 & \sigma_{12} \\ \sigma_{12} & \sigma_2^2 \end{bmatrix}$$

Estabilidad del modelo VAR

Para el VAR(1), sustituir recursivamente produce:

$$X_t = \left(\sum_{i=0}^{n} A_1^i\right) A_0 + \sum_{i=0}^{n} A_1^i u_{t-i} + A_1^{n+1} X_{t-n-1}. \tag{2.1}$$

Si el radio espectral $\rho(A_1) < 1$, entonces $A_1^n \to 0$ y

$$\sum_{i=0}^{\infty} A_1^i = (I - A_1)^{-1}.$$

Que $I - A_1$ sea invertible no basta para garantizar estabilidad.

Estabilidad del modelo VAR

- Para los modelos bivariados la estabilidad depende de lo que pasa conjuntamente en las dos series. La condición de estabilidad es que las raices del determinate $det(I - A_1 z)$ (que se puede escribir como $(1 - a_{11}z)(1 - a_{22}z) - (a_{12}a_{21}z^2)$) estén por **fuera** del circulo unitario.
- Otra forma de analizar la estabilidad es mediante los términos de autovalores. Si se tiene $A_1 * X = \lambda X$ con $X \neq 0$ se dice que λ es un autovalor (eigenvalue) de A_1. Estos pueden ser números reales o complejos. La condición de estabilidad es que los autovalores de A_1 sean menores en valor absoluto a 1 o también **dentro** del circulo unitario.

Estabilidad del modelo VAR

Si el VAR(1) es estable:

$$\mu = (I - A_1)^{-1} A_0, \qquad X_t = \mu + \sum_{i=0}^{\infty} A_1^i u_{t-i}.$$

Su covarianza incondicional satisface:

$$\Gamma(0) = \sum_{i=0}^{\infty} A_1^i \Sigma_u (A_1^i)' = A_1 \Gamma(0) A_1' + \Sigma_u.$$

Esta ecuación de Lyapunov reemplaza una aplicación incorrecta de la fórmula escalar de varianza a una matriz general.

Estabilidad del modelo VAR

Para $h \geq 0$ y un VAR(1) estable:

$$\Gamma(h) = E[(X_t - \mu)(X_{t-h} - \mu)'],$$

$$\Gamma(h) = \sum_{i=0}^{\infty} A_1^{h+i} \Sigma_u (A_1^i)' = A_1^h \Gamma(0),$$

$$\Gamma(-h) = \Gamma(h)'.$$

Las innovaciones de fechas distintas son ortogonales bajo el supuesto de ruido blanco. La estabilidad y los momentos finitos permiten construir esta solución estacionaria.

Estabilidad del modelo VAR

Con operador de rezagos:

$$(1 - a_{11}L)Y_t = a_{10} + a_{12}LZ_t + u_{1t},$$
$$(1 - a_{22}L)Z_t = a_{20} + a_{21}LY_t + u_{2t}.$$

Si $D(L) = (1 - a_{11}L)(1 - a_{22}L) - a_{12}a_{21}L^2$, entonces:

$$D(L)Y_t = a_{10}(1 - a_{22}) + a_{12}a_{20} + (1 - a_{22}L)u_{1t} + a_{12}Lu_{2t},$$
$$D(L)Z_t = a_{20}(1 - a_{11}) + a_{21}a_{10} + (1 - a_{11}L)u_{2t} + a_{21}Lu_{1t}.$$

Estabilidad del modelo VAR

- Se debe notar que en ambas ecuaciones se tiene el mismo denominador característico, con lo que se requiere que las raíces del polinomio $(1 - a_{11}L)(1 - a_{22}L) - a_{12}a_{21}L^2$ esten por fuera del círculo unitario.

Generalización VAR(p)

El modelo VAR puede ser expresado para k variables y p rezagos:

$$X_t = A_0 + A_1 X_{t-1} + A_2 X_{t-2} + \cdots + A_p X_{t-p} + u_t$$

Donde:

- X_t es un vector de $(K \times 1)$.
- A_0 es un vector de interceptos de dimensión $(K \times 1)$.
- $A_i,\ i = 1, 2, \cdots, p$ son matrices de pendientes de dimensión $(K \times K)$.
- u_t es un vector de residuales $(K \times 1)$.

Entonces hay $K + K^2 p$ coeficientes de media en el sistema, además de $K(K+1)/2$ parámetros libres de covarianza.

Generalización VAR(p)

El polinomio de rezagos se define como:

$$A(L) = I_K - A_1 L - \cdots - A_p L^p.$$

La forma reducida implica:

$$A(L)X_t = A_0 + u_t.$$

Si existe una media estacionaria $\mu = (I_K - \sum_{j=1}^{p} A_j)^{-1} A_0$:

$$A(L)(X_t - \mu) = u_t.$$

La constante A_0 no es, en general, la media μ.

Generalización VAR(p)

La estabilidad del modelo VAR depende de las raíces del polinomio del determinante $det(A(z)) = det(I_k - A_1 L - A_2 L^2 - \cdots - A_p L^p)$ que tienen que estar por **fuera** del círculo unitario.

Para el modelo general de dimensión K y p razagos, se puede representar el modelo VAR(p) como un VAR(1):

$$\mathcal{X}_t = \nu + A\mathcal{X}_{t-1} + U_t$$

Generalización VAR(p)

Donde:

$$\mathcal{X}_t = \begin{bmatrix} X_t \\ \vdots \\ X_{t-p+1} \end{bmatrix}, \nu = \begin{bmatrix} A_0 \\ \vdots \\ 0 \end{bmatrix}, A \equiv \begin{bmatrix} A_1 & A_2 & \cdots & A_{p-1} & A_p \\ I_k & 0 & \cdots & 0 & 0 \\ 0 & I_k & \cdots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdots & I_k & 0 \end{bmatrix}$$

$$U_t = \begin{bmatrix} u_t \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Generalización VAR(p)

En el caso anterior:

- $\mathcal{X}_t$ es un vector de dimensión $Kp \times 1$.
- ν es un vector $Kp \times 1$.
- A es una matriz $Kp \times Kp$.
- U_t es un vector $Kp \times 1$.

La restricción de estabilidad para un modelo VAR(p) es equivalente a $det(I_{Kp} - Az) \neq 0$, todas las raíces se encontrarán por fuera del círculo unitario.

Generalización VAR(p)

Bajo estabilidad, la forma compañera admite:

$$\mathcal{X}_t = m + \sum_{i=0}^{\infty} A^i U_{t-i}, \qquad m = (I_{Kp} - A)^{-1}\nu.$$

$\mathcal{X}_t$ es el vector que apila $X_t, \ldots, X_{t-p+1}$. El índice del error es $t - i$ y cambia dentro de la suma.

Generalización VAR(p)

La matriz $J = [I_K \;\; 0_{K\times K(p-1)}]$ recupera las variables originales:

$$X_t = J\mathcal{X}_t = \mu + \sum_{i=0}^{\infty} \Phi_i u_{t-i},$$

$$\mu = Jm = (I_K - A_1 - \cdots - A_p)^{-1} A_0,$$

$$\Phi_i = JA^i J', \qquad \Phi_0 = I_K,$$

$$\Phi_i = \sum_{j=1}^{\min(p,i)} A_j \Phi_{i-j}, \quad i \geq 1.$$

Las matrices Φ_i describen la propagación de innovaciones reducidas.

Ejemplo: VAR(1)

Retomando el siguiente ejercicio (LÜTKEPOHL, 2005, p.17):

$$X_t = A_0 + \begin{bmatrix} 0.5 & 0 & 0 \\ 0.1 & 0.1 & 0.3 \\ 0 & 0.2 & 0.3 \end{bmatrix} X_{t-1} + u_t$$

Se calcula el determinante:

$$det\left(\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix} - \begin{bmatrix} 0.5 & 0 & 0 \\ 0.1 & 0.1 & 0.3 \\ 0 & 0.2 & 0.3 \end{bmatrix} z \right)$$

Ejemplo: VAR(1)

$$det \begin{bmatrix} 1-0.5z & 0 & 0 \\ -0.1z & 1-0.1z & -0.3z \\ 0 & -0.2z & 1-0.3z \end{bmatrix}$$
$$= (1-0.5z)\left(1-0.4z-0.03z^2\right)$$

Las raíces son: $z_1 = 2$, $z_2 = 2.1525$ y $z_3 = -15.4858$. Lo cual en valores absolutos son mayores que 1. Entonces el modelo VAR es estable.

Ejemplo: VAR(2)

Retomando el siguiente ejercicio (LÜTKEPOHL, 2005, p.17):

$$X_t = A_0 + \begin{bmatrix} 0.5 & 0.1 \\ 0.4 & 0.5 \end{bmatrix} X_{t-1} + \begin{bmatrix} 0 & 0 \\ 0.25 & 0 \end{bmatrix} X_{t-2} + u_t$$

Se realiza el proceso de calcular la determinante:

$$det\left(\begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} - \begin{bmatrix} 0.5 & 0.1 \\ 0.4 & 0.5 \end{bmatrix} z - \begin{bmatrix} 0 & 0 \\ 0.25 & 0 \end{bmatrix} z^2 \right)$$
$$= 1 - z + 0.21z^2 - 0.025z^3$$

Ejemplo: VAR(2)

Las raíces del determinante anterior, calculadas numéricamente, son:

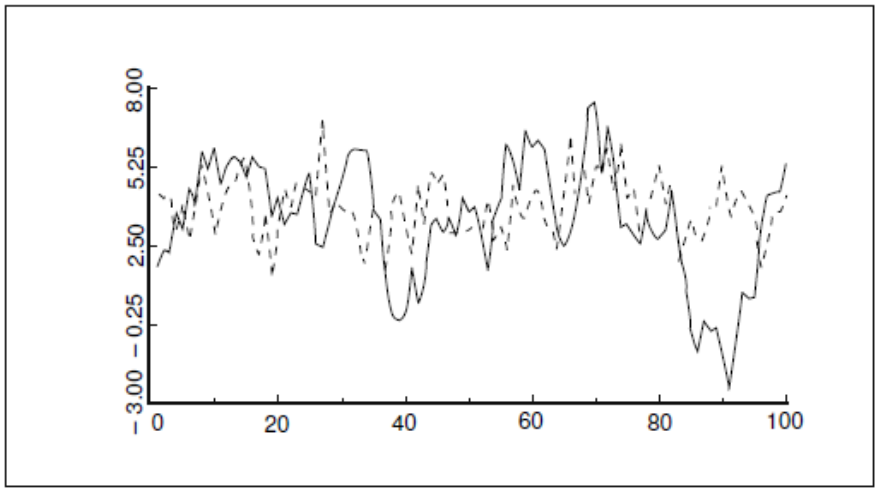
$$z_1 \simeq 1.299957,$$
$$z_2 \simeq 3.550022 + 4.262346i, \qquad z_3 \simeq 3.550022 - 4.262346i.$$

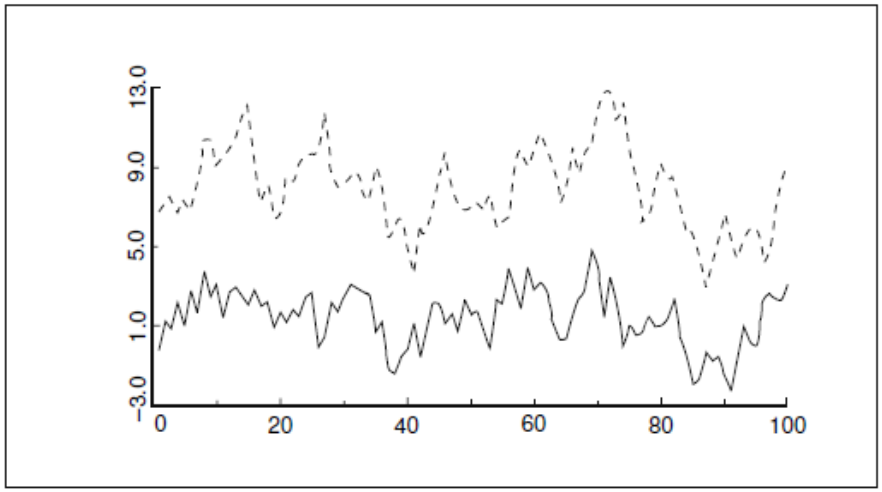
Su módulo complejo es:

$$|z_2| = |z_3| = \sqrt{3.550022^2 + 4.262346^2} \simeq 5.5472.$$

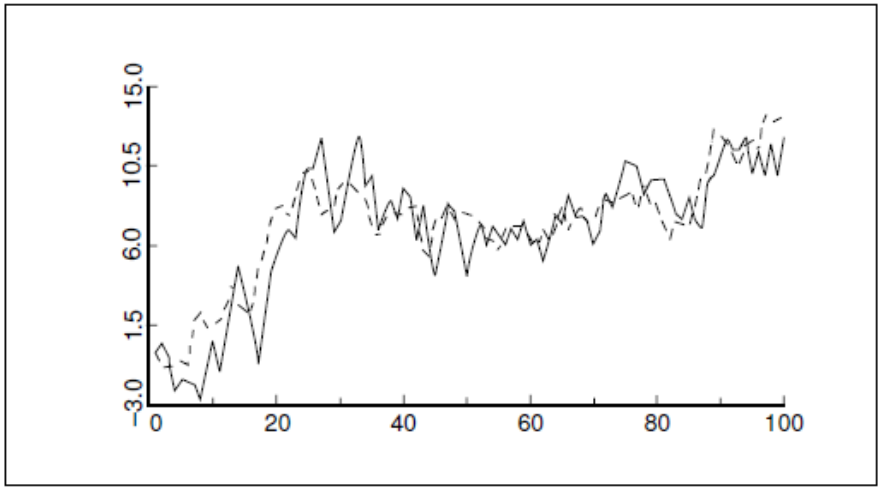
Todas las raíces finitas tienen módulo mayor que uno. El proceso es estable.

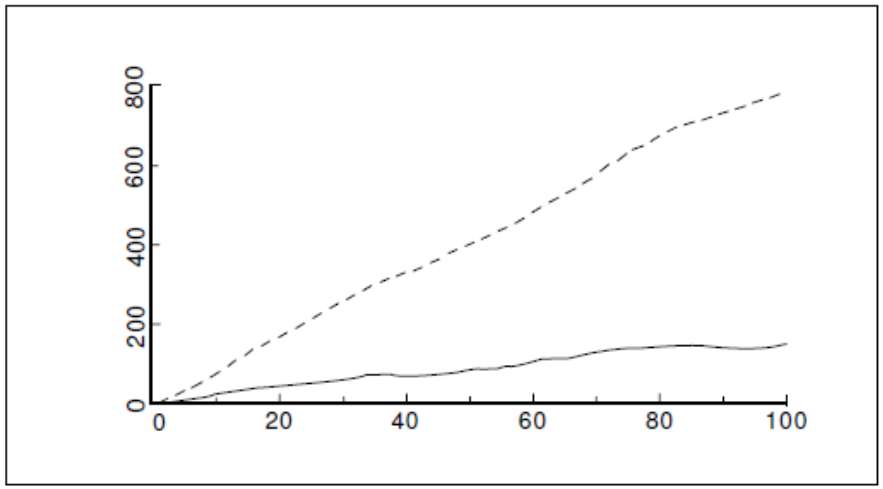
Visualización VAR estable





Visualización VAR no estable





Análisis de causalidad

- La causalidad de Granger evalúa si los rezagos de una variable agregan información para predecir otra, dado el resto del sistema.
- Se contrasta mediante restricciones conjuntas de coeficientes, no a partir de la significancia visual de una función impulso-respuesta.
- Su nula es ausencia de causalidad predictiva en la dirección examinada.
- El resultado depende de variables, rezagos y conjunto de información. No identifica por sí solo un efecto estructural.

Causalidad de Granger

Formalmente, para la media condicional, y no causa a z en sentido de Granger si:

$$E(z_{t+1} \mid \mathcal{F}_t) = E(z_{t+1} \mid \mathcal{F}_t^{(-y)}).$$

$\mathcal{F}_t$ contiene la información pasada del sistema y $\mathcal{F}_t^{(-y)}$ excluye la historia de y.

En un VAR lineal correctamente especificado, la exclusión se traduce en que todos los coeficientes de los rezagos de y en la ecuación de z sean cero.

Causalidad de Granger

- Si todas las variables son estacionarias, el contraste de Granger es:

$$H_0 : a_{21}(1) = a_{21}(2) = \cdots = a_{21}(p) = 0$$

- Más a detalle, supongamos el siguiente proceso:

$$\begin{bmatrix} y_t \\ z_t \end{bmatrix} = \begin{bmatrix} a_{10} \\ a_{20} \end{bmatrix} + \sum_{i=1}^{p} \begin{bmatrix} a_{11}, i & a_{12}, i \\ a_{21}, i & a_{22}, i \end{bmatrix} \begin{bmatrix} y_{t-i} \\ z_{t-i} \end{bmatrix} + \begin{bmatrix} u_{1t} \\ u_{2t} \end{bmatrix}$$

- Entonces y_t no causará a z_t en el sentido de Granger si y solo si $a_{21}, i = 0$ para $i = 1, 2, \cdots, p$. En otros términos, los rezagos de y_t no tendrán efecto en la ecuación z_t

Causalidad de Granger

- La generalización para **n** variables, se dirá que la variable j no causa a i en el sentido de Granger si todos los coeficientes $A_{ij}(L)$ son 0.
- La causalidad o no de Granger, no implica causalidad o no contemporánea y viceversa.

Pronóstico del modelo VAR

- Un punto central de los modelos VAR es el de pronosticar pasos adelantados o valores *futuros*.
- El pronóstico en un horizonte **h** se definirá de la siguiente manera:

$$E_t\left(X_{t+h}\right) = E\left(X_{t+h}|\Omega_t\right)$$

Donde Ω_t es toda la información disponible hasta el momento t.

- Entonces, el prónostico se construye en forma recursiva partiendo de la siguiente estructura:

$$E_t\left(X_{t+h}\right) = A_0 + A_1 E_t\left(X_{t+h-1}\right) + \cdots + A_p E_t\left(X_{t+h-p}\right)$$

Pronóstico del modelo VAR

El error de pronóstico a horizonte finito es:

$$X_{t+h} - E_t(X_{t+h}) = \sum_{i=0}^{h-1} \Phi_i u_{t+h-i}.$$

Tratando los parámetros como conocidos y con innovaciones de covarianza constante:

$$\Sigma_y(h) = \sum_{i=0}^{h-1} \Phi_i \Sigma_u \Phi_i',$$

$$\Sigma_y(h) = \Sigma_y(h-1) + \Phi_{h-1} \Sigma_u \Phi_{h-1}'.$$

La suma hasta infinito es el límite de esta covarianza solo si el VAR es estable y existen los momentos necesarios.

Pronóstico del modelo VAR

Otra forma de entender el pronóstico del modelo VAR es mediante las siguientes ecuaciones:

$$E_t(Y_{t+1}) = \nu + A_1 Y_t + \cdots + A_p Y_{t-p+1}$$
$$E_t(Y_{t+2}) = \nu + A_1 E(Y_{t+1}) + A_2 Y_t + \cdots + A_p Y_{t-p+2}$$
$$\vdots$$

Pronóstico del modelo VAR: Ejemplo

- Se tiene un modelo VAR(1) con $A_0 = (0, 2, 1)'$ y $X_t = (-6, 3, 5)'$:

$$E_t(X_{t+1}) = \begin{bmatrix} 0 \\ 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0.5 & 0 & 0 \\ 0.1 & 0.1 & 0.3 \\ 0 & 0.2 & 0.3 \end{bmatrix} \begin{bmatrix} -6 \\ 3 \\ 5 \end{bmatrix} = \begin{bmatrix} -3 \\ 3.2 \\ 3.1 \end{bmatrix}$$

$$E_t(X_{t+2}) = \begin{bmatrix} 0 \\ 2 \\ 1 \end{bmatrix} + \begin{bmatrix} 0.5 & 0 & 0 \\ 0.1 & 0.1 & 0.3 \\ 0 & 0.2 & 0.3 \end{bmatrix} \begin{bmatrix} -3 \\ 3.2 \\ 3.1 \end{bmatrix} = \begin{bmatrix} -1.5 \\ 2.95 \\ 2.57 \end{bmatrix}$$

Pronóstico del modelo VAR: Ejemplo

Se asume que:

$$\Sigma_u = \begin{bmatrix} 2.25 & 0 & 0 \\ 0 & 1.0 & 0.5 \\ 0 & 0.5 & 0.74 \end{bmatrix}$$

Además se tiene que $\Sigma_y(1) = \Sigma_u$:

$$\Sigma_y(2) = \Sigma_u + \Phi_1 \Sigma_u \Phi_1^{'} = \begin{bmatrix} 2.813 & 0.113 & 0 \\ 0.113 & 1.129 & 0.632 \\ 0 & 0.632 & 0.907 \end{bmatrix}$$

Pronóstico del modelo VAR: Ejemplo

$$\Sigma_y(3) = \Sigma_y(2) + \Phi_2 \Sigma_u \Phi_2' = \begin{bmatrix} 2.953 & 0.146 & 0.011 \\ 0.146 & 1.161 & 0.663 \\ 0.011 & 0.663 & 0.943 \end{bmatrix}$$

Nota

Los coeficientes Φ son aquellos que provienen de la invertivilidad de VAR como MA.

Pronóstico del modelo VAR: Ejemplo 2

Con $c = (0.02, 0.03)'$, $X_t = (0.06, 0.03)'$ y $X_{t-1} = (0.055, 0.03)'$, se utilizan las matrices del ejemplo VAR(2).

Primero se calcula:

$$A_1 X_t + A_2 X_{t-1} = \begin{pmatrix} 0.033 \\ 0.05275 \end{pmatrix}.$$

Los pronósticos recursivos son:

$$\widehat{X}_t(1) = c + A_1 X_t + A_2 X_{t-1} = \begin{pmatrix} 0.053 \\ 0.08275 \end{pmatrix},$$

$$\widehat{X}_t(2) = c + A_1 \widehat{X}_t(1) + A_2 X_t = \begin{pmatrix} 0.054775 \\ 0.107575 \end{pmatrix}.$$

Funciones de impulso-respuesta

- Una función impulso-respuesta describe la diferencia entre trayectorias con y sin una innovación inicial, manteniendo iguales las condiciones posteriores del experimento.
- Las demás variables pueden responder dinámicamente. No se mantienen fijas durante todos los horizontes.
- Se deben declarar el choque, su magnitud, la identificación y las unidades de la respuesta.
- Una innovación estadística no adquiere interpretación causal estructural solamente por recibir el nombre de una variable.

Funciones de impulso-respuesta

En secciones pasadas, se considero que el modelo VAR(1) puede ser representado de la siguiente manera:

$$Y_t = \nu + AY_{t-1} + U_t$$

Del proceso VAR(p), la estabilidad del proceso se puede ver como la siguiente estructura:

$$Y_t = \mu + \sum_{i=0}^{\infty} A^i U_{t-i} \qquad \text{(A)}$$

La anteriro forma del proceso es llamado **Medias móviles** (MA), donde Y_t es expresado en términos del pasado y presente del vector de innovaciones aleatorias U_t y del término de su media μ. Esta representación puede ser usada para determinar las funciones de impulso respuesta.

Funciones de impulso-respuesta

En un VAR(1) estructural identificado:

$$u_t = B_0^{-1} W_t, \qquad X_t = \mu + \sum_{i=0}^{\infty} \Theta_i W_{t-i},$$

con

$$\Theta_i = A_1^i B_0^{-1}.$$

En una identificación ortogonal por Cholesky, $\Sigma_u = PP'$ y se reemplaza B_0^{-1} por la matriz de impacto P, con choques normalizados a varianza uno.

Funciones de impulso-respuesta

- El elemento (j, k) de Θ_i es la respuesta de la variable j al choque k después de i periodos:

$$\theta_{jk,i} = \frac{\partial X_{j,t+i}}{\partial W_{k,t}}.$$

- Θ_0 corresponde al impacto contemporáneo. Θ_i representa la respuesta en el horizonte i, no su suma acumulada.
- La respuesta acumulada hasta h es $\sum_{i=0}^{h} \Theta_i$. Hay K^2 respuestas por horizonte.

Funciones de impulso-respuesta

La respuesta acumulada hasta h y su límite, si existe, son:

$$\sum_{i=0}^{h} \theta_{jk,i}, \qquad \sum_{i=0}^{\infty} \theta_{jk,i}.$$

En un VAR estable con variables estacionarias, la respuesta por horizonte se disipa y sus cuadrados son sumables:

$$\lim_{i \to \infty} \theta_{jk,i} = 0, \qquad \sum_{i=0}^{\infty} \theta_{jk,i}^2 < \infty.$$

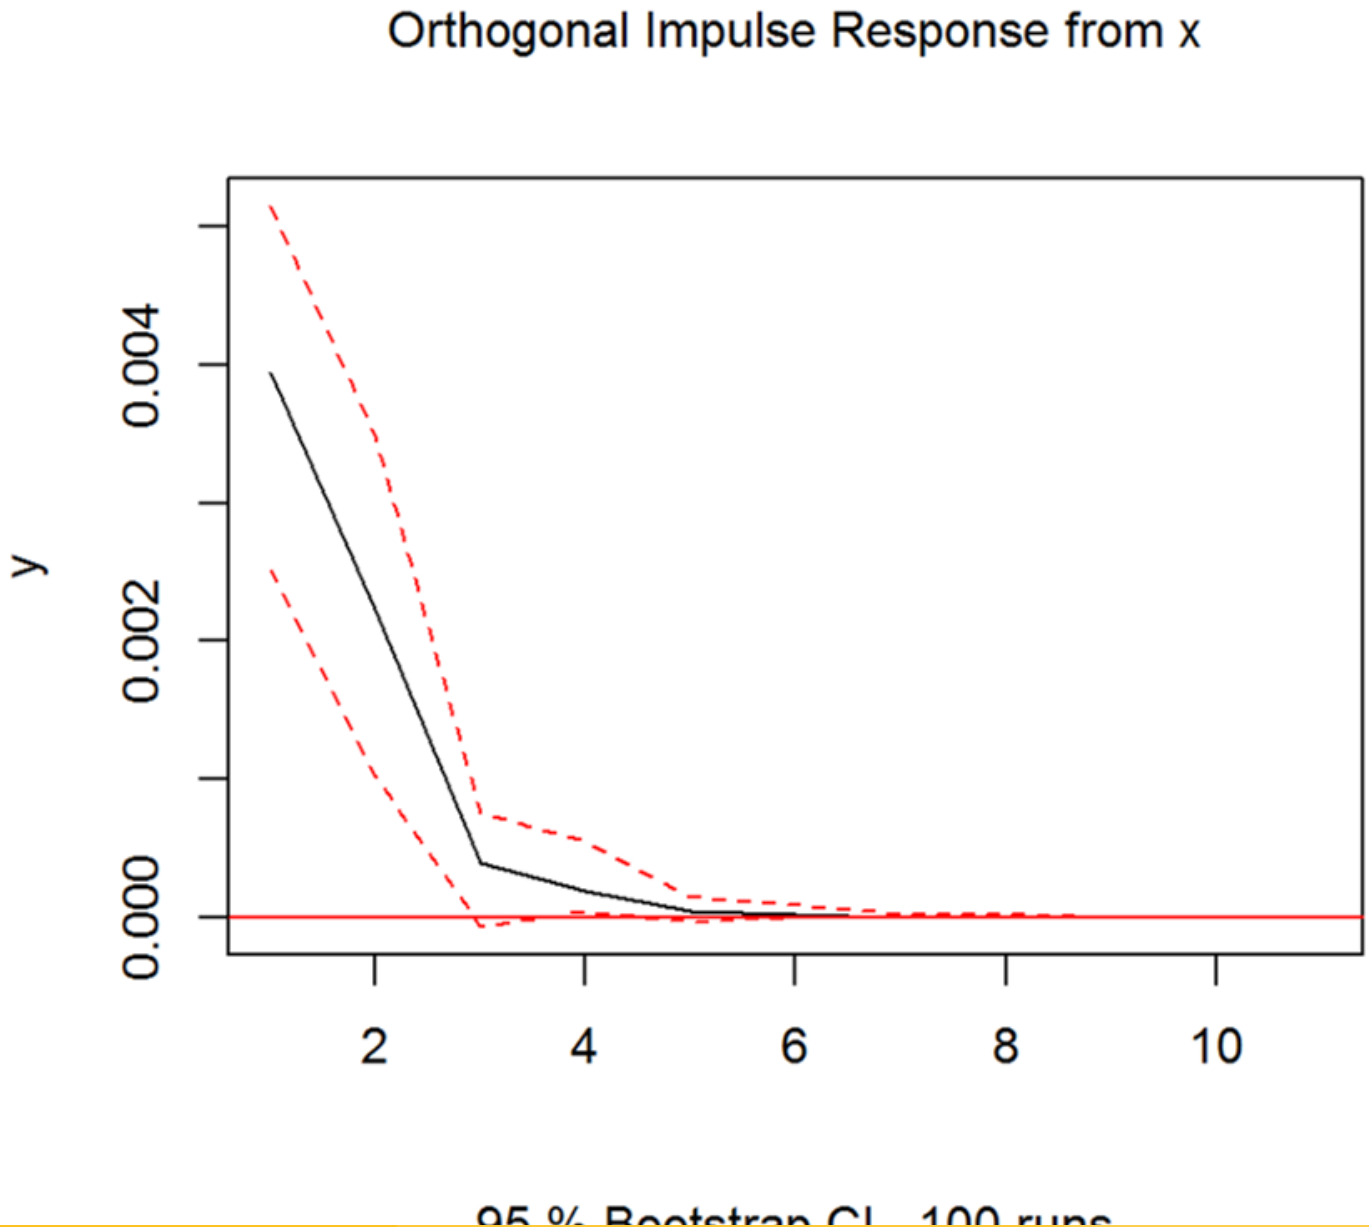
Que la respuesta por horizonte tienda a cero no exige que la suma acumulada sea cero. La acumulación también depende de si se representan niveles o crecimientos.

Funciones de impulso-respuesta

- Para modelos generales, se puede usar el modelo extendido. Entonces, las funciones de impulso-respuesta quedan definidas como:

$$\Theta_0 = B_0^{-1}$$
$$\Theta_1 = JAJ' B_0^{-1}$$
$$\Theta_2 = JA^2 J' B_0^{-1}$$
$$\vdots$$
$$\Theta_i = JA^i J' B_0^{-1}$$

Funciones de impulso-respuesta



¿Cómo identificar el orden de VAR(p)?

- AIC, BIC y HQIC comparan ajuste y penalización por dimensión. BIC también se conoce como criterio de Schwarz.
- Se elige el mínimo de un criterio documentado sobre muestras de comparación compatibles. No se cuentan como criterios distintos BIC y Schwarz.
- La elección requiere revisar autocorrelación residual, parsimonia y sensibilidad. La significancia individual de la mayoría de rezagos no define el orden óptimo.
- Para Johansen se selecciona p del VAR en niveles. El VEC equivalente contiene $p-1$ rezagos de diferencias.

Proceso de estimación de VAR(p)

- Una vez elegido el orden adecuado, conforme los estadísticos anteriores, se realiza la estimación.
- Para realizar la estimación, los coeficientes de un proceso VAR(p) pueden ser estimados mediante mínimos cuadrados aplicados separadamente a cada ecuación.
- Entonces conforme el número de rezagos aumente, o entre mayor (p) mayor será el número de coeficientes para cada ecuación.

Validación de VAR(p)

La validación distingue preguntas diferentes:

- Portmanteau o LM multivariado: autocorrelación residual.
- Normalidad marginal y conjunta: forma de la distribución.
- ARCH marginal y multivariado: dependencia en segundos momentos.
- Autovalores de la compañera: estabilidad dinámica del modelo estimado.
- Contrastes de constancia: posibles cambios de parámetros. CUSUM univariado no certifica constancia de todo el sistema ni de un espacio cointegrante.

CUSUM

CUSUM utiliza residuos recursivos w_r, construidos con estimaciones que se actualizan al avanzar la muestra. Una normalización usual es:

$$W_t = \frac{1}{\widehat{\sigma}\sqrt{T-m}} \sum_{r=m+1}^{t} w_r.$$

m es el número de parámetros de la regresión. Bajo su nula y condiciones de validez, se contrasta constancia mediante bandas específicas del proceso.

No se sustituyen automáticamente w_r por residuos MCO ordinarios de toda la muestra. La aplicación a ecuaciones dinámicas o a un VEC requiere justificar la distribución del contraste.

CUSUM al cuadrado

La suma acumulada normalizada de cuadrados de residuos recursivos es:

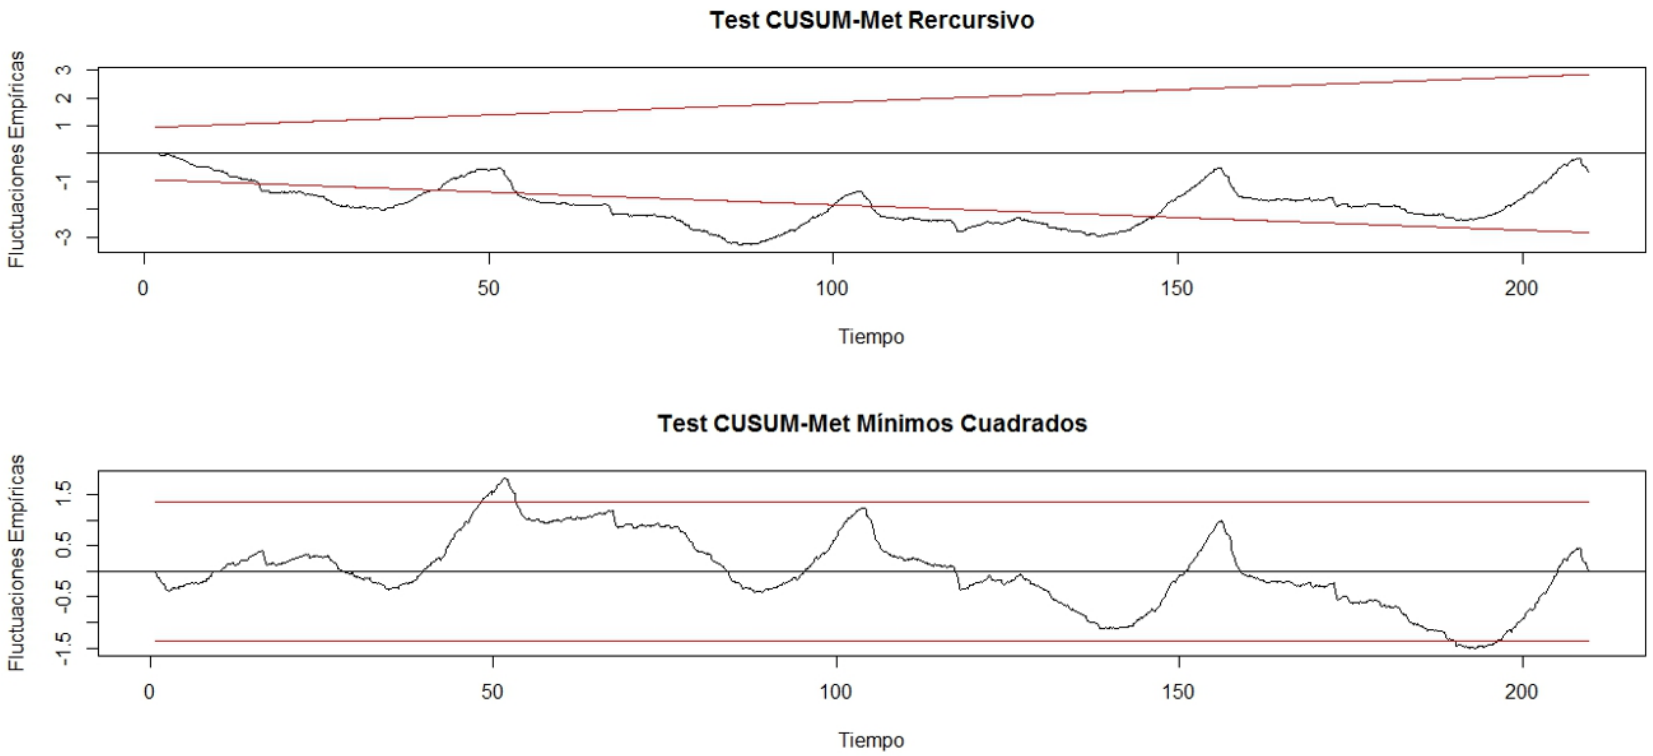
$$S_t = \frac{\sum_{r=m+1}^{t} w_r^2}{\sum_{r=m+1}^{T} w_r^2}.$$

Bajo la nula correspondiente:

$$E(S_t) \simeq \frac{t-m}{T-m}.$$

Se compara con sus bandas específicas. El denominador utiliza toda la ventana y el numerador contiene cuadrados. El contraste no debe confundirse con una prueba general de estabilidad de cointegración.

CUSUM y CUSUM al cuadrado



Pronostico

- El pronóstico recursivo es una implicación del modelo estimado y debe acompañarse de incertidumbre y límites de especificación.
- El horizonte depende de la pregunta económica y de la calidad predictiva que pueda justificarse. Cinco o diez periodos no constituyen una regla universal.
- Una respuesta que se disipa en variables estacionarias no demuestra que todo VAR sea únicamente un modelo de corto plazo.
- Con variables I(1) y cointegración, el VEC permite combinar dinámica de diferencias y relaciones de largo plazo, como se desarrolla a continuación.

Modelo VEC

Definición y pregunta económica

- Un modelo vectorial de corrección de error (VEC o VECM) describe variables I(1) que comparten relaciones de cointegración.
- Combina cambios de corto plazo con un término que depende de los niveles rezagados y de su relación de largo plazo.
- Pregunta económica: ¿cómo se modifican las variables cuando se apartan de una relación estable entre sus niveles?
- Su lectura exige identificar el rango y los determinísticos. La existencia de cointegración no identifica efectos estructurales de política.

Modelo VEC

Usos y límites

- Describir comovimiento de largo plazo, dinámica de corto plazo y mecanismos de ajuste en un mismo sistema.
- Formular pronósticos compatibles con las restricciones de cointegración estimadas.
- Examinar restricciones económicas sobre relaciones de niveles, cargas de ajuste y exclusión predictiva.
- Ejemplos de hipótesis: consumo e ingreso, dinero y precios, tasas de interés relacionadas. Cada aplicación requiere verificar sus supuestos y definiciones de datos.

Modelo VEC

Notación que se mantendrá en el desarrollo

$$X_t = (X_{1t}, \ldots, X_{Kt})', \qquad \Delta X_t = X_t - X_{t-1},$$
$$u_t \in \mathbb{R}^K, \qquad E(u_t \mid \mathcal{F}_{t-1}) = 0.$$

- K: número de variables. p: rezagos del VAR en niveles.
- r: número de relaciones cointegrantes independientes.
- n: observaciones efectivas después de condiciones iniciales.
- Las demostraciones iniciales omiten determinísticos para facilitar el álgebra. Se reincorporan expresamente más adelante.

Modelo VEC

Supuestos del marco I(1)

- Los componentes de X_t son I(1) y sus primeras diferencias son I(0), admitiendo los determinísticos especificados.
- El sistema tiene una representación dinámica adecuada y una covarianza de innovaciones no singular.
- Bajo la representación I(1), hay $K - r$ tendencias estocásticas comunes y los componentes transitorios son estables.
- El rango reducido por sí solo no descarta I(2), raíces explosivas, rupturas o dinámica omitida. Estas condiciones deben verificarse.

Modelo VEC

Cointegración: definición formal

Existe una matriz β de dimensión $K \times r$ y rango columna r tal que:

$$\beta' X_t \sim I(0), \qquad 0 < r < K.$$

Cada columna define una combinación estacionaria. Por ejemplo, para $K = 2$ y $r = 1$:

$$e_t = y_t - bx_t, \qquad \beta = \begin{pmatrix} 1 \\ -b \end{pmatrix}.$$

y_t y x_t pueden ser no estacionarias y e_t estacionario. Si hay constante o tendencia en el equilibrio, se incluyen en la definición de e_t.

Modelo VEC

Demostración VAR(2) a VEC: paso 1

Partimos del VAR en niveles:

$$X_t = c + A_1 X_{t-1} + A_2 X_{t-2} + u_t.$$

Restamos X_{t-1} de ambos lados:

$$\Delta X_t = c + (A_1 - I_K) X_{t-1} + A_2 X_{t-2} + u_t.$$

La identidad $X_{t-2} = X_{t-1} - \Delta X_{t-1}$ permite expresar el segundo rezago mediante el primer nivel y una diferencia.

Modelo VEC

Demostración VAR(2) a VEC: paso 2

Sustituimos la identidad y agrupamos:

$$\Delta X_t = c + (A_1 - I_K)X_{t-1} + A_2(X_{t-1} - \Delta X_{t-1}) + u_t,$$
$$\Delta X_t = c + (A_1 + A_2 - I_K)X_{t-1} - A_2\Delta X_{t-1} + u_t.$$

Definimos:

$$\Pi = A_1 + A_2 - I_K, \qquad \Gamma_1 = -A_2.$$

Hasta aquí la transformación es algebraica. Aún no se ha impuesto un rango reducido.

Modelo VEC

Demostración VAR(2) a VEC: paso 3

La forma resultante es:

$$\boxed{\Delta X_t = c + \Pi X_{t-1} + \Gamma_1 \Delta X_{t-1} + u_t.}$$

La transformación también puede invertirse:

$$A_2 = -\Gamma_1, \qquad A_1 = I_K + \Pi + \Gamma_1.$$

Un VAR(2) en niveles contiene un rezago de diferencias en esta representación. No deben confundirse esos dos órdenes.

Modelo VEC

Demostración general: identidad de los rezagos

Para $j \geq 2$:

$$X_{t-j} = X_{t-1} - \sum_{\ell=1}^{j-1} \Delta X_{t-\ell}.$$

Partiendo de $X_t = c + \sum_{j=1}^{p} A_j X_{t-j} + u_t$ y restando X_{t-1}:

$$\Delta X_t = c + \left(\sum_{j=1}^{p} A_j - I_K \right) X_{t-1} - \sum_{j=2}^{p} A_j \sum_{\ell=1}^{j-1} \Delta X_{t-\ell} + u_t.$$

Cada diferencia $\Delta X_{t-\ell}$ aparece en los términos con $j \geq \ell + 1$.

Modelo VEC

Demostración general: agrupación final

Al intercambiar el orden de las sumas:

$$\Pi = \sum_{j=1}^{p} A_j - I_K, \qquad \Gamma_\ell = -\sum_{j=\ell+1}^{p} A_j,$$

$$\boxed{\Delta X_t = c + \Pi X_{t-1} + \sum_{\ell=1}^{p-1} \Gamma_\ell \Delta X_{t-\ell} + u_t.}$$

La matriz Π contiene la restricción de niveles. Las matrices Γ_ℓ describen dinámica de diferencias, condicionada al término de niveles.

Modelo VEC

Rango de la matriz de niveles

- Si $r = \text{rango}(\Pi) = 0$, entonces $\Pi = 0$. Queda un VAR en diferencias con los determinísticos incluidos.
- Si $0 < r < K$, existen r combinaciones cointegrantes y se utiliza la factorización $\Pi = \alpha\beta'$.
- Si $r = K$, el rango es completo. En el marco habitual esto exige revisar la premisa de variables I(1) y considerar una representación estacionaria alrededor de determinísticos.
- El rango se interpreta junto con las demás raíces y los supuestos. No identifica por sí solo el orden completo de integración.

Modelo VEC

Por qué aparecen combinaciones de niveles estacionarias

Si ΔX_t, sus rezagos y u_t son I(0), entonces la ecuación requiere que ΠX_{t-1} sea I(0), retirando los determinísticos.

- Una matriz Π invertible haría I(0) al vector de niveles y contradiría la premisa I(1).
- Una matriz nula elimina toda corrección de niveles.
- Un rango intermedio permite que algunas combinaciones de niveles sean estacionarias y otras direcciones conserven tendencias estocásticas.

Este argumento explica la restricción. El teorema de representación añade condiciones sobre raíces, rango y regularidad.

Modelo VEC

Factorización y dimensiones

Para $0 < r < K$:

$$\Pi = \alpha\beta', \qquad \alpha \in \mathbb{R}^{K\times r}, \quad \beta \in \mathbb{R}^{K\times r}.$$

El VEC se escribe:

$$\Delta X_t = c + \alpha e_{t-1} + \sum_{\ell=1}^{p-1} \Gamma_\ell \Delta X_{t-\ell} + u_t, \qquad e_{t-1} = \beta' X_{t-1}.$$

Las columnas de β definen relaciones de niveles. Las filas de α indican cómo responde cada ecuación a esas relaciones.

Modelo VEC

Identificación de escala y normalización

La factorización no es única. Para una matriz invertible H de tamaño r:

$$\alpha^* = \alpha H, \qquad \beta^* = \beta H^{-T},$$

$$\alpha^*(\beta^*)' = \alpha H H^{-1}\beta' = \Pi.$$

Se necesitan normalizaciones para reportar coeficientes. Con $r = 1$, multiplicar β por -1 exige cambiar también el signo de α.
Una entrada fijada a uno no tiene un error estándar estimado ni un p-valor de significancia interpretable.

Modelo VEC

Constante dentro de la relación

Con una constante restringida al equilibrio:

$$e_{t-1} = \beta' X_{t-1} + \rho,$$

$$\Delta X_t = \alpha(\beta' X_{t-1} + \rho) + \sum_{\ell} \Gamma_\ell \Delta X_{t-\ell} + u_t.$$

El intercepto de la ecuación de cambios queda restringido a $\alpha\rho$. Esta es una especificación distinta de incluir una constante libre en cada ecuación. En una implementación debe verificarse que la prueba de rango y la estimación utilicen el mismo caso determinístico.

Modelo VEC

Constante fuera de la relación

Con intercepto no restringido:

$$\Delta X_t = c + \alpha\beta' X_{t-1} + \sum_{\ell} \Gamma_\ell \Delta X_{t-\ell} + u_t.$$

Puede haber deriva en las tendencias comunes. La combinación $q_t = \beta' X_t$ no tiene por qué estar centrada en cero.
Si se resta una media muestral $\overline{q}$, la misma ecuación se reescribe con:

$$\widetilde{q}_t = q_t - \overline{q}, \qquad c^* = c + \alpha\overline{q}.$$

Este centrado es descriptivo. No convierte c en una constante restringida ni identifica un equilibrio estructural de valor cero.

Modelo VEC

Tendencias, estacionalidad e intervenciones

- Una tendencia dentro de la relación permite equilibrio alrededor de una trayectoria determinística. Fuera de ella modifica la trayectoria de los niveles.
- Series originales pueden requerir efectos estacionales. Series ya desestacionalizadas exigen revisar la estacionalidad remanente antes de añadir dummies.
- Pulsos, cambios de nivel y rupturas no son intercambiables. Pueden alterar la inferencia de cointegración.
- Que un programa acepte exógenas no garantiza que los valores críticos estándar sigan siendo válidos para cualquier intervención.

Modelo VEC

Interpretación de los coeficientes beta

En un sistema bivariado de log-niveles:

$$e_t = \log Y_t - b \log Z_t - \kappa.$$

Si la relación cointegrante es válida, b caracteriza una asociación proporcional de largo plazo condicionada a esa relación.

- No es automáticamente una elasticidad causal o un parámetro de política.
- Probar $b = 1$ contrasta proporcionalidad unitaria, distinto de probar $b = 0$.
- La significancia de un coeficiente bajo rango impuesto no demuestra que exista cointegración. Esa pregunta corresponde al contraste de rango.

Modelo VEC

Interpretación de los coeficientes alpha

Para $e_t = y_t - bz_t - \kappa$:

$$\Delta y_t = c_y + \alpha_y e_{t-1} + \text{dinámica corta} + u_{yt},$$
$$\Delta z_t = c_z + \alpha_z e_{t-1} + \text{dinámica corta} + u_{zt}.$$

Una unidad adicional de e_{t-1} modifica la media condicional de cada diferencia en α_y y α_z, manteniendo las otras entradas.
El signo se lee con la definición de e. No existe la regla universal de que todos los α deban ser negativos.

Modelo VEC

Interpretación de las matrices Gamma

El elemento $\gamma_{ij,\ell}$ es el coeficiente de $\Delta X_{j,t-\ell}$ en la ecuación de ΔX_{it}, dado el equilibrio y las otras diferencias.
Si X contiene logaritmos y $\gamma_{ij,1} = 0.30$, un punto adicional de $100\Delta \log X_j$ rezagado se asocia con 0.30 puntos de $100\Delta \log X_i$ actual, ceteris paribus. La misma escala por cien en ambos lados no cambia γ. El efecto dinámico total requiere propagar todas las ecuaciones.

Modelo VEC

Ejemplo numérico: especificación ilustrativa

Este ejemplo no corresponde a una estimación de México.

$$e_t = y_t - z_t, \qquad \alpha = \begin{pmatrix} -0.20 \\ 0.10 \end{pmatrix}, \qquad \beta = \begin{pmatrix} 1 \\ -1 \end{pmatrix}.$$

Se omiten constante y diferencias rezagadas:

$$\Delta y_t = -0.20 e_{t-1} + u_{yt}, \qquad \Delta z_t = 0.10 e_{t-1} + u_{zt}.$$

Una desviación positiva induce menor crecimiento de y y mayor crecimiento de z por el canal de corrección.

Modelo VEC

Ejemplo numérico: ajuste de las variables

Si y y z son logaritmos y $e_{t-1} = 0.10$:

$$\alpha_y e_{t-1} = -0.020, \qquad \alpha_z e_{t-1} = 0.010.$$

Las contribuciones son -2 y $+1$ puntos de crecimiento logarítmico. Los cambios porcentuales exactos serían $100(e^{-0.02} - 1)$ y $100(e^{0.01} - 1)$ si esos fueran los cambios totales.
Aquí solo se calcula el aporte de corrección, antes de nuevas innovaciones. En un modelo más general también se añaden constante y diferencias rezagadas.

Modelo VEC

Demostración de la evolución del desequilibrio

Para el ejemplo:

$$\Delta e_t = \Delta y_t - \Delta z_t = (-0.20 - 0.10)e_{t-1} + u_{yt} - u_{zt},$$
$$e_t = 0.70e_{t-1} + u_{yt} - u_{zt}.$$

Sin nuevas innovaciones, cada periodo conserva 70 por ciento de la desviación logarítmica anterior. El sistema corrige 30 por ciento de ese error, no solo el 20 por ciento asociado a la ecuación de y.
La semivida es $\log(0.5)/\log(0.70) \simeq 1.94$ periodos en este ejemplo sin diferencias rezagadas.

Modelo VEC

Demostración general del ejemplo de rango uno

Para $\Delta X_t = \alpha\beta' X_{t-1} + u_t$ y $e_t = \beta' X_t$:

$$\Delta e_t = \beta' \Delta X_t = \beta' \alpha e_{t-1} + \beta' u_t,$$
$$e_t = (1 + \beta'\alpha) e_{t-1} + \beta' u_t.$$

Con momentos apropiados, el error es estacionario si:

$$|1 + \beta'\alpha| < 1.$$

Con diferencias rezagadas esta reducción escalar no es suficiente. Se examina la dinámica completa y no se aplica automáticamente esa fórmula de semivida.

Modelo VEC

Comprobación mediante la representación VAR

En el ejemplo, $A_1 = I_2 + \alpha\beta'$:

$$A_1 = \begin{pmatrix} 0.80 & 0.20 \\ 0.10 & 0.90 \end{pmatrix}.$$

Sus autovalores son 1 y 0.70. Hay una tendencia común y un componente transitorio estable.
La raíz unitaria permite niveles I(1), mientras que la combinación $y_t - z_t$ tiene persistencia 0.70. Esta coexistencia explica por qué no se exige estabilidad estricta de todos los niveles en un VEC cointegrado.

Modelo VEC

Teorema de representación: condiciones y alcance

Bajo una representación I(1) adecuada, rango r y regularidad, cointegración y corrección de error están vinculadas por el teorema de representación de Granger [V1].
Se necesitan, entre otras condiciones:

- α y β de rango columna completo r.
- $K - r$ raíces unitarias en $+1$ y componentes transitorios estables.
- Ausencia de componentes I(2) y una matriz de impacto permanente de rango $K - r$.

La factorización $\Pi = \alpha\beta'$ por sí sola no demuestra todas estas condiciones.

Modelo VEC

Tendencias comunes: espacios ortogonales

Sean $\beta_\perp$ y $\alpha_\perp$ bases de los complementos ortogonales:

$$\beta'\beta_\perp = 0, \qquad \alpha'_\perp\alpha = 0.$$

Ambas matrices tienen $K - r$ columnas. Defina:

$$G = I_K - \sum_{j=1}^{p-1} \Gamma_j.$$

Bajo las condiciones I(1), $\alpha'_\perp G\beta_\perp$ es invertible. Esa condición excluye degeneraciones que pueden dar lugar a componentes de orden superior.

Modelo VEC

Tendencias comunes: derivación del impacto permanente

La restricción de equilibrio exige que el impacto permanente esté en el espacio ortogonal a β:

$$\beta' C = 0, \qquad C = \beta_\perp M.$$

La identidad de largo plazo proyectada sobre $\alpha_\perp$ da:

$$\alpha'_\perp G C = \alpha'_\perp.$$

Sustituyendo $C = \beta_\perp M$ y resolviendo:

$$\boxed{C = \beta_\perp (\alpha'_\perp G \beta_\perp)^{-1} \alpha'_\perp.}$$

Estas igualdades describen la solución bajo el teorema de representación, no una prueba de sus supuestos a partir de los datos.

Modelo VEC

Interpretación de tendencias y equilibrio

Sin detallar los determinísticos, la representación contiene:

$$X_t = C \sum_{s=1}^{t} u_s + \text{componente estacionario} + \text{condiciones iniciales.}$$

Como $\beta' C = 0$, las tendencias comunes se cancelan en $\beta' X_t$.
Los niveles pueden conservar efectos permanentes aunque las combinaciones cointegrantes sean estacionarias. Cointegración no obliga a cada variable a volver a su nivel previo a una perturbación.

Estimación del modelo VEC

Elección de muestra, orden y determinísticos

- Verificar definición, frecuencia, ajuste estacional, revisiones y ventana común. No interpolar huecos sin justificación.
- Examinar integración y posibles rupturas antes de fijar un marco I(1).
- Seleccionar p del VAR de niveles mediante una regla documentada y revisar dinámica residual. En VEC se usan $p-1$ diferencias rezagadas.
- Especificar el caso determinístico y contrastar el rango con valores críticos compatibles. Se estima el VEC condicionado a esa elección.

Estimación del modelo VEC

Verosimilitud gaussiana

Con $u_t \sim N(0, \Sigma_u)$ condicionalmente y una especificación adecuada:

$$\ell = \text{constante} - \frac{n}{2} \log |\Sigma_u| - \frac{1}{2} \sum_t u_t' \Sigma_u^{-1} u_t.$$

La estimación impone rango$(\Pi) = r$ y maximiza la verosimilitud bajo esa restricción.
La normalidad facilita esta formulación. Los resultados de inferencia y sus extensiones requieren condiciones de regularidad. Un rechazo de normalidad o ARCH exige revisar la validez de aproximaciones convencionales.

Estimación del modelo VEC

Paso 1: retirar la dinámica corta

Considere las regresiones auxiliares sobre Z_t, formado por diferencias rezagadas y determinísticos del caso correspondiente:

$$\Delta X_t = B_0 Z_t + R_{0t},$$
$$X_{t-1} = B_1 Z_t + R_{1t}.$$

La relación residualizada que se estima es:

$$R_{0t} = \alpha\beta' R_{1t} + \varepsilon_t.$$

Si hay determinísticos restringidos al equilibrio, se amplía el vector de niveles de forma consistente con ese caso.

Estimación del modelo VEC

Paso 2: matrices de momentos

Con R_0 y R_1 como vectores columna por fecha:

$$S_{ij} = \frac{1}{n} \sum_t R_{it} R'_{jt}, \qquad i, j \in \{0, 1\}.$$

Dada una matriz β, la regresión de R_0 sobre $\beta' R_1$ produce:

$$\widehat{\alpha}(\beta) = S_{01}\beta(\beta' S_{11}\beta)^{-1}.$$

Se requiere rango suficiente. Invertir matrices singulares mediante una pseudoinversa no resuelve automáticamente un problema de identificación.

Estimación del modelo VEC

Paso 3: covarianza concentrada

Al sustituir la solución de α:

$$\widehat{\Sigma}(\beta) = S_{00} - S_{01}\beta(\beta' S_{11}\beta)^{-1}\beta' S_{10}.$$

La log-verosimilitud concentrada es:

$$\ell_c(\beta) = \text{constante} - \frac{n}{2}\log|\widehat{\Sigma}(\beta)|.$$

Por tanto, estimar el espacio cointegrante equivale a minimizar el determinante de la covarianza residual sujeto al rango y a una normalización.

Estimación del modelo VEC

Paso 4: autovalores y espacio cointegrante

El problema generalizado es:

$$\left|\lambda S_{11} - S_{10} S_{00}^{-1} S_{01}\right| = 0.$$

Ordenando $\widehat{\lambda}_1 \geq \cdots \geq \widehat{\lambda}_K$, se seleccionan los r autovectores asociados a los mayores autovalores.
Bajo la normalización correspondiente:

$$|\widehat{\Sigma}_r| = |S_{00}| \prod_{j=1}^{r} (1 - \widehat{\lambda}_j).$$

Esta identidad conecta la estimación de rango reducido con los contrastes de Johansen [V2].

Estimación del modelo VEC

Paso 5: recuperar parámetros y covarianza

- Se normaliza $\widehat{\beta}$ y se obtiene $\widehat{\alpha}$ mediante la fórmula condicional.
- Dados los equilibrios estimados, se recuperan Γ_j y los determinísticos mediante regresiones compatibles con el sistema.
- La covarianza ML es $\widehat{\Sigma}_u = n^{-1} \sum_t \widehat{u}_t \widehat{u}_t'$.
- Errores estándar y pruebas deben reconocer la estimación del espacio de cointegración. Una regresión MCO de niveles sin restricciones no equivale al procedimiento de Johansen.

Pruebas de rango en VEC

Derivación de la traza desde la verosimilitud

Comparando el máximo bajo rango r con el modelo de rango completo:

$$LR = 2(\ell_K - \ell_r) = n \log \frac{|\widehat{\Sigma}_r|}{|\widehat{\Sigma}_K|},$$

$$\frac{|\widehat{\Sigma}_r|}{|\widehat{\Sigma}_K|} = \frac{1}{\prod_{j=r+1}^{K}(1-\widehat{\lambda}_j)},$$

$$LR_{\text{traza}}(r) = -n \sum_{j=r+1}^{K} \log(1-\widehat{\lambda}_j).$$

La distribución bajo la nula es no estándar y depende de los determinísticos.

Pruebas de rango en VEC

Decisión e incertidumbre de especificación

- Se empieza por $r = 0$ y se avanza hasta el primer no rechazo.
- Traza y máximo autovalor pueden discrepar. Esa discrepancia debe informarse y examinarse mediante sensibilidad fundamentada.
- Orden, determinísticos, periodo y rupturas influyen en el resultado. No se modifican solo para lograr cointegración.
- Si se impone un rango por hipótesis docente o económica, todas las inferencias deben rotularse como condicionadas a ese rango. No se presenta la imposición como resultado del test.

Interpretación e inferencia en VEC

Restricciones sobre beta

Una hipótesis económica puede escribirse como una restricción del espacio cointegrante. Por ejemplo, en una relación bivariada normalizada:

$$H_0 : b = 1.$$

Eso contrasta proporcionalidad de largo plazo. Se utiliza un procedimiento de restricciones compatible con la normalización y con rango fijo.
El p-valor de un coeficiente de $\widehat{\beta}$ condicionado a rango r no es el p-valor de la prueba de existencia de cointegración. Son problemas de inferencia diferentes.

Interpretación e inferencia en VEC

Alpha y exogeneidad débil

Bajo el modelo y la partición apropiados, una fila nula:

$$H_0 : \alpha_{i1} = \cdots = \alpha_{ir} = 0$$

puede expresar exogeneidad débil de la variable i respecto de los parámetros de largo plazo.

- Con $r > 1$ se contrasta toda la fila, no un coeficiente aislado.
- No rechazar no demuestra exogeneidad. La conclusión depende de los supuestos y parámetros de interés.
- Exogeneidad débil no equivale a ausencia de Granger, exogeneidad fuerte o causalidad estructural. En R, `urca::alrtest` permite restricciones sobre α [V4].

Causalidad de Granger en VEC

Qué cambia respecto del VAR estacionario

En el VAR estacionario, la exclusión predictiva de j en la ecuación de i se formula mediante:

$$H_0 : a_{ij,1} = \cdots = a_{ij,p} = 0, \qquad i \neq j.$$

El VEC conserva dos entradas potenciales de información de j:

- Sus diferencias rezagadas, a través de Γ_ℓ.
- Su nivel dentro de $\Pi X_{t-1} = \alpha\beta' X_{t-1}$.

Por eso excluir solo diferencias puede dejar abierto el canal de niveles.

Causalidad de Granger en VEC

Prueba del canal de corto plazo

Para la ecuación i se contrasta:

$$H_0^{CP} : \gamma_{ij,1} = \cdots = \gamma_{ij,p-1} = 0.$$

La prueba evalúa si las diferencias rezagadas de j aportan información dado el término de equilibrio y el resto de regresores.
Rechazar indica un canal predictivo de diferencias. No rechazar no establece no causalidad completa si el nivel de j permanece en el término de corrección.
Si $p = 1$, no hay diferencias rezagadas y este bloque de restricciones está vacío.

Causalidad de Granger en VEC

Canal de ajuste al equilibrio

Contrastar una fila de α igual a cero examina si la ecuación i responde a las relaciones cointegrantes.
Con $r = 1$ y $e_t = y_t - bz_t - \kappa$, si $b \neq 0$, $\alpha_y \neq 0$ implica que el nivel de z entra en la corrección de la ecuación de y.
En un sistema mayor, una carga significativa no identifica por sí sola qué variable causa a cuál. Hay varias relaciones y diferentes componentes de β. La denominación aplicada de "causalidad de largo plazo'' debe precisar esta hipótesis y no confundirse con un efecto causal estructural.

Causalidad de Granger en VEC

Demostración de la exclusión completa: VAR(2)

Las matrices en niveles son:

$$A_1 = I_K + \Pi + \Gamma_1, \qquad A_2 = -\Gamma_1.$$

Para $i \neq j$:

$$a_{ij,1} = \pi_{ij} + \gamma_{ij,1}, \qquad a_{ij,2} = -\gamma_{ij,1}.$$

Entonces $a_{ij,1} = a_{ij,2} = 0$ si y solo si:

$$\boxed{\pi_{ij} = 0 \quad \text{y} \quad \gamma_{ij,1} = 0.}$$

Excluir solamente $\gamma_{ij,1}$ deja $a_{ij,1} = \pi_{ij}$ potencialmente distinto de cero.

Causalidad de Granger en VEC

Demostración para p rezagos

Para $p \geq 2$, la inversión de la reparametrización produce:

$$A_1 = I_K + \Pi + \Gamma_1,$$
$$A_\ell = \Gamma_\ell - \Gamma_{\ell-1}, \quad 2 \leq \ell \leq p-1,$$
$$A_p = -\Gamma_{p-1}.$$

Para un elemento fuera de la diagonal, $A_p = 0$ obliga a la última entrada de Γ a ser cero. Retrocediendo por las diferencias se anulan todas, y $A_1 = 0$ obliga a $\pi_{ij} = 0$.
Para $p = 1$, $A_1 = I_K + \Pi$ y solo queda la restricción sobre π_{ij}.

Causalidad de Granger en VEC

Restricción general y cancelaciones

La exclusión predictiva completa de j en la ecuación i requiere:

$$\pi_{ij} = 0, \qquad \gamma_{ij,\ell} = 0 \quad (\ell = 1, \ldots, p-1).$$

Pero:

$$\pi_{ij} = \sum_{m=1}^{r} \alpha_{im}\beta_{jm}.$$

Con varias relaciones puede haber cancelaciones. Por eso imponer toda la fila $\alpha_i = 0$ puede ser una restricción más fuerte que excluir solamente a j. La prueba debe formular las restricciones correctas del sistema, no atribuir causalidad específica a cualquier carga de ajuste significativa.

Causalidad de Granger en VEC

Caso bivariado de rango uno

Para $\beta' = (1, -b)$, con $b \neq 0$:

$$\pi_{12} = -b\alpha_y.$$

Así, ausencia de Granger de z hacia y en la representación lineal requiere conjuntamente:

$$H_0 : \alpha_y = 0, \quad \gamma_{yz,1} = \cdots = \gamma_{yz,p-1} = 0.$$

La dirección inversa tiene sus propias restricciones. Cointegración bivariada no obliga a que ambos sentidos sean significativos. Un ajuste unilateral puede coexistir con una variable débilmente exógena.

Causalidad de Granger en VEC

Wald, razón de verosimilitud y supuestos

Para restricciones regulares $g(\theta) = 0$, una forma Wald es:

$$W = g(\widehat{\theta})'[\widehat{G}\widehat{V}\widehat{G}']^{-1}g(\widehat{\theta}), \qquad \widehat{G} = \left.\frac{\partial g}{\partial \theta'}\right|_{\widehat{\theta}}.$$

Su referencia χ^2_s exige regularidad y una covarianza válida para los parámetros y restricciones considerados. No se aplica mecánicamente a cualquier regresión I(1).

Con rango fijo pueden formularse LR entre sistemas restringido y no restringido. Restricciones producto sobre $\alpha\beta'$ pueden presentar singularidades. Se deben revisar identificación y distribución antes de contar grados de libertad.

Causalidad de Granger en VEC

Alternativa de rezagos aumentados

El enfoque de Toda–Yamamoto [V3] estima en niveles un VAR de $p + d_{\max}$ rezagos, donde $d_{\max}$ es una cota del orden máximo de integración.
Se contrastan las restricciones de exclusión sobre los primeros p rezagos y se dejan sin restringir los rezagos añadidos.
Bajo sus condiciones se obtiene una referencia Wald estándar sin imponer previamente el rango. La elección de p, la cota de integración y la especificación de innovaciones siguen importando.
No identifica causalidad estructural ni resuelve automáticamente heterocedasticidad, rupturas o una dinámica mal especificada.

Causalidad de Granger en VEC

Lectura de una tabla de resultados

Cada contraste debe informar:

- Dirección, ecuación dependiente y conjunto de información.
- Variables en niveles o diferencias y rango mantenido.
- Hipótesis: diferencias, cargas de ajuste o exclusión completa.
- Estadístico, distribución de referencia, grados de libertad y p-valor.

Un p pequeño contradice la nula bajo el diseño. No es la probabilidad de que exista causalidad ni una medida del tamaño económico del efecto. Comparaciones múltiples pueden requerir un ajuste documentado.

Validación del modelo VEC

Qué permanece y qué cambia

Se mantienen las preguntas de autocorrelación, segundos momentos, distribución y constancia de parámetros.
Cambian los objetos que deben respetarse:

- Los residuos proceden del VEC restringido y de sus determinísticos.
- Las pruebas sistémicas deben reconocer rezagos, dimensión y rango.
- Se admiten $K - r$ raíces $+1$ en la representación de niveles.
- Deben investigarse la constancia del espacio cointegrante y las restricciones económicas mantenidas.

Validación del modelo VEC

Residuales y gráficos

Los errores estimados son:

$$\widehat{u}_t = \Delta X_t - \widehat{c} - \widehat{\alpha}\widehat{\beta}' X_{t-1} - \sum_{\ell} \widehat{\Gamma}_\ell \Delta X_{t-\ell}.$$

Se examinan trayectorias, valores extremos, ACF, correlaciones cruzadas residuales y gráficos Q–Q.
Que una combinación cointegrante parezca oscilar o cruce cero no demuestra estacionariedad. Tampoco una ACF marginal pequeña demuestra ausencia de toda dependencia multivariada.

Validación del modelo VEC

Portmanteau multivariado

La nula es que las matrices de autocovarianza residual a rezagos $1, \ldots, h$ sean cero.
Una versión ajustada del estadístico utiliza:

$$Q_h^* = n^2 \sum_{j=1}^{h} \frac{\operatorname{tr}(\widehat{C}_j' \widehat{C}_0^{-1} \widehat{C}_j \widehat{C}_0^{-1})}{n-j}.$$

$\widehat{C}_j$ estima autocovarianzas de residuos. Las convenciones de escala pueden variar por implementación.
Un p pequeño sugiere revisar dinámica y especificación. Un p grande no demuestra independencia ni varianza condicional constante.

Validación del modelo VEC

Ajuste por dimensión, rezagos y rango

No se traslada automáticamente la corrección de un VAR estacionario al VEC.
Como ejemplo, `statsmodels` utiliza para su Portmanteau VEC:

$$gl = K^2(h - p + 1) - Kr,$$

con p el orden VAR en niveles y r el rango. En un VAR estacionario de orden p_s utiliza $K^2(h - p_s)$.
Debe emplearse un horizonte admisible, suficientes observaciones y la rutina apropiada al objeto. La aproximación es asintótica y condicionada al rango y a la especificación [V5].

Validación del modelo VEC

LM de autocorrelación

Otra estrategia añade residuos rezagados a una regresión auxiliar que conserva los regresores del VEC:

$$\widehat{u}_t = DZ_t + \sum_{j=1}^{h} B_j \widehat{u}_{t-j} + v_t.$$

La nula conjunta es $B_1 = \cdots = B_h = 0$.
Se utiliza un LM sistémico con tratamiento adecuado de condiciones iniciales, rango estimado y determinísticos. Una aplicación Breusch–Godfrey por ecuación no sustituye automáticamente ese contraste conjunto.
Se debe documentar si se examina un rezago particular o todos los rezagos hasta h.

Validación del modelo VEC

Normalidad de las innovaciones

En una ecuación, Jarque–Bera combina asimetría S y curtosis C:

$$JB = n\left[\frac{S^2}{6} + \frac{(C-3)^2}{24}\right].$$

La normalidad multivariada requiere un contraste conjunto que considere la covarianza entre ecuaciones. No se obtiene sumando sin ajuste JB de errores correlacionados.

Rechazar normalidad no implica automáticamente inconsistencia de todo estimador, pero exige revisar extremos y la inferencia gaussiana. La distribución de parámetros de largo plazo y la incertidumbre de rango también importan.

Validación del modelo VEC

ARCH marginal

Para cada error se estima la auxiliar:

$$\widehat{u}_t^2 = a + \sum_{j=1}^{q} b_j \widehat{u}_{t-j}^2 + v_t.$$

La nula es $b_1 = \cdots = b_q = 0$. El LM convencional es $n_{aux} R^2$, con referencia asintótica χ_q^2 bajo sus condiciones.
No rechazar no garantiza homocedasticidad del sistema. Estas auxiliares no incluyen de forma completa la dependencia de los productos cruzados entre errores.

Validación del modelo VEC

ARCH multivariado

Se construye el vector de cuadrados y productos cruzados:

$$v_t = \text{vech}(\widehat{u}_t \widehat{u}_t'), \qquad D = K(K+1)/2.$$

Se regresa v_t sobre una constante y q rezagos de sí mismo. La nula anula todas las matrices de pendientes.
Con covarianzas auxiliares $\widehat{\Omega}$ y restringida $\widehat{\Omega}_0$:

$$LM = n_{aux}[D - \text{tr}(\widehat{\Omega}\widehat{\Omega}_0^{-1})], \qquad gl = qD^2.$$

Es una referencia asintótica. Deben verificarse rango, dimensión y sensibilidad a extremos [V6].

Validación del modelo VEC

Estabilidad dinámica de la representación I(1)

Se recuperan las matrices A_j y la matriz compañera del VAR de niveles.

- Se esperan $K - r$ autovalores iguales a $+1$ en una representación I(1) regular.
- Los componentes transitorios deben tener autovalores con módulo menor que uno.
- No deben aparecer componentes explosivos ni estructura I(2).

Las raíces unitarias son consecuencia del rango mantenido. Observarlas en un VEC restringido no es una prueba independiente que confirme cointegración.

Validación del modelo VEC

Constancia de parámetros y del espacio cointegrante

La estabilidad de raíces del modelo estimado no demuestra que sus parámetros hayan permanecido constantes durante toda la muestra.
Pueden cambiar:

- La relación de largo plazo β.
- Las cargas de ajuste α y la dinámica Γ_j.
- Los determinísticos y la covarianza de innovaciones.

Se requieren contrastes de constancia específicos, estimaciones recursivas o procedimientos de ruptura adecuados al sistema cointegrado. CUSUM marginal no certifica por sí solo la constancia de β.

Validación del modelo VEC

Qué hacer ante rechazos

- Autocorrelación: revisar orden, omitidas, determinísticos y posibles cambios de régimen.
- ARCH o no normalidad: revisar la validez de pruebas e intervalos convencionales. Considerar inferencia robusta o bootstrap que preserve la nula y la estructura de integración.
- Rango sensible: documentar la incertidumbre y evitar declarar un equilibrio como establecido.
- Ruptura: estudiar una especificación compatible con ese cambio. Añadir dummies y conservar sin justificar las mismas tablas críticas puede producir inferencia incorrecta.

Validación del modelo VEC

Ejemplo de interpretación integrada

Suponga que Portmanteau no rechaza, pero ARCH multivariado y normalidad sí rechazan.
La lectura admisible es: no se detecta autocorrelación residual de la media hasta los rezagos examinados, pero hay evidencia contra la especificación de segundos momentos y contra la distribución normal.
No se declara el modelo "validado'' solo porque Portmanteau sea favorable. Si se reportan p-valores o bandas convencionales, deben explicitarse su carácter condicionado y sus límites.

Impulso-respuesta en VEC

Diferencias con un VAR estacionario

La respuesta de un VEC puede calcularse desde su representación VAR en niveles, usando las mismas restricciones contemporáneas de identificación declaradas.

- Los efectos sobre niveles I(1) pueden persistir.
- Las combinaciones cointegrantes cancelan las tendencias comunes bajo el modelo válido.
- Una respuesta de log-nivel multiplicada por cien ya representa una desviación porcentual aproximada del nivel. No se acumula nuevamente para esa lectura.
- Si el VAR usa $100\Delta \log X$, sus respuestas son puntos de crecimiento y su suma aproxima el efecto sobre niveles.

Impulso-respuesta en VEC

Choques permanentes y transitorios

La matriz de impacto de largo plazo C separa direcciones permanentes de direcciones que se disipan.

En el ejemplo con $A_1 = \begin{pmatrix} 0.8 & 0.2 \\ 0.1 & 0.9 \end{pmatrix}$:

$$\lim_{h\to\infty} A_1^h = \begin{pmatrix} 1/3 & 2/3 \\ 1/3 & 2/3 \end{pmatrix}.$$

Con una innovación reducida unitaria en y, ambos niveles conservan un desplazamiento de $1/3$ en el largo plazo, pero su diferencia vuelve a cero. Este cálculo ilustra la representación. La interpretación de innovaciones como choques estructurales exige identificación y una normalización de magnitud.

Pronóstico del modelo VEC

Recursión de niveles y diferencias

Dados parámetros estimados, se proyecta:

$$\widehat{\Delta X}_{T+h|T} = \widehat{c} + \widehat{\alpha}\widehat{\beta}'\widetilde{X}_{T+h-1} + \sum_j \widehat{\Gamma}_j \widetilde{\Delta X}_{T+h-j}.$$

Luego se reconstruye el nivel:

$$\widehat{X}_{T+h|T} = \widehat{X}_{T+h-1|T} + \widehat{\Delta X}_{T+h|T}.$$

Las entradas con fecha posterior a T son pronosticadas. Las anteriores son observadas. Los determinísticos futuros se especifican según el diseño.

Pronóstico del modelo VEC

Incertidumbre y vuelta de logaritmos

A horizonte finito, con parámetros tratados como conocidos y covarianza constante:

$$\Omega(h) = \sum_{s=0}^{h-1} \Psi_s \Sigma_u \Psi_s'.$$

Los niveles I(1) no necesitan una varianza incondicional finita para construir esta covarianza de error a horizonte finito.
Si el pronóstico de log-nivel tiene media m_h y varianza v_h bajo normalidad:

$$\text{Mediana}(Y_{T+h} \mid \mathcal{F}_T) = e^{m_h}, \qquad E(Y_{T+h} \mid \mathcal{F}_T) = e^{m_h + v_h/2}.$$

Bandas marginales no incluyen automáticamente incertidumbre de parámetros, rango, selección o revisiones de datos.

Implementación y lectura de VEC

Correspondencia con R y Python

- En `urca::ca.jo`, el argumento `K` representa el número de rezagos del VAR en niveles, aquí denominado p. No representa el número de variables de nuestra notación. La implementación de `ca.jo` requiere al menos dos rezagos en niveles, aunque el VEC teórico también admite $p = 1$.
- `spec="transitory"` utiliza el nivel X_{t-1} y las matrices Γ_j definidas en esta demostración. Otra parametrización cambia esas matrices, no la misma representación de niveles.
- En `statsmodels.VECM`, `k_ar_diff` cuenta diferencias rezagadas y vale $p - 1$.
- Los códigos de determinísticos de diferentes paquetes no se equiparan solo por sus nombres [V4–V5].

Implementación y lectura de VEC

Salidas que deben conservarse

- Muestra, transformaciones, determinísticos, orden en niveles y rango mantenido.
- Estadísticos y valores críticos de traza y máximo autovalor, con decisiones secuenciales.
- $\widehat{\beta}$, su normalización, $\widehat{\alpha}$, $\widehat{\Gamma}_j$, constantes e incertidumbre condicional.
- Pruebas de residuos e interpretación específica de cada nula, junto con sensibilidad y límites.

En R, `cajorls` reporta regresiones condicionadas al rango suministrado. Su salida no decide automáticamente cuántas relaciones existen [V4].

Modelo VEC

Ejercicio resuelto: interpretar una relación en logs

Suponga, solo como ejemplo, que:

$$e_t = \log Y_t - 0.8 \log Z_t - \kappa.$$

Si $e_t = 0.10$, el cociente $Y_t / Z_t^{0.8}$ está $100(e^{0.10} - 1) \simeq 10.52$ por ciento por encima de la referencia e^{κ}.
No significa que Y_t sea aisladamente 10.52 por ciento superior a su nivel óptimo. La desviación combina movimientos de ambas variables y una relación cuya validez debe justificarse.

Modelo VEC

Ejercicio resuelto: corto plazo y exclusión completa

Considere un VEC bivariado de rango uno con $e_t = y_t - bz_t$, $b \neq 0$ y $p = 2$. Si no se rechaza $\gamma_{yz,1} = 0$, pero se rechaza $\alpha_y = 0$, no puede concluirse ausencia completa de Granger de z hacia y.
La razón es:

$$a_{12,1} = -b\alpha_y + \gamma_{yz,1}, \qquad a_{12,2} = -\gamma_{yz,1}.$$

La nula completa exige ambas entradas cero. El nivel de z puede seguir contribuyendo mediante el equilibrio.

Modelo VEC

Ejercicio resuelto: signo e inferencia del ajuste

Con $\beta' = (1, -1)$, las cargas $\alpha_y = -0.20$ y $\alpha_z = 0.10$ reducen un desequilibrio positivo por ambos canales.
Si se cambia la normalización a $(-1, 1)$, las cargas pasan a $(0.20, -0.10)'$ y el modelo no cambia.
La estabilidad no depende de exigir cargas negativas en ambas ecuaciones.
Tampoco un signo esperado sustituye su error estándar o una prueba conjunta cuando hay varias relaciones.

Modelo VEC

Síntesis de la interpretación

El VEC representa una hipótesis conjunta sobre integración, relaciones de niveles y dinámica de cambios.
β define las combinaciones, α describe su ajuste por ecuación y Γ_j recoge la dinámica corta condicionada.
Granger completo exige considerar tanto niveles como diferencias. La validación debe respetar rango y determinísticos y distinguir estabilidad dinámica de constancia histórica.
El informe debe separar evidencia empírica, restricciones mantenidas y ejemplos ilustrativos. Ninguna prueba aislada establece una explicación causal estructural.

Fuentes

BOX, P. G. (2016). *Time Series Analysis: Forecasting and Control* (5th ED.). Wiley, USA.

GUJARATI, D. M. (2010). *Econometría* (5ta. ED.), McGrawHill, México.

GREENE, W. (2000). *Análisis econométrico* (3ra. ED.) Prentice Hall, Madrid.

LÜTKEPOHL, H. (2005) *New Introduction to Multiple Time Series Analysis*. Springer, Germany.

PHILLIPS, B. P. & OULIARIS, S. (1990). *Asymptotic Properties of Residual Based Test for Cointegration*, Econometrica, Vol. 58, N°1. (Jan, 1990). pp. 165-193.

NOVALES, A. (2017). *Modelos vectoriales autorregresivos (VAR). Universidad Complutense*, Madrid.