Long Short-Term Memory (LSTM)

Series de tiempo con Python

Econ. Alexis Adonai Morales Alberto

Octubre de 2026



Introducción

Pregunta central

¿Cómo aprovechar el orden y la historia de una serie cuando su relación predictiva puede ser no lineal y variar con el contexto?

- Una LSTM es una arquitectura de red neuronal recurrente con un estado de memoria y compuertas entrenables.
- Aprende una regla de actualización del estado y una regla de pronóstico.
- Su flexibilidad debe justificarse con evaluación temporal frente a modelos más simples.

Introducción

Ruta del desarrollo

1. Objetivo estadístico y relación con modelos dinámicos.
2. RNN: recurrencia y dificultad del gradiente.
3. Celda LSTM y demostraciones del flujo de memoria.
4. Estimación, retropropagación y regularización.
5. Pronóstico, interpretación y validación temporal.

Las demostraciones emplean una LSTM estándar, sin conexiones *peephole*, sin proyección y con salida escalar lineal.

¿Qué es una LSTM?

Dos estados con funciones diferentes

$$c_t \in \mathbb{R}^m : \text{ estado de la celda,}$$

$$h_t \in \mathbb{R}^m : \text{ estado oculto expuesto.}$$

La red actualiza ambos a partir de x_t y de los estados anteriores. El estado c_t ofrece una vía aditiva para conservar y modificar información; h_t se utiliza en la salida y en la siguiente actualización.

"Long short-term memory'' designa una arquitectura de memoria entrenable. No equivale a memoria larga fraccional de una serie ni prueba que la economía tenga un mecanismo concreto de persistencia.

Principales usos

Dónde puede ser útil

- Demanda eléctrica, ventas o tráfico con abundantes observaciones y dependencias no lineales.
- Pronóstico con varias señales disponibles y diferentes patrones temporales.
- Clasificación de secuencias, reconocimiento de voz y detección de anomalías.

Aquí se estudia **regresión para pronóstico de series**. Las tareas de clasificación requieren otras salidas, pérdidas y métricas.

Con pocas observaciones trimestrales, como suele ocurrir con el PIB, una LSTM grande puede sobreajustar. Su conveniencia es una pregunta empírica.

Fundamento estadístico

Información y variable objetivo

Sea $\mathcal{F}_t$ la información efectivamente disponible al emitir el pronóstico. Para horizonte uno:

$$y_{t+1} = \mu_t + \varepsilon_{t+1}, \qquad \mu_t = E(y_{t+1} \mid \mathcal{F}_t).$$

$$E(\varepsilon_{t+1} \mid \mathcal{F}_t) = 0.$$

La LSTM propone $\widehat{\mu}_t = f_\theta(x_{t-L+1:t})$ para aproximar esa media. Una ventana finita puede omitir información de $\mathcal{F}_t$; la arquitectura y el entrenamiento no garantizan recuperar la media verdadera.

Fundamento estadístico

Por qué el error cuadrático apunta a una media: paso 1

Para cualquier pronóstico a medible respecto a $\mathcal{F}_t$, escribimos:

$$y_{t+1} - a = (y_{t+1} - \mu_t) + (\mu_t - a).$$

Al elevar al cuadrado y condicionar:

$$\begin{aligned} E[(y_{t+1} - a)^2 \mid \mathcal{F}_t] = E[(y_{t+1} - \mu_t)^2 \mid \mathcal{F}_t] \\ + 2(\mu_t - a)E[y_{t+1} - \mu_t \mid \mathcal{F}_t] \\ + (\mu_t - a)^2. \end{aligned}$$

Se requiere segundo momento finito. El término cruzado es cero por la definición de μ_t.

Fundamento estadístico

Por qué el error cuadrático apunta a una media: paso 2

$$E[(y_{t+1} - a)^2 \mid \mathcal{F}_t] = \mathrm{Var}(y_{t+1} \mid \mathcal{F}_t) + (\mu_t - a)^2.$$

La varianza no depende de a. El mínimo se alcanza en $a = \mu_t$.

- El resultado caracteriza el objetivo poblacional bajo pérdida cuadrática.
- Minimizar una pérdida muestral dentro de una clase neuronal limitada no asegura alcanzar ese óptimo.
- Bajo pérdida absoluta el óptimo es una mediana condicional; bajo pérdida cuantílica es un cuantil condicional.

De una RNN a una LSTM

Recurrencia básica

Una RNN sencilla utiliza:

$$a_t = Wx_t + Uh_{t-1} + b, \qquad h_t = \tanh(a_t),$$
$$\widehat{y}_{t+1|t} = v' h_t + b_y.$$

Los mismos W, U, b se comparten entre fechas. Al desplegar la red en el tiempo se obtiene una cadena de operaciones diferenciables.

El estado es una representación aprendida del pasado; sus coordenadas no son automáticamente variables económicas observables.

De una RNN a una LSTM

Demostración del problema del gradiente: paso 1

El Jacobiano de una transición es:

$$J_t = \frac{\partial h_t}{\partial h_{t-1}} = D_t U, \qquad D_t = \mathrm{diag}(1 - h_t^2).$$

Por la regla de la cadena:

$$\frac{\partial h_T}{\partial h_s} = J_T J_{T-1} \cdots J_{s+1}.$$

Cada componente de $1 - h_t^2$ pertenece a $(0, 1]$. Cuando la activación se satura cerca de -1 o 1, su derivada se acerca a cero.

De una RNN a una LSTM

Demostración del problema del gradiente: paso 2

Por submultiplicatividad de una norma matricial inducida:

$$\left\| \frac{\partial h_T}{\partial h_s} \right\| \leq \prod_{t=s+1}^{T} \|J_t\|.$$

Si $\|J_t\| \leq \rho < 1$ uniformemente, entonces:

$$\left\| \frac{\partial h_T}{\partial h_s} \right\| \leq \rho^{T-s} \longrightarrow 0.$$

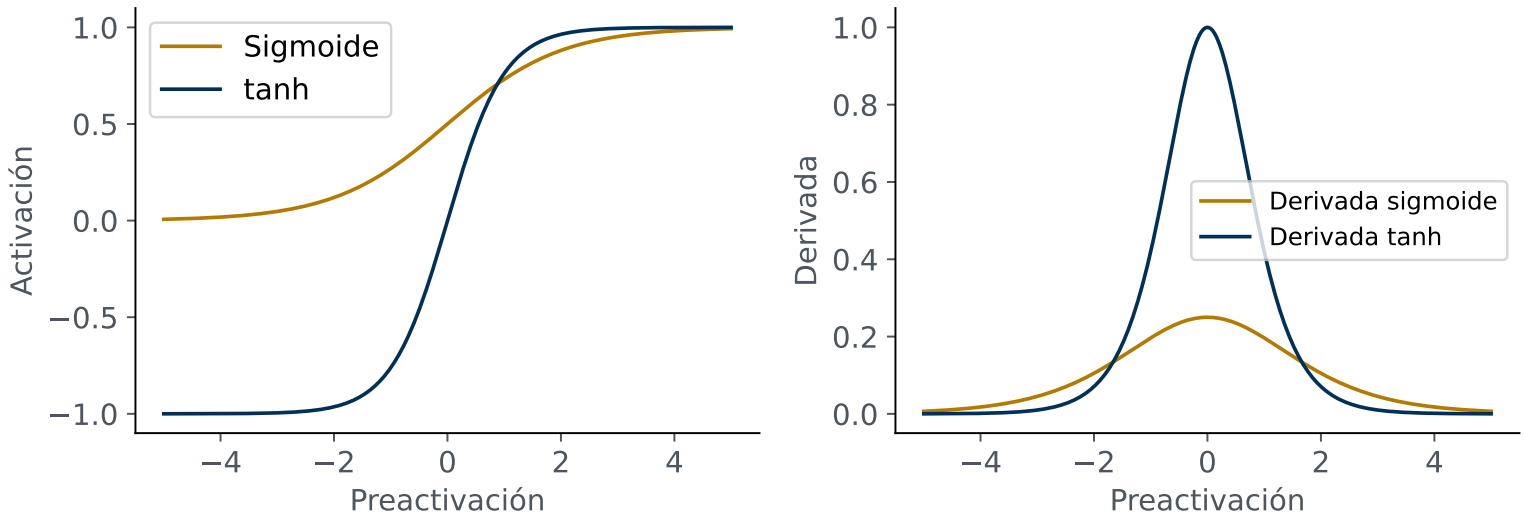
Es una condición suficiente de desvanecimiento. Factores grandes pueden permitir explosión, pero una cota superior mayor que uno **no demuestra** que el producto real explote: también importan las direcciones de los Jacobianos.

Funciones de activación

Compuertas y candidatos

$$\sigma(a) = \frac{1}{1 + e^{-a}}, \quad \sigma'(a) = \sigma(a)[1 - \sigma(a)],$$

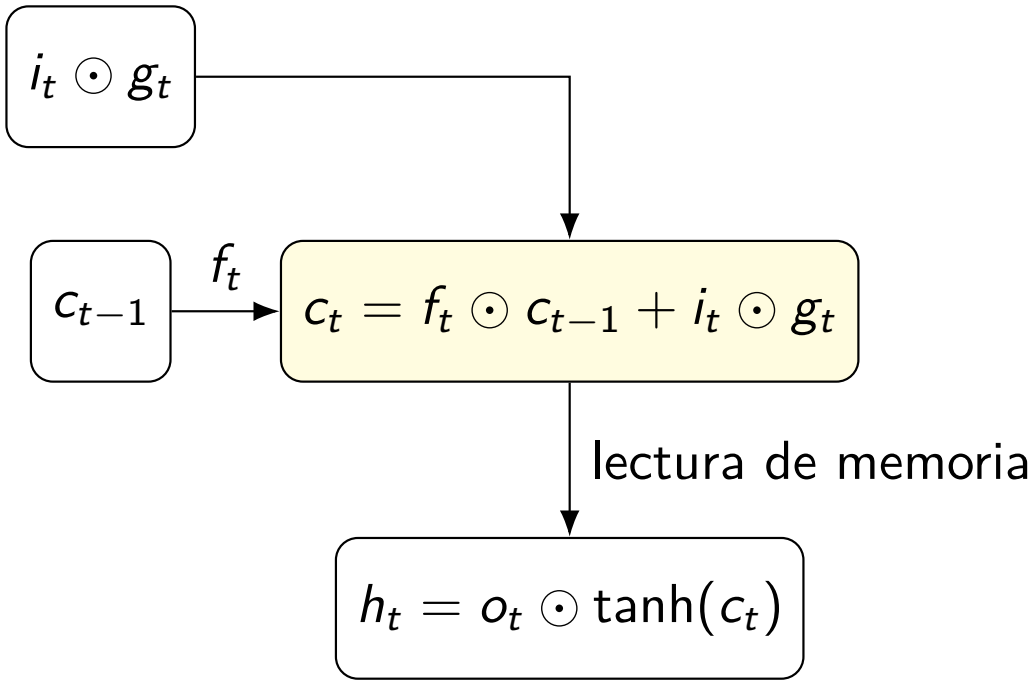
$$\frac{d \tanh(a)}{da} = 1 - \tanh^2(a).$$



La sigmoide entrega factores entre cero y uno; tanh genera candidatos de signo positivo o negativo. Ambas pueden saturarse.

Estructura matemática LSTM

La vía de memoria y su salida



Las compuertas dependen de x_t y h_{t-1}. El esquema resalta el camino aditivo; sus ecuaciones completas se desarrollan a continuación.

Estructura matemática LSTM

Dimensiones de la celda

$$x_t \in \mathbb{R}^d, \quad h_t, c_t \in \mathbb{R}^m.$$

Para $r \in \{f, i, o, g\}$:

$$W_r \in \mathbb{R}^{m \times d}, \quad U_r \in \mathbb{R}^{m \times m}, \quad b_r \in \mathbb{R}^m.$$

Definimos $a_t^r = W_r x_t + U_r h_{t-1} + b_r$. El símbolo $\odot$ representa multiplicación componente a componente; no es un producto matricial.

Los subíndices f, i, o identifican olvido, entrada y salida; g identifica el candidato de memoria.

Estructura matemática LSTM

Paso 1: cuánto conservar y cuánto incorporar

$$f_t = \sigma(a_t^f), \qquad i_t = \sigma(a_t^i),$$
$$g_t = \tanh(a_t^g).$$

- f_t regula la parte del estado anterior que se conserva.
- i_t regula cuánto del candidato g_t se incorpora.
- g_t puede añadir o sustraer memoria, pues tiene signo.

Las compuertas se estiman conjuntamente. No son porcentajes de contribución económica y $f_t + i_t$ no tiene por qué ser uno.

Estructura matemática LSTM

Paso 2: actualizar memoria y producir estado visible

$$c_t = f_t \odot c_{t-1} + i_t \odot g_t,$$

$$o_t = \sigma(a_t^o), \qquad h_t = o_t \odot \tanh(c_t),$$

$$\widehat{y}_{t+1|t} = v' h_t + b_y.$$

La vía de c_{t-1} a c_t es aditiva respecto a la nueva información. La salida utiliza una transformación acotada de la memoria.

Aunque h_t está acotado, c_t no tiene una cota universal independiente del horizonte si los factores de olvido pueden acercarse arbitrariamente a uno.

Estructura matemática LSTM

Demostración: contar los parámetros

Una transformación a_t^r contiene $md + m^2 + m$ parámetros. Hay cuatro transformaciones:

$$N_{\text{celda}} = 4m(d + m + 1).$$

La salida escalar añade $m + 1$ parámetros:

$$N_\theta = 4m(d + m + 1) + (m + 1).$$

Con $d = 1$ y $m = 16$ hay 1 169 parámetros. Aumentar la longitud de la ventana no cambia ese conteo, pero sí el costo y la profundidad temporal. Otras implementaciones pueden usar sesgos adicionales.

Demostración del flujo de memoria

Expansión de la recurrencia: paso 1

Para una coordenada, escribimos $u_t = i_t g_t$:

$$c_t = f_t c_{t-1} + u_t.$$

Sustituyendo una vez:

$$\begin{aligned} c_t &= f_t(f_{t-1} c_{t-2} + u_{t-1}) + u_t \\ &= f_t f_{t-1} c_{t-2} + f_t u_{t-1} + u_t. \end{aligned}$$

Esto permite distinguir el arrastre de memoria antigua y la acumulación de nuevas aportaciones.

Demostración del flujo de memoria

Expansión de la recurrencia: paso 2

Por sustitución sucesiva, o por inducción:

$$c_t = \left(\prod_{j=1}^{t} f_j \right) c_0 + \sum_{s=1}^{t} \left(\prod_{j=s+1}^{t} f_j \right) u_s.$$

El producto vacío vale uno. Si el resultado es válido en $t-1$, multiplicarlo por f_t y sumar u_t produce exactamente la expresión para t.

Es una identidad sobre los valores calculados de las compuertas. No supone que estas sean constantes ni independientes de los estados.

Demostración del flujo de memoria

La vía directa de la derivada

Manteniendo fijas las compuertas y los candidatos del camino:

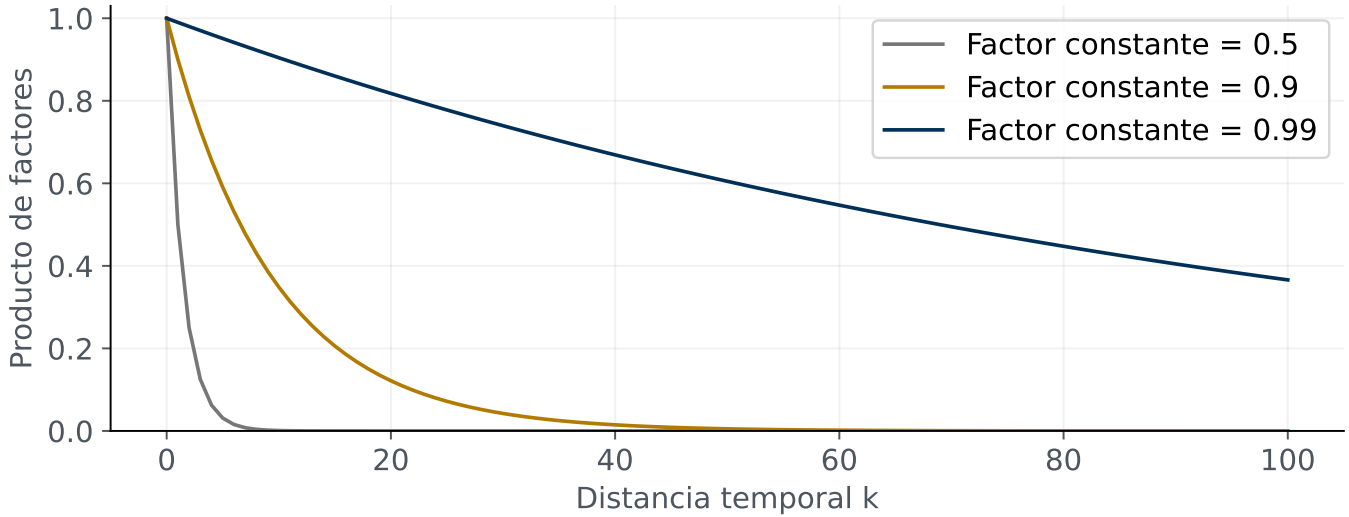
$$\left.\frac{\partial c_t}{\partial c_s}\right|_{\text{vía directa}} = \operatorname{diag}\left(\bigodot_{j=s+1}^{t} f_j\right).$$

Con factores cercanos a uno, esta vía conserva mejor la señal que un producto de activaciones saturadas.

Es **una contribución al gradiente total**. En una LSTM real hay además caminos a través de h y de las compuertas, que también dependen de los estados. La arquitectura no elimina todo desvanecimiento ni toda explosión.

Demostración del flujo de memoria

Interpretación de la persistencia



Si un factor constante es $f \in (0, 1)$, su semivida es:

$$f^k = \frac{1}{2} \quad \Rightarrow \quad k_{1/2} = \frac{\log(1/2)}{\log(f)}.$$

Para $f = .9$: 6.58 pasos; para $f = .99$: 68.97. Es una ilustración de la vía directa, no una estimación de persistencia económica.

Ejemplo numérico de una celda

Cálculo hacia adelante

Supongamos una coordenada con valores ilustrativos:

$$c_{t-1} = .8, \quad f_t = .9, \quad i_t = .2, \quad g_t = .5, \quad o_t = .7.$$

Entonces:

$$c_t = .9(.8) + .2(.5) = .82,$$

$$h_t = .7 \tanh(.82) \simeq .47255.$$

Si $v = 2$ y $b_y = .1$, entonces $\widehat{y}_{t+1|t} \simeq 1.04510$. Los valores elegidos muestran la mecánica; no provienen de una estimación de datos.

Ejemplo numérico de una celda

Lectura de los cálculos

Se conservaron .72 unidades del estado previo y se añadieron .10 del candidato. La compuerta de salida no altera c_t; regula cuánto de $\tanh(c_t)$ se expone como h_t.

Si se estandarizó y mediante $z = (y - \bar{y})/s_y$, una salida $\widehat{z}$ vuelve a la escala original con:

$$\widehat{y} = \bar{y} + s_y \widehat{z}.$$

$\bar{y}$ y s_y se calculan con el pasado de estimación. Una salida estandarizada de 1.04510 no significa crecimiento de 104.51%.

Método de estimación

Riesgo empírico y regularización

Para n ventanas de entrenamiento:

$$J(\theta) = \frac{1}{n} \sum_{t \in \mathcal{T}} \frac{1}{2} (y_{t+1} - f_\theta(X_t))^2 + \frac{\lambda}{2} \|\theta_w\|_2^2.$$

$X_t = x_{t-L+1:t}$; θ_w es el conjunto de pesos penalizados, que debe declararse. Los sesgos pueden excluirse de la penalización.

Se minimiza una función generalmente no convexa mediante gradientes. No hay una solución cerrada como $(X'X)^{-1}X'y$ ni garantía general de mínimo global.

Método de estimación

Cuándo coincide con máxima verosimilitud

Si se especifica secuencialmente:

$$y_{t+1} \mid \mathcal{F}_t \sim N(\mu_{\theta,t}, \sigma^2),$$

la log-verosimilitud negativa condicional es:

$$-\ell(\theta, \sigma^2) = \frac{n}{2} \log(2\pi\sigma^2) + \frac{1}{2\sigma^2} \sum_t (y_{t+1} - \mu_{\theta,t})^2.$$

Para σ^2 fija, minimizarla equivale a minimizar SSE. Sin esa especificación probabilística, MSE sigue siendo un criterio de predicción, pero no debe llamarse automáticamente máxima verosimilitud gaussiana.

Retropropagación en el tiempo

Qué se deriva

Para mostrar BPTT, usamos una secuencia con pérdida en cada fecha:

$$\mathcal{L} = \sum_{t=1}^{T} \ell_t, \quad \ell_t = \tfrac{1}{2} e_t^2, \quad e_t = v' h_t + b_y - y_{t+1}.$$

Denotamos $\bar{h}_t = \partial \mathcal{L} / \partial h_t$ y $\bar{c}_t = \partial \mathcal{L} / \partial c_t$, acumulando todos los caminos futuros.

En una ventana con salida solamente al final, las pérdidas locales anteriores al último paso se hacen cero. El mecanismo de retropropagación es el mismo.

Retropropagación en el tiempo

Paso 1: salida y memoria

Con contribuciones futuras ya acumuladas:

$$\bar{h}_t = ve_t + \sum_{r\in\{f,i,o,g\}} U'_r \bar{a}^r_{t+1},$$

$$\bar{c}_t = \bar{h}_t \odot o_t \odot [1 - \tanh^2(c_t)] + \bar{c}_{t+1} \odot f_{t+1}.$$

Al final se fijan en cero los términos posteriores a T. La primera ecuación recoge la salida local y las cuatro preactivaciones futuras; la segunda recoge la salida de la celda y la conexión directa de memoria.

Retropropagación en el tiempo

Paso 2: derivadas de las cuatro preactivaciones

Aplicando la regla de la cadena componente a componente:

$$
\begin{aligned}
\bar{a}_t^o &= (\bar{h}_t \odot \tanh(c_t)) \odot o_t \odot (1 - o_t), \\
\bar{a}_t^f &= (\bar{c}_t \odot c_{t-1}) \odot f_t \odot (1 - f_t), \\
\bar{a}_t^i &= (\bar{c}_t \odot g_t) \odot i_t \odot (1 - i_t), \\
\bar{a}_t^g &= (\bar{c}_t \odot i_t) \odot (1 - g_t^2).
\end{aligned}
$$

Se recorre $t = T, T-1, \ldots, 1$. Estas expresiones corresponden a la celda estándar indicada; conexiones adicionales cambian el grafo y sus derivadas.

Retropropagación en el tiempo

Paso 3: pesos compartidos y actualización

Cada peso participa en todas las fechas, por lo que:

$$\nabla_{W_r}\mathcal{L} = \sum_t \bar{a}_t^r x_t', \quad \nabla_{U_r}\mathcal{L} = \sum_t \bar{a}_t^r h_{t-1}',$$

$$\nabla_{b_r}\mathcal{L} = \sum_t \bar{a}_t^r, \quad \nabla_v\mathcal{L} = \sum_t e_t h_t, \quad \partial\mathcal{L}/\partial b_y = \sum_t e_t.$$

En el objetivo promedio se divide por n y se añade $\lambda\theta_w$ a los pesos penalizados. Descenso básico: $\theta^{(k+1)} = \theta^{(k)} - \eta\nabla J(\theta^{(k)})$.

Método de estimación

Adam: momentos del gradiente

Sea $g_a = \nabla J_a(\theta_{a-1})$ el gradiente del lote en la iteración a. Con $m_0 = v_0 = 0$:

$$m_a = \beta_1 m_{a-1} + (1 - \beta_1) g_a,$$

$$v_a = \beta_2 v_{a-1} + (1 - \beta_2)(g_a \odot g_a).$$

Se corrige el sesgo inicial de estas medias móviles:

$$\widehat{m}_a = \frac{m_a}{1 - \beta_1^a}, \qquad \widehat{v}_a = \frac{v_a}{1 - \beta_2^a}.$$

Aquí v_a es un acumulador del optimizador, no el vector de pesos de salida usado en las ecuaciones de la red.

Método de estimación

Adam: actualización y alcance

La actualización se calcula componente a componente:

$$\theta_a = \theta_{a-1} - \eta \frac{\widehat{m}_a}{\sqrt{\widehat{v}_a} + \epsilon}, \qquad \epsilon > 0.$$

El numerador suaviza la dirección del gradiente; el denominador adapta la escala de cada coordenada. La tasa η y los controles del entrenamiento siguen siendo importantes.

Adam es un algoritmo de optimización. Su uso no implica una distribución posterior de parámetros, errores estándar válidos o convergencia garantizada al mejor predictor.

Entrenamiento y regularización

Controles con propósitos distintos

- **Recorte del gradiente:** $g \leftarrow g \min(1, \tau/\|g\|)$ limita actualizaciones grandes; no recupera gradientes ya desvanecidos.
- **Parada temprana:** escoge la época con mejor pérdida en un bloque posterior de validación.
- **Penalización y dropout:** restringen o perturban el ajuste para reducir sobreajuste; sus intensidades se seleccionan temporalmente.
- **BPTT truncada:** limita la distancia de retropropagación. Conservar el estado numérico no significa conservar gradientes a través de toda la historia.

Metodología de modelación

Paso 1: definir la pregunta antes de estimar

Declarar variable objetivo, frecuencia, horizonte H, pérdida y fecha de información. Por ejemplo: pronosticar demanda diaria a $H = 10$ días con los datos conocidos al cierre de hoy.

Revisar duplicados, calendario, faltantes, atípicos, cambios de definición y rezagos de publicación. En macroeconomía, distinguir datos revisados de las versiones disponibles en tiempo real.

Una variable fechada en t pero publicada después no pertenece necesariamente a $\mathcal{F}_t$.

Metodología de modelación

Paso 2: transformaciones y ventanas

Una muestra para horizonte h es:

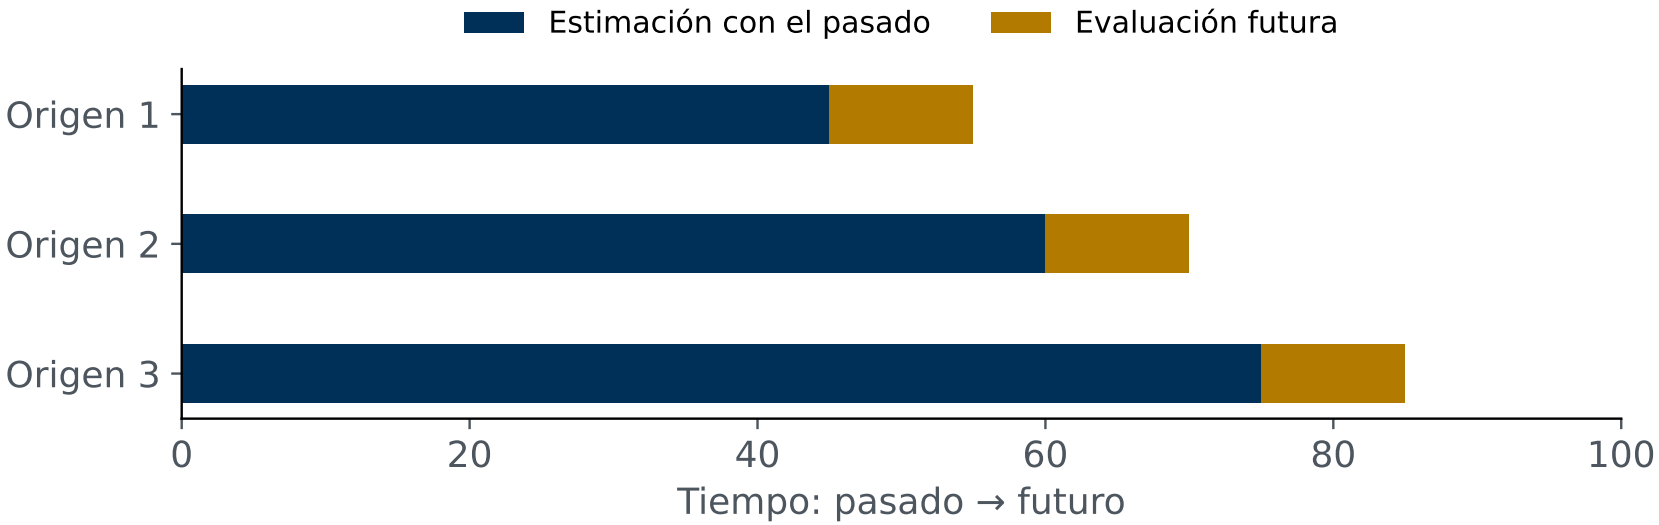
$$X_t = (x_{t-L+1}, \ldots, x_t), \qquad Y_t = y_{t+h}.$$

Si existen T fechas completas, $t = L, \ldots, T - h$ produce $T - L - h + 1$ muestras. Ventanas solapadas no son observaciones independientes nuevas.

Imputación, escalamiento y selección de variables se ajustan dentro de cada pasado de entrenamiento. Un suavizado centrado que usa datos futuros produce fuga de información.

Metodología de modelación

Paso 3: estimación y selección temporal



En cada origen se entrena con el pasado y se evalúa lo que habría sido futuro. La ventana puede ser expansiva o móvil.

Seleccionar L, m, λ, época y tasa de aprendizaje con orígenes internos; reservar orígenes externos para evaluar la decisión completa. Después puede reestimarse con toda la información disponible.

Metodología de modelación

Qué significa respetar el tiempo

La evaluación de pronósticos futuros no debe usar una partición aleatoria convencional. Si una muestra de entrenamiento tiene origen t y etiqueta y_{t+h}, esa etiqueta debe estar observada al cerrar el bloque de estimación.

Usar historia anterior dentro de una ventana de evaluación es legítimo: esa historia ya era conocida. Es distinto de entrenar con sus etiquetas futuras.

Evaluar fuera de muestra y estimar finalmente con todos los datos son actividades compatibles; el ajuste total no reemplaza la evidencia de desempeño futuro.

Supuestos y alcance

Condiciones que deben explicitarse

- La información predictiva usada estará disponible también al operar el modelo.
- La distribución o los mecanismos relevantes serán suficientemente estables entre estimación y uso.
- Para MSE se necesitan segundos momentos finitos; resultados asintóticos bajo dependencia requieren hipótesis adicionales, como condiciones de mezcla y control de complejidad.
- La arquitectura y los datos permiten aproximar una relación útil sin excesivo sobreajuste.

La normalidad y homocedasticidad no son requisitos algebraicos para calcular una LSTM.

Supuestos y alcance

Estacionariedad, diferencias y cointegración

La LSTM no impone una raíz unitaria o un rango de cointegración. Tampoco convierte automáticamente una serie no estacionaria en una relación estable.

ADF y KPSS ayudan a caracterizar persistencia bajo sus hipótesis; no seleccionan por sí solas la arquitectura. Diferenciar o quitar tendencia puede facilitar aprendizaje, pero altera la variable pronosticada y exige reconstruir niveles.

Una red en diferencias no conserva por construcción relaciones de largo plazo de un VEC. Si estas importan, deben incorporarse o verificarse explícitamente.

Interpretación del modelo

Qué se puede leer de los pesos

Un peso combina escalamiento, activación, compuertas y otras rutas. Su signo aislado no equivale al signo del efecto de una variable sobre el pronóstico.

Un efecto marginal local puede definirse como:

$$M_{t,j,\ell} = \frac{\partial \widehat{y}_{t+1|t}}{\partial x_{t-\ell,j}}.$$

Se obtiene por regla de la cadena y se evalúa en una historia concreta. Es sensibilidad predictiva condicionada al modelo, no un efecto causal identificado ni una elasticidad salvo que las escalas lo justifiquen.

Interpretación del modelo

Ablación y explicaciones locales

Comparar errores al retirar una variable o un grupo de rezagos informa sobre su valor predictivo incremental, si la comparación utiliza el mismo protocolo temporal y vuelve a entrenar cuando corresponde.

Permutar fechas al azar puede crear historias imposibles. Preferir perturbaciones plausibles, bloques o escenarios coherentes.

Las compuertas muestran un cálculo interno. No permiten concluir por sí solas que una crisis fue causada por una señal, ni que la red descubrió un mecanismo económico estructural.

Pronóstico a varios periodos

Recursivo, directo y de salida múltiple

- **Recursivo:** entrenar un paso, alimentar las predicciones como futuros valores desconocidos y repetir.
- **Directo:** entrenar f_{θ_h} para cada horizonte h.
- **Salida múltiple:** entrenar un vector $(\widehat{y}_{t+1|t}, \ldots, \widehat{y}_{t+H|t})$ con una pérdida conjunta.

Las variables futuras de entrada deben ser conocidas, pronosticadas o fijadas como escenario. No se pueden sustituir por sus realizaciones futuras al evaluar un pronóstico genuino de H pasos.

Pronóstico a varios periodos

Demostración: iterar medias no siempre da la media futura

Si $y_{t+1} = f(y_t) + \varepsilon_{t+1}$ con error de media cero:

$$E(y_{t+2} \mid \mathcal{F}_t) = E[f(y_{t+1}) \mid \mathcal{F}_t],$$

que generalmente difiere de $f(E[y_{t+1} \mid \mathcal{F}_t])$. Por ejemplo, si $f(z) = z^2$:

$$E[f(y_{t+1}) \mid \mathcal{F}_t] = \mu_t^2 + \sigma_t^2 \neq \mu_t^2 = f(\mu_t).$$

En una LSTM, propagar solamente valores centrales también omite la distribución de estados futuros. Para medias multihorizonte puede usarse integración por simulación bajo un modelo probabilístico explícito.

Pronóstico probabilístico

Una salida puntual no es un intervalo

Una extensión especifica:

$$\mu_t = v'_\mu h_t + b_\mu, \qquad \sigma_t^2 = \log(1 + e^{v'_s h_t + b_s}) + \epsilon,$$

con $\epsilon > 0$, y una distribución condicional gaussiana. Se minimiza:

$$\sum_t \left[\frac{1}{2} \log \sigma_t^2 + \frac{(y_{t+1} - \mu_t)^2}{2\sigma_t^2} \right].$$

Esta forma modela varianza positiva. Su adecuación distributiva y su calibración deben evaluarse; una distribución gaussiana no queda demostrada por usar esa pérdida.

Pronóstico probabilístico

Cuantiles y simulación

Para cuantil τ, usar la pérdida:

$$\rho_\tau(u) = u[\tau - \mathbf{1}(u < 0)], \qquad u = y - q_\tau.$$

Su derivada poblacional respecto a q es $F(q) - \tau$ en puntos regulares: el mínimo satisface $F(q) = \tau$.

Intervalos entre cuantiles deben evitar cruces y comprobar cobertura. Simular innovaciones y estados exige declarar su distribución; bootstrap residual iid no es adecuado si quedan dependencia o varianza cambiante. Dispersión entre semillas no cubre por sí sola toda la incertidumbre predictiva.

Validación del modelo

Tres preguntas diferentes

1. **Optimización:** ¿convergió el procedimiento y son reproducibles los resultados entre semillas?
2. **Generalización:** ¿mejora pronósticos futuros frente a ingenuo, ingenuo estacional, ARIMA o NNAR?
3. **Especificación probabilística:** ¿residuos e intervalos concuerdan con las hipótesis declaradas?

Una pérdida de entrenamiento pequeña solo responde parcialmente a la primera pregunta. Ninguna prueba aislada certifica que el modelo completo sea correcto.

Validación del modelo

Medidas de pronóstico por horizonte

Para errores genuinos $e_{o,h} = y_{o+h} - \widehat{y}_{o+h|o}$:

$$MAE_h = \frac{1}{N_h} \sum_o |e_{o,h}|, \quad RMSE_h = \sqrt{\frac{1}{N_h} \sum_o e_{o,h}^2}.$$

MAE mide error absoluto típico; RMSE penaliza más los errores grandes. Reportar unidades, horizontes, orígenes y dispersión, no únicamente un promedio agregado.

MASE escala MAE por el error ingenuo calculado en el pasado de entrenamiento. MAPE resulta problemática con ceros, signos cambiantes o valores cercanos a cero.

Validación del modelo

Autocorrelación y predicción remanente

Para errores de un paso, inspeccionar serie, ACF y relación con información pasada. Bajo media condicional correcta:

$$E(e_{t+1} z_t) = 0 \quad \text{para } z_t \in \mathcal{F}_t$$

si existen los momentos. Es más fuerte que autocorrelación lineal nula.

Ljung–Box explora autocorrelaciones hasta m; su referencia clásica χ^2 tras estimación de una red flexible no se obtiene restando mecánicamente el número de pesos. Usar un diseño justificable, evaluación separada o bootstrap que reproduzca ajuste y selección.

Validación del modelo

Heterocedasticidad y normalidad

ARCH-LM regresa cuadrados de errores sobre sus rezagos y contrasta que las pendientes sean cero. Un rechazo sugiere dinámica de segundo momento bajo las condiciones del contraste; obliga a revisar la incertidumbre, no necesariamente a abandonar la media.

Q–Q y Jarque–Bera exploran discrepancias frente a normalidad. La normalidad no es necesaria para pronóstico MSE.

En redes estimadas, los valores p convencionales no son automáticos por selección, regularización y dependencia. Con varianza condicional modelada, revisar residuos estandarizados además de errores brutos.

Validación del modelo

Errores multihorizonte e intervalos

Errores de $h > 1$ pueden estar correlacionados por solapamiento incluso con un modelo bien especificado. No exigirles ruido blanco usando el mismo criterio de un paso.

Para intervalo $[L_{o,h}, U_{o,h}]$:

$$\widehat{C}_h = \frac{1}{N_h} \sum_o \mathbf{1}\{L_{o,h} \leq y_{o+h} \leq U_{o,h}\}.$$

Una cobertura cercana al nivel nominal es necesaria, pero intervalos enormes pueden obtenerla trivialmente. Revisar anchura y cobertura por régimen; las bandas de incertidumbre de esa cobertura deben reconocer la dependencia entre orígenes.

Validación del modelo

Cambios de régimen y comparación formal

Graficar pérdidas por origen, cobertura y sesgo por subperiodo. Buscar deterioro tras rupturas, revisiones de datos o cambios de escala.

Para comparar modelos, $d_o = L(e^A_{o,h}) - L(e^B_{o,h})$ permite estudiar si $E(d_o) = 0$. Contrastes tipo Diebold–Mariano necesitan una estimación válida de la varianza de largo plazo y cautela con pocos orígenes o modelos seleccionados reiteradamente.

No usar el mismo bloque para escoger muchas arquitecturas y después presentarlo como evidencia final independiente.

Implementación y reproducibilidad

Estructura mínima en Python; esquema sin ejecución

```
from keras import Sequential, Input
from keras.layers import LSTM, Dense

modelo = Sequential([
    Input(shape=(L, d)),
    LSTM(m),
    Dense(1)
])
modelo.compile(optimizer="adam", loss="mse")
```

La entrada tiene forma (n, L, d). Este esquema define una arquitectura, no una estimación validada. Faltan datos, bloques temporales, escalamiento, controles de entrenamiento y evaluación.

Implementación y reproducibilidad

Estados e información disponible

En entrenamiento por ventanas independientes pueden reiniciarse los estados en cada muestra. Con estados persistentes se debe mantener continuidad, separar series y reiniciar al cambiar de tramo cuando corresponda.

No transferir estados desde fechas futuras hacia fechas anteriores. Una red bidireccional puede procesar una ventana histórica completa si toda ella era conocida; usar posiciones posteriores al origen contamina el pronóstico.

Guardar versiones, semillas, transformaciones, índices de ventanas, hiperparámetros y pesos. La semilla ayuda a reproducir; algunas operaciones de hardware requieren controles adicionales.

Ejercicio resuelto

Crecimiento frente a nivel del PIB

Si $g_t = 100\Delta \log Y_t$ y la red pronostica $\widehat{g}_{T+1|T} = .8$:

$$\widehat{\log Y}_{T+1} = \log Y_T + .008,$$
$$\widetilde{Y}_{T+1} = Y_T e^{.008}.$$

El aumento implícito de esa trayectoria central es $100(e^{.008} - 1) \simeq .8032\%$.

Si el logaritmo futuro tiene distribución normal con media μ y varianza s^2, e^{μ} es mediana y la media es $e^{\mu + s^2/2}$. Reconstruir niveles exige distinguir ambas.

Ejercicio de interpretación

Una red parece perfecta dentro de muestra

Entrenamiento RMSE = .05; evaluación temporal RMSE = .90; ingenuo estacional RMSE = .65, en las mismas unidades y fechas.

- La red ajusta muy bien el pasado y pierde frente al referente en la evaluación realizada.
- Revisar complejidad, fuga, escalamiento y cambios de régimen antes de ampliar la red.
- No concluir superioridad por el RMSE interno ni corregir hiperparámetros repetidamente mirando el bloque final.

Son cifras ilustrativas; no resultados del PIB ni de una aplicación estimada.

Fuentes

Arquitectura y entrenamiento

- Hochreiter, S. y Schmidhuber, J. (1997). *Long Short-Term Memory*. Neural Computation, 9(8), 1735–1780. Artículo original.
- Gers, F. A., Schmidhuber, J. y Cummins, F. (2000). *Learning to Forget: Continual Prediction with LSTM*. Neural Computation, 12(10), 2451–2471. Compuerta de olvido.
- Goodfellow, I., Bengio, Y. y Courville, A. (2016). *Deep Learning*, cap. 10. Redes recurrentes y BPTT.

Se desarrolla la variante moderna con compuerta de olvido; no se atribuyen todas sus ecuaciones a la arquitectura original de 1997.

Fuentes

Implementación y metodología

- Kingma, D. P. y Ba, J. (2015). *Adam: A Method for Stochastic Optimization*. Artículo.
- Keras. Documentación oficial de la capa LSTM. Consultada el 30 de octubre de 2026.
- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3.ª ed., secciones de evaluación temporal y redes neuronales. Texto de los autores.

Las demostraciones algebraicas y los ejemplos numéricos son desarrollos didácticos de esta presentación. Las figuras representan funciones y simulaciones declaradas; no constituyen resultados empíricos ni pruebas de superioridad de LSTM.