Redes neuronales autorregresivas (NNAR)

Series de tiempo con Python

Econ. Alexis Adonai Morales Alberto

Octubre de 2026



Introducción

De un AR lineal a una autorregresión neuronal

Un AR utiliza rezagos de una serie para predecirla. Una red neuronal autorregresiva conserva esa idea y reemplaza la combinación lineal por una función no lineal estimada.

$$y_t = f_\theta(y_{t-1}, \ldots, y_{t-p}) + \varepsilon_t.$$

El objetivo es modelar una relación predictiva flexible. La complejidad se justifica si mejora la evaluación temporal y produce una incertidumbre adecuada.

Introducción

Alcance y ruta del desarrollo

Se estudia NNAR: una red de alimentación hacia adelante con rezagos como entradas. No se usa "autorregresiva'' como sinónimo de red recurrente.

1. Modelo estadístico y estructura matemática.
2. Relación con AR, no linealidad y efectos marginales.
3. Estimación y demostración de retropropagación.
4. Estabilidad y pronóstico multihorizonte.
5. Metodología, validación y lectura económica.

¿Qué es una red NNAR?

Memoria explícita mediante entradas rezagadas

Cada fila de datos contiene observaciones anteriores. La red transforma esa fila en una predicción.

- La memoria se fija mediante el conjunto de rezagos.
- No hay un estado oculto persistente que se actualice entre filas como en una LSTM.
- Al pronosticar recursivamente sí se realimentan valores pronosticados a futuras entradas.

Una NNAR puede ser útil con ciclos asimétricos, saturación o interacciones entre rezagos que un AR lineal no representa bien.

Principales usos

Problemas de pronóstico

- Ventas y demanda con respuesta no lineal a su historia.
- Series con estacionalidad conocida y suficientes ciclos observados.
- Procesos con expansión y contracción asimétricas.
- Referente neuronal sencillo para comparar con LSTM, ARIMA y ETS.

Para series macroeconómicas cortas conviene limitar rezagos y neuronas. Una red flexible no crea información adicional ni garantiza extrapolar rupturas, crisis o tendencias inéditas.

Fundamento estadístico

Especificación condicional

Sea z_t un vector de q entradas conocidas antes de observar y_t:

$$y_t = f_\theta(z_t) + \varepsilon_t, \qquad E(\varepsilon_t \mid \mathcal{F}_{t-1}) = 0.$$

Entonces $f_\theta(z_t) = E(y_t \mid \mathcal{F}_{t-1})$ solamente si la especificación recoge correctamente esa media.

La arquitectura por sí sola es un mapa determinista. La ecuación de error añade el componente estadístico; su distribución y varianza deben declararse para realizar inferencia o simulación probabilística.

Estructura matemática NNAR

Una capa oculta y salida lineal

Para neurona $j = 1, \ldots, k$:

$$a_{jt} = b_j + \sum_{\ell=1}^{q} w_{j\ell} z_{t\ell}, \qquad s_{jt} = g(a_{jt}),$$

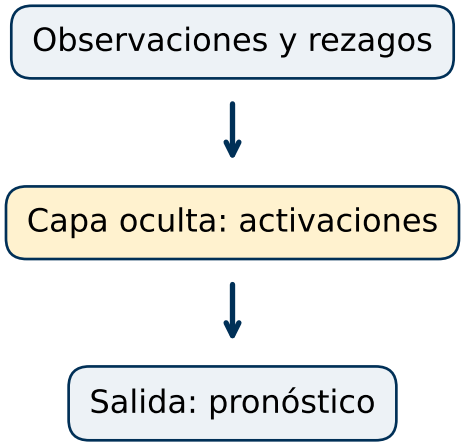
$$f_\theta(z_t) = b_0 + \sum_{j=1}^{k} v_j s_{jt}.$$

g puede ser sigmoide, tanh u otra activación. En regresión, una salida lineal evita restringir artificialmente el rango del objetivo.

No confundir neuronas ocultas k con rezagos p, ni con número de variables de un VAR.

Estructura matemática NNAR

Flujo de información



Los rezagos entran juntos a la red. Cada neurona oculta puede combinar varios rezagos y generar interacciones no lineales.

Estructura matemática NNAR

Conteo de parámetros: demostración

La capa oculta tiene kq pesos y k sesgos. La salida tiene k pesos y un sesgo:

$$N_\theta = kq + k + k + 1 = k(q + 2) + 1.$$

Con $q = 12$, $k = 5$: $N_\theta = 71$.

El conteo corresponde a una sola red, una capa oculta y sin conexiones lineales directas. Promediar varias redes no convierte el conjunto en un estimador lineal ni proporciona automáticamente grados de libertad clásicos para pruebas residuales.

Notación y estacionalidad

NNAR no estacional y estacional

- NNAR(p, k): rezagos $1, \ldots, p$ y k neuronas ocultas.
- NNAR$(p, P, k)_m$: añadir rezagos estacionales $m, 2m, \ldots, Pm$.

El conjunto de entradas temporales es:

$$\mathcal{L} = \{1, \ldots, p\} \cup \{m, 2m, \ldots, Pm\}.$$

Se usan rezagos únicos; si $m \leq p$, el rezago m no debe duplicarse. P cuenta rezagos estacionales, no diferencias; esta notación no incorpora automáticamente los operadores de un SARIMA.

Notación y estacionalidad

Ejemplo de diseño trimestral

NNAR$(2, 1, 3)_4$ emplea $\mathcal{L} = \{1, 2, 4\}$ y tres neuronas:

$$z_t = (y_{t-1}, y_{t-2}, y_{t-4})'.$$

Por tanto, $q = 3$ y $N_\theta = 3(3 + 2) + 1 = 16$.

La muestra empieza cuando el rezago cuatro está observado. Un patrón trimestral puede motivar ese rezago; su utilidad se verifica temporalmente. La frecuencia de una serie no demuestra que tenga estacionalidad ni determina por sí sola el tamaño óptimo de la red.

Relación con el modelo AR

Demostración con activación identidad: paso 1

Si $g(a) = a$:

$$f_\theta(z_t) = b_0 + \sum_j v_j \left(b_j + \sum_\ell w_{j\ell} z_{t\ell} \right)$$
$$= \left(b_0 + \sum_j v_j b_j \right) + \sum_\ell \left(\sum_j v_j w_{j\ell} \right) z_{t\ell}.$$

Definimos $c = b_0 + \sum_j v_j b_j$ y $\phi_\ell = \sum_j v_j w_{j\ell}$.

Relación con el modelo AR

Demostración con activación identidad: paso 2

Si $z_t = (y_{t-1}, \ldots, y_{t-p})'$:

$$y_t = c + \sum_{\ell=1}^{p} \phi_\ell y_{t-\ell} + \varepsilon_t.$$

La red con activaciones identidad se reduce a un AR lineal. Sus pesos internos no se identifican de forma única: muchas factorizaciones producen los mismos ϕ_ℓ.

Con activación sigmoide o tanh, la NNAR estándar no es exactamente el mismo AR global. Puede aproximar funciones lineales en un dominio acotado; no debe afirmarse igualdad por analogía de notación.

Relación con el modelo AR

Aproximación local: derivación

Alrededor de una entrada z^* y para g diferenciable:

$$f_\theta(z) \simeq f_\theta(z^*) + \nabla f_\theta(z^*)'(z - z^*).$$

El coeficiente local del rezago ℓ es:

$$\frac{\partial f_\theta(z)}{\partial z_\ell} = \sum_{j=1}^{k} v_j g'(a_j) w_{j\ell}.$$

A diferencia de un AR, esa sensibilidad cambia con la historia z. Es una aproximación de primer orden, no una ley lineal global ni un efecto causal.

Demostración de no linealidad

Interacciones entre entradas

Si g es dos veces diferenciable:

$$\frac{\partial^2 f_\theta(z)}{\partial z_r \partial z_s} = \sum_j v_j g''(a_j) w_{jr} w_{js}.$$

Puede ser distinta de cero incluso sin crear explícitamente productos $z_r z_s$. El efecto de un rezago depende del valor de otros rezagos que llegan a la misma neurona.

Una red con ReLU es lineal por regiones: sus segundas derivadas son cero dentro de cada región y la derivada puede cambiar en los puntos de quiebre.

Interpretación de los coeficientes

Por qué no leer un peso como una pendiente de regresión

El efecto de z_ℓ combina $w_{j\ell}$, v_j y la derivada de la activación. Por ello, un peso positivo no garantiza una sensibilidad total positiva.

Además, permutar neuronas ocultas junto con sus pesos deja el pronóstico intacto. En redes con tanh, cambiar el signo de todos los pesos y del sesgo de una neurona, y también de su peso de salida, preserva su contribución.

Estas simetrías impiden interpretar la etiqueta de una neurona como un parámetro económico identificado.

Interpretación de los coeficientes

Escalamiento y unidades: demostración

Si $z_\ell = (x_\ell - \bar{x}_\ell)/s_\ell$ y $\widehat{y} = \bar{y} + s_y f_\theta(z)$:

$$\frac{\partial \widehat{y}}{\partial x_\ell} = \frac{s_y}{s_\ell} \frac{\partial f_\theta(z)}{\partial z_\ell}.$$

La sensibilidad en escala estandarizada debe convertirse antes de interpretarse en unidades originales. Si tanto entrada como salida están en logaritmos, la derivada respecto al logaritmo puede leerse como elasticidad local del pronóstico, condicionada al modelo.

No equivale a una elasticidad causal estructural.

Ejemplo numérico NNAR

Una neurona y un rezago

Para el mapa ilustrativo $f(y) = .2 + 1.2\tanh(.8y)$ y $y_t = .7$:

$$\widehat{y}_{t+1|t} = .2 + 1.2\tanh(.56) \simeq .80957.$$

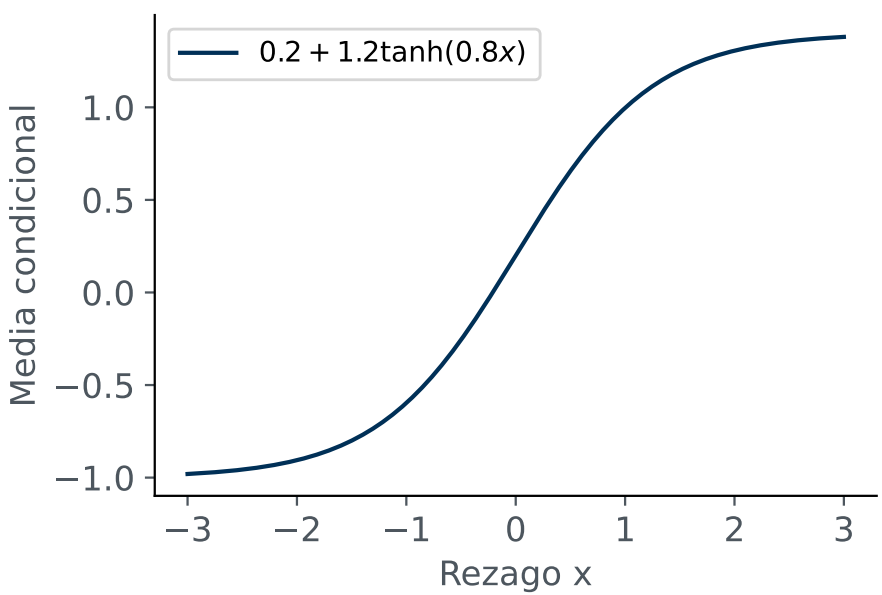
Su pendiente local es:

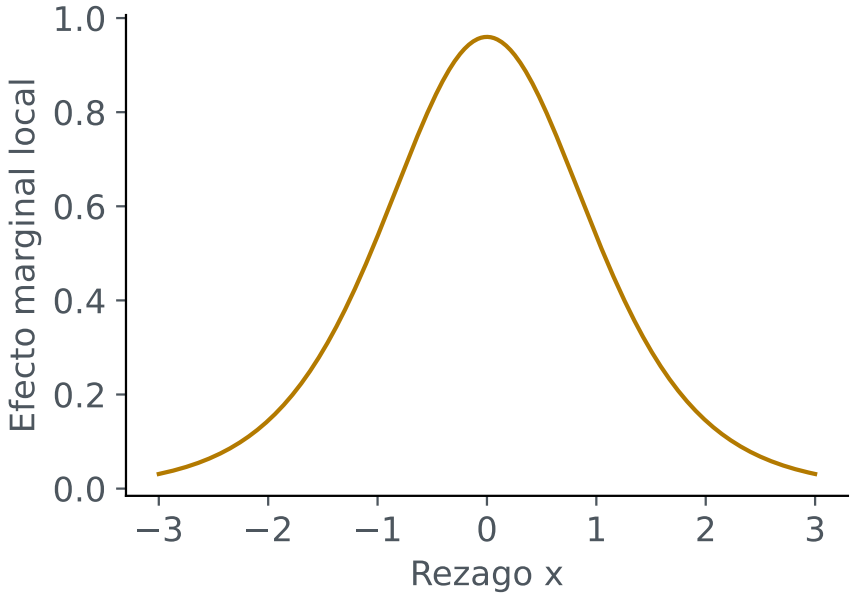
$$f'(.7) = .96[1 - \tanh^2(.56)] \simeq .71228.$$

Una variación pequeña de .01 en ese rezago modifica el pronóstico aproximadamente .00712. Es un cálculo local, no una respuesta constante para cualquier nivel.

Ejemplo numérico NNAR

Curva y pendiente de la misma red





La saturación reduce el efecto marginal cuando $|y|$ crece. La salida central y la sensibilidad son objetos distintos. La figura muestra una función elegida para enseñar el cálculo, no una función estimada de datos económicos.

Demostración del objetivo MSE

Sea $\mu(z) = E(y \mid z)$ y un predictor $a(z)$. Entonces:

$$\begin{aligned} E[(y-a)^2 \mid z] &= E[(y-\mu+\mu-a)^2 \mid z] \\ &= \text{Var}(y \mid z) + (\mu - a)^2, \end{aligned}$$

porque $E(y - \mu \mid z) = 0$. El mínimo poblacional es $a(z) = \mu(z)$ si existe el segundo momento.

Una NNAR estima una aproximación en una clase de funciones. Error de aproximación, variación muestral y error de optimización pueden alejarla del óptimo.

Método de estimación

Función objetivo

Para n filas temporales completas:

$$J(\theta) = \frac{1}{2n} \sum_t [y_t - f_\theta(z_t)]^2 + \frac{\lambda}{2} \|\theta_w\|_2^2.$$

Se eligen pesos para reducir error y penalización. λ controla la contracción de los pesos; las entradas deben escalarse consistentemente para que la penalización sea comparable.

Si se especifican errores condicionalmente normales con varianza constante, el término SSE corresponde a su verosimilitud condicional, salvo escala y constantes. Sin esa hipótesis, es un criterio de mínimos cuadrados no lineales.

Demostración de retropropagación

Paso 1: salida

Para una fila, $r_t = f_\theta(z_t) - y_t$ y $\ell_t = \frac{1}{2} r_t^2$:

$$\frac{\partial \ell_t}{\partial f} = r_t,$$

$$\frac{\partial \ell_t}{\partial v_j} = r_t s_{jt}, \qquad \frac{\partial \ell_t}{\partial b_0} = r_t.$$

El signo de r_t importa: aquí es predicción menos observado. El residual convencional de diagnóstico es su negativo, $e_t = y_t - \widehat{y}_t$; ambos producen la misma pérdida cuadrática.

Demostración de retropropagación

Paso 2: capa oculta

Por la regla de la cadena:

$$\frac{\partial \ell_t}{\partial a_{jt}} = r_t v_j g'(a_{jt}),$$

$$\frac{\partial \ell_t}{\partial w_{j\ell}} = r_t v_j g'(a_{jt}) z_{t\ell}, \qquad \frac{\partial \ell_t}{\partial b_j} = r_t v_j g'(a_{jt}).$$

Si $g = \tanh$, sustituir $g'(a) = 1 - g(a)^2$. Si $g = \sigma$, usar $g'(a) = g(a)[1 - g(a)]$. No hay retropropagación entre fechas en este ajuste por filas de una red de alimentación hacia adelante.

Demostración de retropropagación

Paso 3: promedio y penalización

Para un peso penalizado:

$$\frac{\partial J}{\partial w_{j\ell}} = \frac{1}{n}\sum_{t} r_t v_j g'(a_{jt}) z_{t\ell} + \lambda w_{j\ell}.$$

Actualizar:

$$w_{j\ell}^{(a+1)} = w_{j\ell}^{(a)} - \eta \frac{\partial J}{\partial w_{j\ell}}.$$

La pérdida no es convexa en todos los pesos conjuntamente. Utilizar varios inicios y reportar sensibilidad ayuda a detectar soluciones inestables; no demuestra que se haya encontrado el mínimo global.

Demostración de retropropagación

Paso 4: una actualización numérica

En el ejemplo $f(y) = b_0 + v\tanh(wy)$, con $y = .7$, objetivo $= .6$, $v = 1.2$, $w = .8$ y $b_0 = .2$:

$$r \simeq .20957, \qquad \frac{\partial \ell}{\partial w} = r(1.2)[1 - \tanh^2(.56)](.7) \simeq .13062.$$

Si $\eta = .1$ y $\lambda = 0$:

$$w_{\text{nuevo}} \simeq .8 - .1(.13062) = .78694.$$

Se muestra una coordenada de una actualización. Una iteración real actualiza también los demás parámetros usando sus derivadas.

Regularización y selección

No confundir capacidad con evidencia

Más rezagos y neuronas permiten representar más formas, pero aumentan la posibilidad de memorizar ruido.

- Regularizar pesos y limitar tamaño de la red.
- Seleccionar p, P, k, λ y criterio de parada en orígenes temporales internos.
- Examinar varios inicios con el mismo diseño de evaluación.
- Promediar redes puede reducir variación por inicialización; no corrige fuga de información ni sesgo de especificación.

Un AIC de AR puede sugerir rezagos iniciales, pero no identifica necesariamente el orden predictivo óptimo de una NNAR.

Supuestos y alcance

Dependencia temporal y estabilidad del aprendizaje

Las filas con rezagos están relacionadas. La minimización numérica no necesita independencia entre filas, pero la justificación estadística de generalización e inferencia sí requiere tratar la dependencia.

Estacionariedad y ergodicidad, junto con momentos y condiciones de regularidad, pueden apoyar leyes de grandes números. No basta mencionarlas para garantizar consistencia de cualquier red, penalización y algoritmo.

En presencia de tendencia, rupturas o cambios de varianza, transformar, modelar determinísticos o usar ventanas móviles puede ser útil y debe evaluarse.

Estabilidad dinámica

NNAR(1) determinista: demostración por contracción

Considerar $y_t = f(y_{t-1})$ y otra trayectoria $\widetilde{y}_t = f(\widetilde{y}_{t-1})$. Si $|f'(x)| \leq L < 1$ para todo x, el teorema del valor medio da:

$$\begin{aligned} |y_t - \widetilde{y}_t| &\leq L|y_{t-1} - \widetilde{y}_{t-1}| \\ &\leq L^t|y_0 - \widetilde{y}_0| \longrightarrow 0. \end{aligned}$$

Es una condición suficiente de olvido de condiciones iniciales. En el ejemplo, $|f'(x)| \leq .96 < 1$ y existe un punto fijo único en $\mathbb{R}$ por el teorema de contracción.

Estabilidad dinámica

Del mapa determinista al proceso con ruido

Si $y_t = f(y_{t-1}) + \varepsilon_t$, f es globalmente contractiva, las innovaciones son iid y $E|\varepsilon_t| < \infty$, puede construirse una solución causal estacionaria única por iteración desde el pasado.

Al acoplar dos trayectorias con las mismas innovaciones, estas se cancelan al restar y se conserva la cota de contracción anterior. Esto explica el olvido de condiciones iniciales.

Sin contracción, no se concluye automáticamente no estacionariedad: es una condición suficiente, no necesaria. Una activación acotada tampoco demuestra por sí sola todas las propiedades del proceso.

Estabilidad dinámica

Más de un rezago y dinámica local

Escribir el estado $S_t = (y_t, \ldots, y_{t-p+1})'$ y su mapa F permite estudiar el Jacobiano en un punto fijo. Su primera fila contiene $\partial f / \partial y_{t-j}$; las demás desplazan los rezagos.

Si todos sus autovalores tienen módulo menor que uno, el punto fijo es localmente asintóticamente estable bajo diferenciabilidad. No es una demostración de estabilidad global ni de estacionariedad del proceso estocástico.

La condición lineal de raíces AR no puede aplicarse directamente a los pesos individuales de una NNAR no lineal.

Metodología de modelación

Paso 1: explorar y definir la información

Fijar objetivo, frecuencia, horizonte y pérdida. Graficar nivel, transformación, estacionalidad, faltantes y posibles rupturas.

ADF tiene como nula una raíz unitaria bajo su especificación; KPSS tiene como nula estacionariedad de nivel o de tendencia. No son pruebas directas de que una NNAR esté bien especificada.

La ACF y PACF orientan posibles entradas lineales, pero no agotan relaciones no lineales. Incluir rezagos plausibles y contrastar su utilidad mediante evaluación temporal.

Metodología de modelación

Paso 2: construir la matriz sin fuga

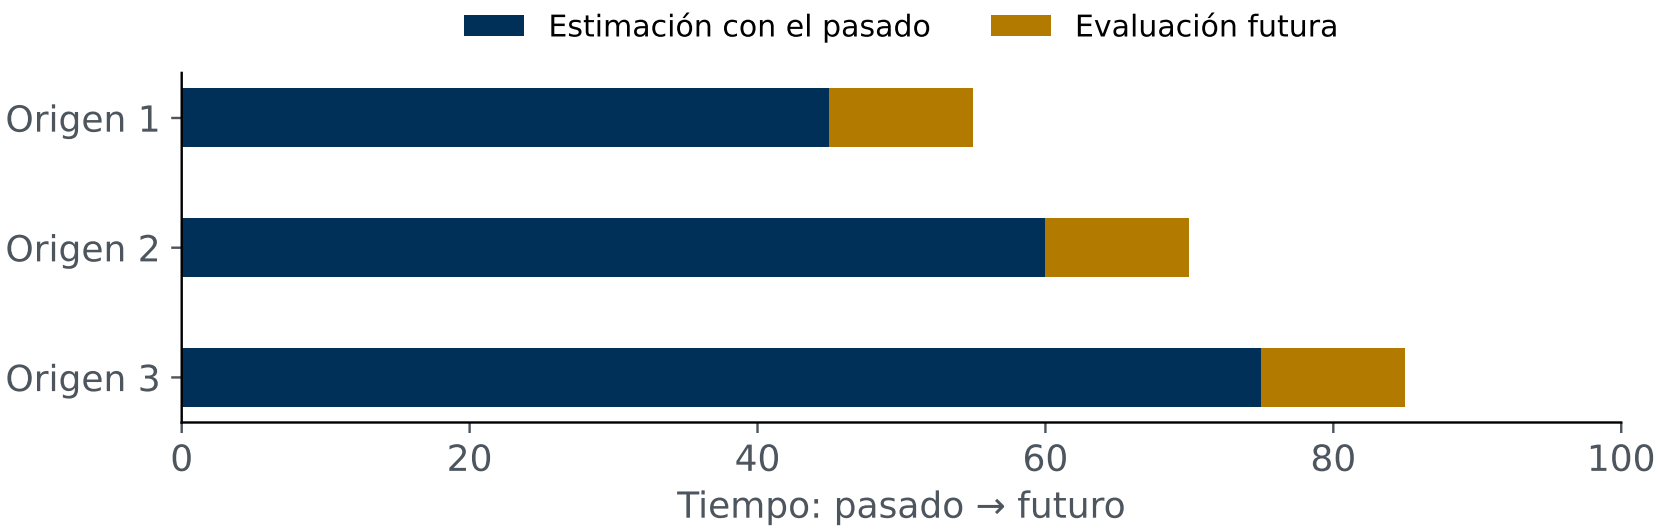
Para $\mathcal{L} = \{1, 2, 4\}$:

$$Z = \begin{pmatrix} y_4 & y_3 & y_1 \\ y_5 & y_4 & y_2 \\ \vdots & \vdots & \vdots \\ y_{T-1} & y_{T-2} & y_{T-4} \end{pmatrix}, \quad Y = \begin{pmatrix} y_5 \\ y_6 \\ \vdots \\ y_T \end{pmatrix}.$$

La respuesta siempre es posterior a sus entradas. Una fila con un faltante o un rezago faltante requiere tratamiento explícito. Escaladores e imputadores se calculan solo con el pasado del origen correspondiente.

Metodología de modelación

Paso 3: evaluar con orígenes móviles



Cada pronóstico utiliza exclusivamente información disponible en su origen. Se pueden usar ventanas expansivas o de longitud fija.

El bloque usado para escoger hiperparámetros no debe presentarse como una evaluación final independiente. Tras seleccionar y evaluar el procedimiento, reestimar con la muestra disponible para emitir el pronóstico operativo.

Pronóstico a varios periodos

Recursión NNAR(2)

Con una función de dos rezagos:

$$\widehat{y}_{T+1|T} = f(y_T, y_{T-1}),$$
$$\widetilde{y}_{T+2|T} = f(\widehat{y}_{T+1|T}, y_T),$$
$$\widetilde{y}_{T+3|T} = f(\widetilde{y}_{T+2|T}, \widehat{y}_{T+1|T}).$$

Se sustituyen valores desconocidos por predicciones. En una red no lineal, esta trayectoria sin innovaciones no tiene por qué coincidir con la media condicional exacta a varios pasos.

Pronóstico a varios periodos

Demostración de la diferencia respecto a un AR

Si $y_{t+1} = f(y_t) + \varepsilon_{t+1}$ y $E(\varepsilon_{t+1} \mid \mathcal{F}_t) = 0$:

$$E(y_{t+2} \mid \mathcal{F}_t) = E[f(y_{t+1}) \mid \mathcal{F}_t].$$

Para $f(x) = c + \phi x$, la linealidad permite intercambiar función y esperanza. Para $f(x) = x^2$:

$$E[f(y_{t+1}) \mid \mathcal{F}_t] = \mu_t^2 + \sigma_t^2,$$

mientras $f(\mu_t) = \mu_t^2$. La discrepancia no es error de programación: procede de integrar una función no lineal sobre la incertidumbre futura.

Pronóstico probabilístico

Simulación paso a paso

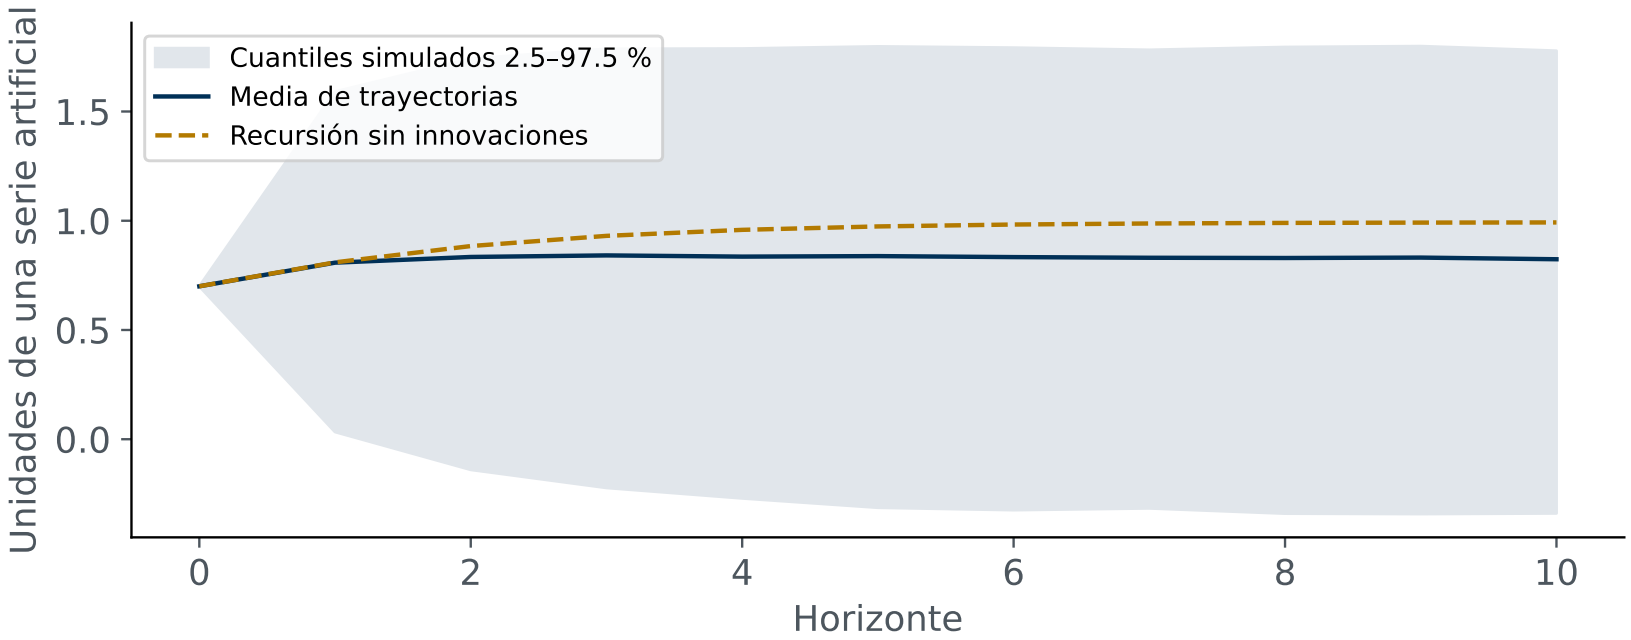
Con un modelo de innovaciones apropiado, para trayectoria b:

1. Inicializar con la misma historia observada hasta T.
2. Generar $\varepsilon_{T+1}^{(b)}$ y calcular $y_{T+1}^{(b)} = f(\text{historia}) + \varepsilon_{T+1}^{(b)}$.
3. Actualizar entradas con ese valor simulado y repetir hasta H.
4. Promediar trayectorias para estimar medias; tomar cuantiles por horizonte para intervalos.

La distribución de innovaciones debe justificar su independencia o modelar su dependencia y heterocedasticidad. Fijar pesos omite incertidumbre de estimación.

Pronóstico probabilístico

Demostración mediante una serie artificial



Se simulan 20 000 trayectorias de $y_{t+1} = .2 + 1.2\tanh(.8y_t) + \varepsilon_{t+1}$, con $\varepsilon \sim N(0, .4^2)$ iid y $y_T = .7$.

La recursión sin ruido y la media simulada divergen. La banda incluye solo innovaciones de este modelo conocido; no incorpora incertidumbre de pesos ni es una estimación del PIB.

Pronóstico probabilístico

Transformaciones y fuentes de incertidumbre

Si se modela $\log y$, invertir el pronóstico central con $e^{\widehat{\mu}}$ no produce en general $E(y \mid \mathcal{F}_T)$.

Simular en la escala transformada, invertir cada trayectoria y después resumir evita esa confusión cuando la simulación representa adecuadamente la distribución.

Distinguir incertidumbre de innovaciones, de parámetros y de selección del modelo. Promediar redes y remuestrear residuos del ajuste no cubre automáticamente las tres. Un sobreajuste puede producir residuos artificialmente pequeños e intervalos demasiado estrechos.

Validación del modelo

Qué debe comprobarse

- Desempeño temporal por horizonte frente a referentes pertinentes.
- Sensibilidad a rezagos, tamaño de red, penalización y semillas.
- Sesgo, autocorrelación y predictibilidad remanente en errores de un paso.
- Dinámica de varianza, colas y calibración de intervalos.
- Estabilidad del desempeño entre subperiodos y regímenes.

La validación evalúa evidencia compatible con un uso concreto. No convierte a la red en un modelo causal ni demuestra que sea la única especificación válida.

Validación del modelo

Métricas y referentes

$$RMSE_h = \sqrt{\frac{1}{N_h}\sum_o e_{o,h}^2}, \qquad MAE_h = \frac{1}{N_h}\sum_o |e_{o,h}|.$$

Comparar en las mismas fechas, escala y horizontes con ingenuo, ingenuo estacional, AR/ARIMA o ETS. Reportar también sesgo $\bar{e}_h$.

Para datos estacionales, MASE puede escalar el MAE por $\frac{1}{n-m}\sum_{t=m+1}^{n} |y_t - y_{t-m}|$ del entrenamiento. Ese denominador debe ser positivo. No usar datos de evaluación para definir la escala del error ingenuo.

Validación del modelo

Autocorrelación: qué prueba Ljung–Box

Para errores de un paso y n observaciones:

$$Q(m) = n(n+2)\sum_{j=1}^{m}\frac{\widehat{\rho}_j^2}{n-j}.$$

La nula es ausencia de autocorrelación hasta m, bajo las condiciones que justifican su distribución. No equivale a independencia ni a media condicional correcta.

Tras estimar y seleccionar una red no existe una corrección universal $m - N_\theta$ comparable a un ARMA regular. No restar todos los pesos. Una calibración por bootstrap debe reproducir el ajuste y la selección bajo una nula explícita.

Validación del modelo

Ortogonalidad e información no aprovechada

Si $e_t = y_t - E(y_t \mid \mathcal{F}_{t-1})$, entonces:

$$E[e_t \psi(\mathcal{F}_{t-1})] = 0$$

para funciones integrables apropiadas. La prueba de autocorrelación usa solo algunas funciones lineales del pasado.

Explorar e_t frente a rezagos, predicciones, calendario y otras variables permite detectar fallas que la ACF omite. Contrastes formales requieren tratar dependencia y selección; buscar muchas relaciones y reportar solo las significativas introduce multiplicidad.

Validación del modelo

Heterocedasticidad: ARCH-LM

Auxiliar conceptual:

$$e_t^2 = a_0 + \sum_{j=1}^{q} a_j e_{t-j}^2 + u_t,$$

$$H_0 : a_1 = \cdots = a_q = 0.$$

En su marco clásico, $LM = n_{\text{aux}} R^2$ tiene referencia asintótica χ_q^2 bajo regularidad. En residuos neuronales seleccionados, esa referencia necesita justificación o calibración específica.

Un rechazo señala posible dinámica de varianza. La respuesta puede ser una salida probabilística heterocedástica o un modelo de volatilidad, y no simplemente más neuronas para la media.

Validación del modelo

Normalidad y distribución predictiva

Jarque–Bera combina asimetría S y curtosis K:

$$JB = n\left(\frac{S^2}{6} + \frac{(K-3)^2}{24}\right).$$

Su referencia habitual χ^2_2 exige condiciones que no se transfieren automáticamente a errores dependientes de una red ajustada y seleccionada.

La NNAR puntual no requiere errores normales para ser calculada. Si se usan intervalos gaussianos, la distribución condicional sí importa: examinar Q–Q, colas y residuos estandarizados cuando haya una varianza estimada.

Validación del modelo

Cobertura y puntuación de intervalos

Para intervalo nominal $1-\alpha$, comprobar cobertura por horizonte y anchura. Una puntuación que penaliza ambos aspectos es:

$$\begin{aligned} IS_\alpha(L,U;y) = (U-L) \\ + \frac{2}{\alpha}(L-y)\mathbf{1}(y<L) \\ + \frac{2}{\alpha}(y-U)\mathbf{1}(y>U). \end{aligned}$$

Menor puntuación es mejor al comparar el mismo nivel nominal y conjunto de observaciones. También revisar cobertura por estación, nivel y régimen; un promedio global puede ocultar fallas sistemáticas.

Validación del modelo

Cambios respecto a los modelos lineales

Los pesos no tienen, por defecto, errores estándar y pruebas t convencionales. La no identificación interna, regularización y selección afectan la inferencia.

Las raíces de un AR no validan directamente la estabilidad de una NNAR. La estabilidad local se analiza mediante el Jacobiano del mapa dinámico, y la robustez operativa mediante evaluación temporal.

Ni los criterios de información lineales ni sus grados de libertad residuales se trasladan mecánicamente. Deben justificarse para el estimador y el modelo probabilístico utilizados.

Causalidad e interpretación económica

Qué cambia en una pregunta tipo Granger

En una NNAR univariante solo hay historia de la propia serie. Para preguntar si otra variable x añade información, construir modelos restringido y ampliado:

$$E(y_t \mid y_{<t}) \quad \text{frente a} \quad E(y_t \mid y_{<t}, x_{<t}).$$

Comparar capacidad predictiva temporal con complejidad y selección controladas. Un peso $w = 0$ aislado no describe en general la restricción funcional de no dependencia, por cancelaciones y rutas múltiples.

La mejora predictiva no demuestra causalidad estructural, y un contraste neuronal requiere un procedimiento inferencial específico.

Implementación en R

Correspondencia con nnetar; esquema sin ejecución

```
library(forecast)
set.seed(13)
ajuste <- nnetar(y_pasado, p = 2, P = 1,
                 size = 3, repeats = 20)
pronostico <- forecast(ajuste, h = 10,
                       PI = TRUE, npaths = 2000)
plot(pronostico)
```

Si `frequency(y_pasado)` es cuatro, esta configuración representa NNAR$(2, 1, 3)_4$. `repeats` controla múltiples inicializaciones promediadas. Los argumentos son una especificación ilustrativa, no órdenes seleccionados ni evidencia de una estimación realizada.

Implementación en Python

La matriz de rezagos debe construirse antes

```
from sklearn.neural_network import MLPRegressor

red = MLPRegressor(
    hidden_layer_sizes=(3,), activation="tanh",
    solver="lbfgs", alpha=0.1,
    max_iter=1000, random_state=13
)
# Z_pasado: columnas con rezagos únicos 1, 2 y 4
# y_pasado: respuestas posteriores a esas entradas
```

Es una red autorregresiva al utilizar rezagos como entradas; no replica exactamente `nnetar`. Escalamiento, penalización, optimizador, múltiples inicios y pronóstico recursivo requieren un flujo explícito. El esquema no se ejecuta al compilar estas diapositivas.

Caso económico

PIB: definir primero qué se pronostica

Si $g_t = 100\Delta \log PIB_t$, una NNAR sobre g_t modela crecimiento logarítmico, no el nivel directamente. Con pronósticos $\widehat{g}_{T+j|T}$:

$$\widetilde{PIB}_{T+h} = PIB_T \exp\left(\frac{1}{100}\sum_{j=1}^{h}\widehat{g}_{T+j|T}\right).$$

Es una trayectoria reconstruida; no necesariamente la media del nivel. Si se diferencia una serie ya ajustada estacionalmente, justificar qué estructura se conserva y evitar atribuirle estacionalidad solo por su frecuencia trimestral.

Ejercicio resuelto

Interpretar una comparación de pronósticos

En los mismos orígenes: NNAR obtiene MAE = .8 y AR obtiene MAE = 1.0.

$$\text{Reducción relativa de MAE} = 100\frac{1.0 - .8}{1.0} = 20\%.$$

Esto describe una mejora en ese diseño de evaluación. No significa 20% más de precisión en cualquier horizonte ni prueba causalidad.

Para valorar si es estable, revisar errores por origen, horizonte, régimen y semillas; para inferencia formal, considerar dependencia del diferencial de pérdidas y selección de modelos. Las cifras son ilustrativas.

Ejercicio de interpretación

¿Cómo leer una sensibilidad local?

Supongamos $\partial \widehat{g}_t / \partial g_{t-1} = .4$ en una historia concreta. Si g se mide en puntos de crecimiento logarítmico, aumentar g_{t-1} en .1 puntos cambia la predicción aproximadamente .04 puntos, manteniendo las demás entradas.

No implica que .4 sea un coeficiente fijo para toda la muestra ni que un choque causal tenga ese efecto.

Para una respuesta dinámica no lineal habría que especificar perturbación, historia inicial y distribución de futuras innovaciones, comparando trayectorias de forma coherente.

Fuentes

NNAR y pronóstico probabilístico

- Hyndman, R. J. y Athanasopoulos, G. (2021). *Forecasting: Principles and Practice*, 3.ª ed. Sección de redes neuronales.
- Hyndman, R. J. y Caceres, G. Documentación oficial de nnetar.
- Equipo de forecast. Pronósticos e intervalos de nnetar.
- Scikit-learn. Documentación oficial de MLPRegressor.

Documentación consultada el 30 de octubre de 2026. Las demostraciones y simulaciones son didácticas; no se presentan estimaciones empíricas inexistentes.

Fuentes

Inferencia y evaluación temporal

- Goodfellow, I., Bengio, Y. y Courville, A. (2016). *Deep Learning*, capítulos 6 y 7: redes de alimentación hacia adelante y regularización. Texto de los autores.
- Hyndman y Athanasopoulos. Validación cruzada temporal y Diagnóstico de residuos.
- Diebold, F. X. y Mariano, R. S. (1995). *Comparing Predictive Accuracy*. Journal of Business & Economic Statistics, 13(3), 253–263. Artículo.

Las referencias clásicas orientan preguntas de diagnóstico; sus distribuciones de prueba requieren justificar su aplicación al estimador neuronal y al diseño temporal concreto.